

МИНИСТЕРСТВО НАУКИ И ВЫСШЕГО ОБРАЗОВАНИЯ РОССИЙСКОЙ
ФЕДЕРАЦИИ
ФЕДЕРАЛЬНОЕ ГОСУДАРСТВЕННОЕ АВТОНОМНОЕ ОБРАЗОВАТЕЛЬНОЕ
УЧРЕЖДЕНИЕ ВЫСШЕГО ОБРАЗОВАНИЯ
«СЕВАСТОПОЛЬСКИЙ ГОСУДАРСТВЕННЫЙ УНИВЕРСИТЕТ»

“УТВЕРЖДАЮ”
Заведующий кафедрой
«Информационные технологии и
системы»



Моисеев Д.В. /

“ 26 ” августа 2025 г.

УЧЕБНО-МЕТОДИЧЕСКИЕ МАТЕРИАЛЫ ДИСЦИПЛИНЫ

Б1.О.27 Машинное обучение

(шифр и наименование дисциплины в соответствии с учебным планом)

09.03.04 Программная инженерия

(код и наименование направления подготовки / специальности)

Технологии программирования. Разработка игр

(наименование профиля / специализации)

бакалавриат

(уровень высшего образования)

очная, 2025

(форма обучения, год набора)

Севастополь
2025

Содержание

1. ЛАБОРАТОРНАЯ РАБОТА 1. СБОР ДАННЫХ ДЛЯ МАШИННОГО ОБУЧЕНИЯ.....	3
2. ЛАБОРАТОРНАЯ РАБОТА 2. ПРЕДВАРИТЕЛЬНЫЙ АНАЛИЗ И ВИЗУАЛИЗАЦИЯ ДАННЫХ.	27
3. ЛАБОРАТОРНАЯ РАБОТА 3. МЕТОДЫ РЕГРЕССИИ.	35
4. ЛАБОРАТОРНАЯ РАБОТА 4. МЕТОДЫ КЛАССИФИКАЦИИ.	42
5. ЛАБОРАТОРНАЯ РАБОТА 5. КЛАСТЕРНЫЙ АНАЛИЗ.	46
ЛАБОРАТОРНАЯ РАБОТА 6. ПРЕДСТАВЛЕНИЕ РЕЗУЛЬТАТОВ АНАЛИТИЧЕСКОГО ПРОЕКТА.....	51

1. ЛАБОРАТОРНАЯ РАБОТА 1. СБОР ДАННЫХ ДЛЯ МАШИННОГО ОБУЧЕНИЯ.

Цель работы: Изучить методы сбора данных для машинного обучения, извлечения данных из источников: использование открытых данных, подключения к источникам данных; сбор с использованием систем бизнес-аналитики, генерация синтетических данных.

Часть 1. Анализ открытых источников данных.

Цель работы: Научиться извлекать данные из открытых источников и проводить их предварительную обработку средствами Microsoft Excel.

Краткие теоретические сведения.

Открытые данные (англ. open data) — концепция, отражающая идею о том, что определённые данные должны быть свободно доступны для машиночитаемого использования и дальнейшей републикации без ограничений авторского права, патентов и других механизмов контроля.

Открытые данные – информация, размещенная в сети «Интернет» в виде массивов данных в формате, обеспечивающем их автоматическую обработку в целях повторного использования без предварительного изменения человеком (машиночитаемый формат), и на условиях ее свободного (бесплатного) использования.

Освободить данные от ограничений авторского права можно с помощью свободных лицензий, таких как лицензий Creative Commons. Если какой-либо набор данных не является общественным достоянием, либо не связан лицензией, дающей права на свободное повторное использование, то такой набор данных не считается открытым, даже если он выложен в машиночитаемом виде в Интернет.

Цели движения открытых данных похожи на другие «открытые» движения, такие как открытое программное обеспечение (open source), открытый контент (open content) и открытый доступ (open access). Рост популярности идеи об открытых данных во второй половине 2000-х годов связан, прежде всего, с запуском правительственных инициатив, таких как Data.gov.

Доступ к данным, как и последующее их использование, контролируется организациями — государственными и частными. Контроль может быть через ограничения, лицензии, копирайт, патенты и требования оплаты для доступа или повторного использования. Сторонники идеи «открытых данных» считают, что подобные ограничения идут против общественного блага и данные должны быть доступны без ограничений или оплаты. Также важно что данные должны быть доступны без последующих запросов на разрешение, хотя и способы повторного использования, такие как создание продуктов на базе данных, могут контролироваться лицензией.

Открытые данные могут поступать из различных источников. Однако наибольшие массивы данных публикуются (или готовятся к публикации) государственными органами и научным сообществом.

Концепция открытого доступа к государственным данным является одним из ключевых интересов общества, многочисленные некоммерческие организации и отдельные активисты, которые добиваются открытости государственной информации в машиночитаемой форме. Многие правительства в рамках стратегий «открытого государства» создали веб-сайты для распространения части данных, обрабатываемых в секторе государственного управления.

В октябре 2015 года Партнерство «Открытое правительство» (OGP) приняло

Международную хартию открытых данных — набор принципов и передовых методов публикации открытых государственных данных, во время Международного саммита OGP в Мексике.

Условия использования открытых данных.

Пользователь может использовать (в том числе повторно) открытые данные свободно, бесплатно, бессрочно, безвозмездно и без ограничения территории использования, в том числе имеет право копировать, публиковать, распространять открытые данные, видоизменять открытые данные и объединять их с другой информацией, использовать открытые данные в некоммерческих и коммерческих целях, использовать для создания программ для ЭВМ и приложений.

При использовании открытых данных пользователь обязан:

- использовать открытые данные только в законных целях;
- не искажать открытые данные при их использовании;
- сохранять ссылку на источник информации при использовании открытых данных.

ГЛОССАРИЙ

Агрегированные данные — данные, сведенные вместе по тому или иному признаку непосредственно или с использованием определенного алгоритма обработки. Допустим, есть реестр контрактов, где каждая запись содержит сведения о сумме контракта, заказчике и поставщиках. Из такого реестра можно получить, например, список всех заказчиков, которые встречаются в контрактах, и для каждого заказчика посчитать, сколько контрактов он заключил и какова сумма заключенных им контрактов. Полученные цифры будут агрегированными данными.

База данных — система хранения комплексной информации, описывающей ту или иную предметную область. Допускает сложную иерархию данных и групп данных, а также позволяет выстраивать связи между различными группами данных. Также обладает инструментами фильтрации для быстрого поиска необходимых данных по заданным признакам.

Данные — поддающееся многократной интерпретации представление информации в формализованном виде, пригодном для передачи, связи, или обработки.

Документ — файл немашиночитаемого формата, содержащий неструктурированную информацию. Это может быть, например, текст или изображение в форматах DOC(X), PDF, JPG, PNG и т.п.

Машиночитаемые форматы данных — форматы представления и публикации данных, предназначенные для обработки машинными методами. К ним относятся такие форматы, как: CSV (TSV), JSON, XML, XLSX, XLS и другие.

Метаданные — данные, описывающие набор данных или документ. Например, даты его создания и обновления; автора; публикатора; контактную и лицензионную информацию и т.п.

Набор данных — совокупность данных, представленных в машиночитаемом формате и описывающих те или иные процессы, явления или предметную область. В отличие от базы данных, обычно обладают плоской или несложной иерархической структурой и

сравнительно небольшим объемом, поэтому для их публикации часто используются табличные форматы (CSV, XLS/XLSX).

Неструктурированная информация – информация, представленная в форме, пригодной, прежде всего, для человеческого восприятия. Например, текст, изображение, видео- или аудиозапись. В ряде случаев неструктурированную информацию возможно и даже целесообразно преобразовывать в структурированную.

Обладатель данных – в контексте открытых данных под этим подразумевается лицо, получившее доступ к данным. Схожее понятие присутствует в законе «Об информации»[2], где «обладатель информации» определяется как «лицо, самостоятельно создавшее информацию либо получившее на основании закона или договора право разрешать или ограничивать доступ к информации, определяемой по каким-либо признакам».

Обезличенные данные – данные, которые нельзя соотнести с каким-либо конкретным субъектом. Федеральное законодательство не поясняет, что такое обезличенные данные, однако дает понятие «обезличивания персональных данных»: действия, в результате которых становится невозможным без использования дополнительной информации определить принадлежность персональных данных их конкретному субъекту. Также в законодательстве нет понятия анонимизированных данных, но это понятие есть в европейском регламенте GDPR (General Data Protection Regulation). По сути, это окончательно обезличенные данные – то есть данные, которые нельзя соотнести с их конкретным владельцем, проведя «реидентификацию». Если же такое возможно, то такой вид обезличенных данных называют «псевдоанонимизированными».

Открытые данные – данные, опубликованные в публичном доступе в сети Интернет в машиночитаемом формате и под свободной (открытой) лицензией, допускающей бесплатное повторное использование этих данных, их переработку и распространение. Приведенное каноническое определение затрагивает только машиночитаемые данные, однако практически все (кроме узко технических) рекомендации и нормы по работе с открытыми данными затрагивают и публикацию данных в не машиночитаемых форматах.

Персональные данные – любая информация, относящаяся к определенному или определяемому на ее основании физическому лицу (субъекту персональных данных). Например, фамилия, имя, отчество в комбинации с датой и местом рождения или адресом проживания уже позволяют это сделать.

Повторное использование – практика многократного использования (в исходном или переработанном виде) одних и тех же данных или документов.

Свободная (открытая) лицензия – лицензия, дающая максимально широкие права на использование данных и документов, в том числе право на бесплатное повторное использование, переработку и распространение. Лицензии, требующие при повторной публикации ссылки на источник или указания авторства, обычно относят к открытым. С оговорками к ним иногда относят лицензии, требующие, чтобы на продукты, созданные с использованием лицензируемых материалов, распространялись те же права, что и на исходный материал. Лицензии, которые добавляют к этому запрет на коммерческое использование, к открытым не относятся.

Сырые данные – данные, не прошедшие какую-либо обработку и представленные в своем первичном виде. Пример не сырых (обработанных) данных - это статистика, обобщающая показатели исходного набора, или агрегированные данные. То, на основе чего рассчитана

эта статистика или произведена агрегация, и есть сырые данные.

Человекочитаемые форматы данных – форматы представления и публикации данных, предназначенные для восприятия человеком. Например, DOC/DOCX, PDF, PPT/PPTX, JPEG, PNG, TIFF, GIF, HTML и т.п. Хотя некоторые из них относительно легко поддаются машинной обработке (как, например, HTML), их главная задача в том, чтобы упростить человеческое зрительное восприятие (зачастую в ущерб структурированности и последовательности, необходимым для корректной машинной обработки).

Чувствительные данные – данные, раскрытие которых может нести риски для субъекта, к которому они относятся. Для физического лица к ним можно отнести, например, информацию об этническом или расовом происхождении, состоянии здоровья, политических и религиозных убеждениях, а для коммерческого – информацию о производственных процессах и особенностях сделок. Этот термин не имеет сейчас определения в российском законодательстве, но уже определен в рамках европейского регламента по защите данных GDPR (General Data Protection Regulation).

Задание на лабораторную работу

Необходимо выполнить следующие действия:

1. Выбрать источник открытых данных для исследования наборов данных, согласно варианту (таблица 1).
2. Определить набор данных для анализа, скачать его в форматах xlsx, или csv).
3. Загрузить данные в Microsoft Excel.
4. Проанализировать данные по временным периодам, визуализировать данные в виде различных диаграмм (столбчатых, лепестковых и др.).

Таблица 1 – Варианты заданий.

№	Источник данных	Адрес
1.	Открытые данные России	https://data.gov.ru/
2.	Портал государственной статистики	https://fedstat.ru/
3.	Федеральная служба государственной статистики	https://rosstat.gov.ru/opendata/ , https://rosstat.gov.ru/statistic
4.	Федеральная служба по гидрометеорологии и мониторингу окружающей среды	https://www.meteorf.ru/opendata/index.php
5.	Хаб открытых данных АНО "Информационная культура"	https://opengovdata.ru/dataset/
6.	Портал открытых данных Правительства Москвы	https://data.mos.ru/
7.	Система классификаторов и открытые данные Санкт-Петербурга	https://classif.gov.spb.ru/
8.	Открытые данные Сбербанка	https://sberindex.ru/ru
9.	Министерство финансов Российской Федерации	https://minfin.gov.ru/ru/opendata/
10.	Министерство просвещения Российской Федерации	https://opendata.edu.gov.ru/opendata/

11.	Министерство науки и высшего образования Российской Федерации	https://www.minobrnauki.gov.ru/opendata/
12.	Министерство культуры Российской Федерации	https://opendata.mkrf.ru/

По согласованию с преподавателем можно использовать другие источники и форматы данных.

Ход работы

1. Выбор источника открытых данных.

Выбираем источник данных для исследования, например <https://minfin.gov.ru/ru/opendata/> (Рисунок 1). Желательно выбирать источники, предоставляющие наборы данных в формате **xlsx**. При предоставлении данных в формате **CSV** может потребоваться дополнительная ручная обработка данных.




Рисунок 1 – Пример источника данных для исследования

2. Выбор набора данных

2.1 Выбираем набор данных для исследования (рисунок 2).

№	Название	Статус	Просмотры Скачивания	Рейтинг	Дата обновления
	Наборов открытых данных 175: в формате CSV 170, в формате XML 5				
1	Организации, находящиеся в ведении Минфина России CSV 13.9 Кб Паспорт		0 53	2.7	31.07.2020
14	Государственный внутренний долг Российской Федерации CSV 0.4 Кб Паспорт		0 107	2.69	01.02.2022
16	Информация об объеме Фонда национального благосостояния CSV 0.4 Кб Паспорт		0 50	2.7	30.10.2021
17	План проведения плановых проверок саморегулируемых организаций аудиторов CSV 0.9 Кб Паспорт		0 56	2.66	22.12.2021

Рисунок 2 – Пример набора данных для исследования

2.2 Просматриваем паспорт набора данных (Рисунок 3).

14. Государственный внутренний долг Российской Федерации		
Вернуться к списку		
№	Название поля паспорта	Значение поля паспорта
1	Идентификационный номер	7710168360-DomesticDebt
2	Наименование набора открытых данных	Государственный внутренний долг Российской Федерации
3	Описание набора открытых данных	В соответствии со статьей 6 Бюджетного кодекса Российской Федерации внутренним долгом являются обязательства, возникающие в валюте Российской Федерации. В соответствии с частью 4 статьи 98 Бюджетного кодекса Российской Федерации в объем государственного внутреннего долга Российской Федерации включаются: 1) номинальная сумма долга по государственным ценным бумагам Российской Федерации, обязательства по которым выражены в валюте Российской Федерации; 2) объем основного долга по кредитам, которые получены Российской Федерацией и обязательства по которым выражены в валюте Российской Федерации; 3) объем основного долга по бюджетным кредитам, полученным Российской Федерацией; 4) объем обязательств по государственным гарантиям, выраженным в валюте Российской Федерации; 5) объем иных (за исключением указанных) долговых обязательств Российской Федерации, оплата которых в валюте Российской Федерации предусмотрена федеральными законами до введения в действие БК РФ. Периодичность обновления: ежемесячная
4	Владелец набора открытых данных	Министерство финансов Российской Федерации Департамент государственного долга и государственных финансовых активов
5	Ответственное лицо	Морозова Елена Васильевна Бычкова Ольга Александровна
6	Телефон ответственного лица	+7 (495) 983-38-88 доб. (0478, 0465, 0427)
7	Адрес электронной почты ответственного лица	Elena.Morozova@minfin.ru Olga.Bychkova@minfin.ru
8	Гиперссылка (URL) на открытые данные	http://minfin.ru/OpenData/7710168360-DomesticDebt/data-20220201-structure-20190204.csv посмотреть
9	Формат набора открытых данных	CSV
10	Описание структуры набора открытых данных	http://minfin.ru/OpenData/7710168360-DomesticDebt/structure-20190204.csv
11	Дата первой публикации набора открытых данных	2014-04-02

Рисунок 3 – Пример паспорта набора данных

2.3. Просматриваем набор данных (Рисунок 4)

 ОТКРЫТЫЕ ДАННЫЕ

14. Государственный внутренний долг Российской Федерации

[Вернуться к паспорту набора](#)

7710168360-DomesticDebt/data-20211216-structure-20190204.csv

Государственный внутренний долг Российской Федерации	Государственные гарантии Российской Федерации в валюте Российской Федерации	код разреза	код признака	Отчетная дата
16764978136.6	738549607.7	OKEI	384	2021-12-01

Рисунок 4 – Просмотр набора данных

Если набор данных выбран, возвращаемся на страницу паспорта и скачиваем его. Иначе просматриваем другой набор данных. При необходимости анализа данных за более ранний временной период можно скачать со страницы паспорта более ранние версии набора данных (Рисунок 5).

11	Дата первой публикации набора открытых данных	2014-04-02
12	Дата последнего внесения изменений	2022-02-01
13	Содержание последнего изменения	Информация по состоянию на 2022-01-01
14	Дата актуальности набора данных	2022-02-25
15	Ключевые слова, соответствующие содержанию набора данных	Государственный внутренний долг Российской Федерации
16	Гиперссылка (URL) на версии открытых данных	http://minfin.ru/OpenData/7710168360-DomesticDebt/data-20211216-structure-20190204.csv http://minfin.ru/OpenData/7710168360-DomesticDebt/data-20211115-structure-20190204.csv http://minfin.ru/OpenData/7710168360-DomesticDebt/data-20211015-structure-20190204.csv http://minfin.ru/OpenData/7710168360-DomesticDebt/data-20210916-structure-20190204.csv http://minfin.ru/OpenData/7710168360-DomesticDebt/data-20210812-structure-20190204.csv http://minfin.ru/OpenData/7710168360-DomesticDebt/data-20210713-structure-20190204.csv http://minfin.ru/OpenData/7710168360-DomesticDebt/data-20210611-structure-20190204.csv http://minfin.ru/OpenData/7710168360-DomesticDebt/data-20210514-structure-20190204.csv http://minfin.ru/OpenData/7710168360-DomesticDebt/data-20210416-structure-20190204.csv http://minfin.ru/OpenData/7710168360-DomesticDebt/7710168360-DomesticDebt.zip
17	Гиперссылка (URL) на версии структуры открытых данных	http://minfin.ru/OpenData/7710168360-DomesticDebt/structure-20181217.csv http://minfin.ru/OpenData/7710168360-DomesticDebt/structure-20141127.csv
18	Версия методических рекомендаций	3.0

Типовые условия использования общедоступной информации, размещаемой в информационно-телекоммуникационной сети «Интернет» в форме открытых данных (утв. протоколом заочного голосования Правительственной комиссии по координации деятельности открытого правительства от 19 сентября 2016 г. № 6) 

[Скачать файловое представление паспорта набора](#)

Рисунок 5 – Предыдущие версии набора данных

3. Загрузка данных в Microsoft Excel.

При скачивании набора данных в формате CSV необходимо преобразовать его в формат xlsx с помощью онлайн-инструментов, например <https://convertio.co/ru/csv-xls/> (Рисунок 6):




Рисунок 6 – Конвертор файлов Convertio.co
Затем загружаем файл с набором данных в Microsoft Excel.

4. Провести анализ данных.

Рассмотрим процесс анализа данных на примере анализа набора данных источника <https://data.mos.ru/> - Портала открытых данных Правительства Москвы.

4.1 Выбираем поставщика данных – Департамент региональной безопасности и противодействия коррупции города Москвы (Рисунок 7).




Рисунок 7 – Выбор поставщика данных

4.2 Далее выбираем набор данных - Данные по количеству выявленных общественными пунктами охраны порядка в городе Москве фактов незаконной сдачи жилья в аренду (поднаем) по административным округам – и скачиваем его в формате xlsx. (Рисунок 8).




Рисунок 8 – Скачивание набора данных

4.3 Загружаем данные в Microsoft Excel. При загрузке данных может возникнуть следующая ситуация: числовые данные могут быть сохранены как текст (Рисунок 9).




Рисунок 9 – Числовые данные сохранены как текст

В этом случае нужно преобразовать текст в число по инструкции ниже (материал из справки Excel, преобразовывать формат в денежный или финансовый не обязательно) (Рисунок 10):

	D	E	F	G	H
	Расходы				
	107,71				
	89,55				
	101,11				
	=СУММ(D2:D4)				


Числа, хранящиеся как текст, могут приводить к непредвиденным результатам. Выделите ячейки и нажмите кнопку , чтобы выбрать вариант преобразования. Если эта кнопка недоступна, выполните указанные ниже действия.

1. Выделите столбец

	D	E	F	G
Расходы				
107,71				
89,55				
101,11				
=СУММ(D2:D4)				


Выделите столбец с такими ячейками. Если вы не хотите преобразовывать весь столбец, можно выбрать одну или несколько ячеек. Ячейки должны находиться в одном и том же столбце, иначе этот процесс не будет работать. (Если такие ячейки есть в нескольких столбцах, см. раздел "Другие способы преобразования" ниже.)

2. Нажмите эту кнопку




Кнопка "столбцы" обычно применяется для разделения столбцов, но ее также можно использовать для преобразования столбца текста в числа. На вкладке **Данные** нажмите кнопку **Текст по столбцам**.

3. Нажмите кнопку "Готово"



Остальные шаги мастера нужны для разделения текста на столбцы. Так как нам нужно только преобразовать текст, нажмите кнопку **Готово**, и Excel преобразует ячейки.

4. Задайте формат



Нажмите клавиши CTRL+1 (или ⌘ +1 на Mac). Выберите нужный формат.

Рисунок 10 – Преобразование текста в числовые данные

4.4 Расширяем границы столбцов для удобства работы, устанавливаем фильтры (Рисунок 11):

	A	B	C	D	E	F	G	H	I	J
1	AdmArea	Year	Month	NumberFacts	global_id					
2	Центральный административный округ	2016	Январь	126	667045962					
3	Северо-Восточный административный округ	2016	Январь	255	667047873					
	Северо-Западный административный округ									

Рисунок 11 – Установка фильтров

4.5. Настраиваем фильтры под задачу, например, анализа данных за 2019 год по Центральному административному округу (Рисунок 12).

398	Центральный административный округ	2019	Январь	528	926857372
399	Центральный административный округ	2019	Февраль	553	926857375
400	Центральный административный округ	2019	Март	560	926857377
401	Центральный административный округ	2019	Апрель	544	926857379
402	Центральный административный округ	2019	Май	375	926857382
453	Центральный административный округ	2019	Июнь	773	930701900
464	Центральный административный округ	2019	Июль	598	933917693

Рисунок 12 – Установка фильтров

4.6. Выделяем столбцы с названием месяца и NumberFacts (Числом фактов) и строим лепестковую диаграмму (Рисунок 13, 14).




Рисунок 13 – Построение лепестковой диаграммы




Рисунок 14 – Лепестковая диаграмма количества выявленных общественными пунктами охраны порядка в городе Москве фактов незаконной сдачи жилья в аренду (поднаем) за 2019 год по месяцам в Центральном административном округе

4.7. Проводим такой же анализ данных по всем административным округам, сравниваем диаграммы.

4.8. Делаем выводы по проведенному анализу данных.

Содержание отчета

Отчет должен содержать следующие разделы: цель работы, краткие теоретические сведения, ход работы со скриншотами выполнения, анализ результатов и выводы. В выводах рекомендуется перечислить возникшие проблемы при анализе данных, оценить качество и удобство использования источников открытых данных.

Контрольные вопросы

1. Дайте определение понятию «Открытые данные».
2. Поясните различия между агрегированными и сырыми данными.
3. Что такое набор данных?
4. Какая информация содержится в паспорте набора данных?
5. Приведите пример машиночитаемых форматов данных.
6. Как преобразовать текст в число в Microsoft Excel?
7. Какой источник открытых данных вы использовали для анализа?
8. Какие выводы по проведенному анализу открытых данных можно сделать?

Часть 2. Сервис визуализации данных Yandex DataLens.

Цель работы: приобрести навыки подключения к источникам данных и построения интерактивных дашбордов с использованием сервиса визуализации данных Yandex DataLens.

Краткие теоретические сведения.

Аналитическая панель или дашборд возникла как синтез мощных математических средств аналитики и оптимального графического представления результатов анализа. Руководство компаний хотело видеть ключевые показатели эффективности, тренды, зависимости и другие метрики в понятном компактном виде, а также интерактивно изменять различные параметры. Кроме наглядной визуализации данных, основные цели, достигаемые с помощью дашбордов, связаны со сравнением того или иного показателя во времени или оценкой относительно других показателей [1].

Дашборд — это интерфейс между системой анализа данных и пользователем-аналитиком. К дашборду применимы все принципы построения интерфейсов, методы улучшения UX и повышения Usability.

Пользователи любого интерактивного продукта хотят иметь быстрый и функциональный инструмент. Дашборды в современных условиях высокой конкуренции должны также учитывать принципы визуализации данных и иметь высокий User Experience.

Принципы визуализации данных:

- 1) упрощайте — уловите суть и покажите проще;
- 2) сравнивайте — покажите необходимые визуализации рядом;
- 3) сопровождайте — облегчите доступ к важным данным;
- 4) исследуйте — позвольте посмотреть и найти новые знания;
- 5) смотрите иначе — дайте разные представления одних и тех же данных, что породит различные идеи;
- 6) спрашивайте “почему?” — больше, чем «что происходит», важно дать понять «почему это происходит», как возник тот или иной результат действий;
- 7) будьте скептиками — дайте возможность задавать больше вопросов и сразу получать ответ на них;
- 8) откликайтесь — не просто отвечайте на вопросы, предоставьте средства, чтобы делиться знаниями.

Правила разработки дашбордов:

- 1) высокое соотношение графики для данных к общему занимаемому ею месту (data-ink ratio) — увеличьте количество полезного изображения на занимаемом визуализацией пространстве, т.е. максимизируйте отображение основной информации;
- 2) отсутствие графического мусора (chartjunk) — исключайте неважные графические элементы, не отвлекайте от данных лишним дизайном.

Аналитические данные показываются разными виджетами от таблицы и диаграммы до стрелочных индикаторов. Некоторые инструменты позволяют программисту самому реализовать требуемую визуализацию вплоть до анимаций, видео или произвольной инфографики. Аналитические данные представляют из себя сгруппированные и агрегированные исходные данные. Есть возможность применить фильтры и сортировки на разных уровнях, отсекают данные по топовым значениям, создавать вычисляемые поля практически любой сложности. Пример дашборда приведен на рисунке 1.




Рисунок 1 – Пример Дашборда

Основные понятия аналитических дашбордов

- 1) **группировка** — способ объединения схожих данных (по какому-то общему признаку, например по первой букве слова или имени человека);
- 2) **агрегация** (сумма, минимум, максимум, количество и т.д.) — способ отображения колонки фактов из исходной базы данных (например уникальное количество посетителей сайта, или сумма расходов на продукты);
- 3) **сортировка** — упорядочивание уже сгруппированных данных по заданному признаку (кроме алфавита, можно отсортировать фамилии менеджеров по их наибольшим продажам за месяц и т.п.);
- 4) **фильтрация** — исключение данных по заданному признаку или сложной формуле;
- 5) **вычисляемая колонка** — способ получения новых данных и знаний с использованием методов работы с датами, строками, математических функций (например отображение имени и фамилии, вычисление возраста согласно дате рождения и текущей дате);
- 6) **топовые (лучшие) значения** — способ отобразить указанное количество максимальных или минимальных значений данной группировки (например, возраст трёх самых молодых сотрудников крупной компании, или пять менеджеров, обеспечивающих максимальные продажи);
- 7) **виджеты** (таблицы, диаграммы, карты и т.п.) — собственно способ визуализации вышеуказанных понятий.

Дашборды, как правило, позволяют подключаться к обширному списку источников данных, начиная от Excel-файла и заканчивая источниками больших данных. Часто заранее подготавливается специализированный для аналитики источник, именуемый хранилищем данных. Это делается в случаях, когда запрос данных к исходному источнику требует большого количества времени или запрос перегружает сервер, что недопустимо.

Сервис визуализации данных Yandex DataLens

Компания Яндекс предоставляет сервис визуализации данных Yandex DataLens [2], (рисунок 2) который обладает следующими функциональными возможностями:

- 1) Визуализация данных через простой интерфейс: Создание отдельного графика (диаграммы), чтобы проверить гипотезу, или сборка полноценного дашборда

- с ключевыми бизнес-метриками для всей команды.
- 2) Публичные дашборды: Визуализация данных и публикация их в открытом доступе. Yandex DataLens позволяет делиться дашбордами и встраивать визуализации во внешние порталы.
 - 3) Хранение востребованных данных: Настройка автоматической загрузки часто используемых данных, что позволит уменьшить нагрузку на источник данных и ускорить работу с графиками и таблицами.
 - 4) Работа с разными источниками данных. Подключение своих данных, использование уникальных коннекторов или наборов данных. Данные из разных источников можно комбинировать в рамках одного дашборда или графика.
 - 5) Тарификация. Плата за фактическое потребление, а не за количество пользователей. Визуализация данных из внутренних источников и управляемых баз данных Yandex.Cloud для всех пользователей — бесплатно. Для использования сервиса необходимо иметь аккаунт Яндекса.




Рисунок 2 – Сервис визуализации данных Yandex DataLens

Задание на лабораторную работу

1. Изучить информацию о Yandex DataLens [4] [по ссылке](#).
2. Выполнить сценарий визуализации данных и построения дашборда согласно варианту в таблице 1.
3. Провести визуализацию данных своего датасета из части 1 Анализ данных из открытых источников.
4. Составить отчет по работе, включающий:
 - цель работы,
 - краткий ход работы со скриншотами,
 - публичную ссылку на дашборды для возможности проверки.
 - выводы.

Таблица 1 Варианты заданий

№ в списке группы	№ варианта	Тема дашборда	Ссылка
1,6,11, 16,21	1	Визуализация данных из CSV-файла Супергерои	https://yandex.cloud/ru/docs/datalens/tutorials/data-from-csv-visualization
2, 7, 12, 17, 22	2	Визуализация данных из CSV-файла Диаграмма с картой Москвы	https://yandex.cloud/ru/docs/datalens/tutorials/data-from-csv-to-public-visualization
3, 8, 13, 18, 23	3	Анализ продаж сети магазинов из БД ClickHouse	https://yandex.cloud/ru/docs/datalens/tutorials/data-from-ch-visualization
4, 9, 14, 19, 24	4	Анализ открытых данных ДТП на дорогах России	https://yandex.cloud/ru/docs/datalens/tutorials/data-from-csv-geo-visualization
5, 10, 15, 20, 25	5	Анализ продаж и локаций пиццерий на данных из БД Clickhouse и Marketplace	https://yandex.cloud/ru/docs/datalens/tutorials/data-from-ch-to-geolayers-visualization

Контрольные вопросы

1. Что такое дашборд?
2. Как загрузить данные в Yandex DataLens?
3. Как создать чарт (график)?
4. Как провести сортировку данных на графике?
5. Как создать и редактировать дашборд?
6. Как добавить график на дашборд?
7. Что такое селектор? Для чего его применяют?
8. Как предоставить публичный или приватный доступ к дашборду?

Список источников:

1. Дашборд — что это и почему он будет вам полезен или современный способ сделать тайное явным
<https://habr.com/ru/company/devexpress/blog/341972/>
2. Yandex DataLens. Сервис анализа и визуализации данных от Yandex Cloud. Доступная аналитика любого масштаба — от графиков и дашбордов до аналитических систем. <https://datalens.yandex.cloud/>
3. Как начать работать с DataLens. <https://yandex.cloud/ru/docs/datalens/quickstart>
4. Обучающие курсы и материалы по Yandex DataLens
<https://yandex.cloud/ru/docs/datalens/training>
5. Практические руководства DataLens
<https://yandex.cloud/ru/docs/datalens/tutorials/>

Часть 3. Генерация синтетических данных.¹

Цель работы: изучить методы генерации синтетических данных с использованием библиотек Faker и Sklearn.

Краткие теоретические сведения.

Синтетические данные -это искусственно созданные наборы данных, которые имитируют реальные данные, но не основаны на реальных событиях. Они генерируются с помощью алгоритмов и математических моделей, которые воспроизводят статистические свойства, паттерны и взаимосвязи, присущие реальным данным. По сути, это цифровые двойники реальности, где мы можем контролировать каждый параметр: от распределений до корреляций и аномалий.

Преимущества синтетических данных:

1. **Быстрое создание больших объемов данных.** Одним из главных преимуществ синтетических данных является возможность генерировать их достаточно быстро и в любом количестве. Это особенно актуально для моделей глубокого обучения, которые часто требуют миллионы примеров для достижения высокого качества. В то время как сбор и разметка такого количества реальных данных может занять месяцы или даже годы, синтетические данные можно создать намного быстрее.
2. **Моделирование редких событий и edge-cases.** Редкие события, такие как финансовые мошенничества или редкие заболевания, по определению трудно зафиксировать в достаточном количестве для обучения моделей. Обучение на таких несбалансированных данных чревато созданием модели, которая будет склонна предсказывать только доминирующий класс, игнорируя редкие, но важные случаи. Синтетические данные позволяют искусственно сбалансировать классы, создавая дополнительные примеры для миноритарных классов.
3. **Снижение затрат на сбор данных.** Традиционный сбор данных – ресурсоемкий и дорогостоящий процесс. Синтетические данные позволяют значительно снизить финансовые и временные издержки на этапах разработки, тестирования и прототипирования продуктов и моделей машинного обучения.
4. **Решение проблем конфиденциальности и приватности.** Синтетические данные не содержат персональной информации и не подпадают под действие законодательных ограничений, связанных с обработкой персональных данных. Это делает их идеальным решением для работы с чувствительной информацией в различных средах, включая разработку, тестирование и исследовательскую деятельность.
5. **Полный контроль над характеристиками данных.** Как правило, инструменты генерации предоставляют достаточный контроль над всеми аспектами создаваемых датасетов, включая распределения, корреляции, аномалии и другие статистические параметры.

Области применения синтетических данных выходят далеко за рамки задачи data science. В разработке ПО они позволяют проводить тщательное тестирование без раскрытия конфиденциальной информации. В кибербезопасности могут моделировать шаблоны атак, не подвергая риску реальные системы. Для стартапов в отраслях с ограниченным доступом к данным синтетика может сократить цикл разработки с месяцев до недель, не заставляя ждать, пока соберётся достаточная выборка из реального мира.

¹ Выполняется при необходимости, если это требуется для конкретной задачи сбора и анализа данных либо для освоения компетенции BD1 Предварительный анализ данных, индикатора BD1.3 на продвинутом уровне.

Недостатки синтетических данных:

1. **Риск нереалистичности.** Основным недостатком синтетических данных является риск того, что они не будут в полной мере отражать сложность реального мира. Даже самые продвинутые алгоритмы генерации не могут учесть все нюансы и взаимосвязи, присутствующие в реальных данных. Это может привести к созданию моделей, которые хорошо работают на синтетических данных, но дают плохие результаты при применении к реальным ситуациям. Здесь в полной мере работает принцип "мусор на входе – мусор на выходе": ошибки в алгоритмах генерации неизбежно аукнутся проблемами с качеством обученных моделей.
2. **Унаследованные смещения.** Синтетические данные часто создаются на основе реальных данных или с использованием моделей, обученных на реальных данных. Это означает, что они могут унаследовать существующие смещения и предубеждения. Это особенно важно учитывать в социально значимых областях, таких как медицина или правосудие. Например, генерация текста на основе оскорбительных комментариев из интернета создаст «токсичную» синтетику.
3. **Этическая дилемма.** С синтетическими данными связан целый ряд этических вопросов. Например, генерация синтетических изображений лиц может использоваться как для обучения алгоритмов компьютерного зрения, так и для создания дипфейков. Возникает и вопрос доверия: можно ли полагаться на данные, созданные другой моделью? Не получится ли так, что модель будет обучаться на низкокачественных или спорных генерациях другой модели?

Никто не станет утверждать, что синтетические данные могут полностью заменить реальные — они остаются лишь инструментом для оптимизации и дополнения традиционных подходов. Наилучшие результаты достигаются при комбинировании синтетики с реальными данными.

Инструменты Python для генерации синтетических данных

1. Faker: универсальный генератор данных для разработки и тестирования



[Faker](#) — это библиотека Python, которая помогает генерировать правдоподобные, но вымышленные данные: имена, адреса, номера телефонов, email-адреса и многое другое. Например, тестирование веб-приложений, заполнение баз данных или подготовка данных для машинного обучения. Это идеальный инструмент для тех, кто хочет быстро сгенерировать выглядящие как настоящие и не нарушающие конфиденциальность данные, без глубокого погружения в статистику.

2. Scikit-learn: генерация синтетических данных для машинного обучения



[Scikit-learn](#) — это, в первую очередь, библиотека для машинного обучения, но в ней есть и полезные функции для генерации синтетических данных. Это не специализированная библиотека для синтетики (как Faker), но если необходимо быстро сгенерировать

синтетический датасет для классификации, регрессии или кластеризации, с полным контролем над его свойствами, Scikit-learn поможет это сделать.

Scikit-learn предлагает разнообразные функций для генерации данных, вот некоторые часто используемые:

- `make_classification`. Создает набор данных для задач классификации. Можно настроить количество информативных и избыточных признаков, уровень шума и дисбаланс классов. Это удобно для тестирования алгоритмов в условиях имитации реальных распределений классов.
- `make_regression`. Генерирует данные для задач регрессии. Здесь тоже полный контроль над зависимостями между признаками и целевой переменной, плюс возможность добавить случайный шум.
- `make_blobs`. Генерирует наборы для задач кластеризации в виде "пятен" (blobs), которые визуально хорошо разделяются и удобны для тестирования алгоритмов и визуализации результатов.
- `make_circles` и `make_moons`. Эти функции создают данные с нелинейными разделяющими границами, что позволяет протестировать алгоритмы, способные уловить более сложные зависимости.
- Наборы данных из `sklearn.datasets` (например, `load_iris`, `load_diabetes`): Хотя это и реальные наборы данных, их можно использовать как шаблоны или основу для создания синтетических вариаций. Например, можно изменить распределения признаков, добавить шум, перемешать данные, чтобы получить новые, контролируемые наборы данных.

3. Synthetic Data Vault: генерация сложных синтетических данных

SDV

The Synthetic Data Vault



Synthetic Data Vault (SDV) — это фреймворк, предназначенный для создания синтетических данных, которые не просто выглядят правдоподобно, а сохраняют статистические свойства и взаимосвязи реальных данных. SDV обучается на ваших данных и создает синтетические наборы, отражающие корреляции, распределения и структуру исходной информации. При этом инструмент позволяет генерировать не только отдельные столбцы данных, но и целые таблицы, связанные между собой отношениями, временные ряды и даже графовые данные.

Дополнительная информация: Олег Булыгин. Игра в имитацию: используем Python для генерации синтетических данных для ML и не только. <https://habr.com/ru/articles/888830/>

Ход работы

Генерация синтетических данных с использованием библиотеки Faker

Задача 1. Оценка риска компаний.

1.1 Сгенерировать датасет, содержащий список компаний. Число компаний – 50. Каждая компания описывается следующими полями:

1. 'name' – имя компании;
2. 'location' – город или населенный пункт;
3. 'years_in_business' – число лет в бизнесе;

4. 'revenue' - выручка (доход) в рублях;
5. 'employees' – число сотрудников;
6. 'has_online_store' - наличие интернет-магазина (True, False),
7. 'has_physical_store' - наличие магазина (True, False),
8. 'supply_chain_issues' – проблемы с поставками ('Нет', 'Редко', 'Часто'),
9. 'legal_issues' – юридические проблемы (0 - нет, 1-2 есть, 0 должен встречаться чаще),
10. 'customer_complaints' - жалобы клиентов, количество жалоб random.randint(0, 20),
11. 'financial_stability' – финансовая стабильность ('Высокая', 'Средняя', 'Низкая').

Генерацию синтетических данных реализовать в виде отдельной функции, для генерации использовать функции *fake.company()* и *fake.city()* библиотеки **Faker** и функции случайной генерации *random.choice()* и *random.randint()* библиотеки **random**. Перед генерацией настроить библиотеку **Faker** на работу с русским языком командой: `fake = Faker('ru_RU')`

- 1.2. Разработать правила оценки риска и реализовать функцию расчета риска. Максимальный риск не должен превышать 100 баллов. Пример функции приведен на рисунке 1.

```
def calculate_risk_score(self, company):  
    """Расчет оценки риска для компании"""  
    score = 0  
  
    # Оценка на основе лет в бизнесе  
    if company['years_in_business'] < 3:  
        score += 30  
    elif company['years_in_business'] < 10:  
        score += 15  
  
    # Оценка финансовой стабильности  
    if company['financial_stability'] == 'Низкая':  
        score += 40  
    elif company['financial_stability'] == 'Средняя':  
        score += 20  
  
    # Проблемы с поставками  
    if company['supply_chain_issues'] == 'Часто':  
        score += 25  
    elif company['supply_chain_issues'] == 'Редко':  
        score += 10  
  
    # Юридические проблемы  
    score += company['legal_issues'] * 15  
  
    # Жалобы клиентов  
    score += min(company['customer_complaints'], 20) # макс 20 баллов  
  
    # Наличие онлайн-магазина снижает риск  
    if company['has_online_store']:  
        score -= 10  
  
    # Ограничение оценки от 0 до 100  
    return max(0, min(100, score))
```

Рисунок 1 – Функция расчета оценки риска

- 1.3. Разработать правила категоризации риска по уровням (высокий, низкий, умеренный) и реализовать функцию категоризации риска. Пример функции приведен на рисунке 2.

```
def categorize_risk(self, score):
    """Категоризация риска по баллам"""
    if score < 20:
        return 'Низкий риск'
    elif score < 50:
        return 'Умеренный риск'
    elif score < 75:
        return 'Высокий риск'
    else:
        return 'Критический риск'
```

Рисунок 2 – Функция категоризации риска

1.4. Разработать функцию – анализатор риска компаний, реализующую следующие действия:

- формирование итогового датасета, содержащего следующие поля:
 'Компания', 'Город', 'Лет в бизнесе', : company['years_in_business'],
 'Выручка (млн руб)', 'Финансовая стабильность', 'Балл риска', 'Категория риска',
 'Проблемы с поставками', 'Юридические проблемы',
 'Жалобы клиентов'
- вызов функций расчета риска и расчета категорий риска.

Итоговый датасет должен выглядеть следующим образом (Рисунок 3):

[2]: # Смотрим на данные в виде датасета
risk_df

	Компания	Город	Лет в бизнесе	Выручка (млн руб)	Финансовая стабильность	Балл риска	Категория риска	Проблемы с поставками	Юридические проблемы	Жалобы клиентов
0	ЗАО «Белякова-Горбачев» Промышленность	ст. Якутск	24	168.0	Средняя	29	Умеренный риск	Нет	0	19
1	Fonbet Промышленность	д. Красноуфимск	29	465.0	Высокая	10	Низкий риск	Редко	0	10
2	ООО «Козлова» Промышленность	д. Кострома	15	252.0	Средняя	69	Высокий риск	Нет	2	19
3	Игнатьев и партнеры Промышленность	к. Сухиничи	44	268.0	Средняя	63	Высокий риск	Редко	1	18
4	АО «Алексеев Федоров» _	с. Яшкуль	20	37.0	Низкая	30	Умеренный	Нет	0	0

Рисунок 3 – Итоговый датасет

1.5. Разработать функцию подсчета статистики по уровням риска. Вывод функции должен выглядеть следующим образом (Рисунок 4):

```
Общая статистика по рискам:
Категория риска  count
0    Умеренный риск    23
1    Высокий риск     18
2    Критический риск    6
3    Низкий риск        3
```

Рисунок 4 – Общая статистка по рискам

1.6. Разработать функцию выборки списка компаний с высоким и критическим риском. Вывод функции должен выглядеть следующим образом (Рисунок 5):

Компании с высоким уровнем риска:

	Компания	Город \
0	ЗАО «Костина» Строительство	п. Палана
4	НПО «Белоусова, Емельянова и Красильникова» Эн...	д. Владивосток
10	Белуга Групп Транспорт	г. Ачхой Мартан
12	ОАО «Ершова-Ширяева» Сельское хозяйство	с. Шуя
13	Соколов Лтд Сельское хозяйство	с. Нижний Новгород
16	ИП «Гришина» Сельское хозяйство	клх Уэлен
17	Павлова Лимитед Транспорт	с. Уренгой
21	ИП «Журавлев, Фомина и Воробьева» Энергетика	с. Кежма
22	ОАО «Сергеева, Панов и Морозов» Промышленность	клх Эльтон
23	ЗАО «Миронова Беляева» Строительство	клх Горячий Ключ
24	ООО «Данилов Исакова» Энергетика	п. Красновишерск
26	ФосАгро Строительство	с. Сочи
29	ЗАО «Ларионов Родионова» Промышленность	к. Белый Яр (Томск.)
30	РАО «Большакова» Строительство	с. Тверь
35	ООО «Лебедев» Энергетика	к. Горячий Ключ
42	ИП «Горбачева-Николаева» Строительство	г. Самара
43	ООО «Зайцева» Строительство	ст. Печора
44	Техинком Транспорт	п. Ялуторовск
45	ДОМ.РФ Строительство	п. Адлер
48	ОАО «Стрелков-Носкова» Транспорт	клх Тарко-Сале
49	РАО «Крылова, Дорофеева и Копылов» Промышленность	г. Одинцово

	Категория риска	Балл риска
0	Высокий риск	54
4	Высокий риск	63
10	Высокий риск	66
12	Высокий риск	73
13	Высокий риск	66
16	Высокий риск	54
17	Высокий риск	51
21	Высокий риск	70
22	Критический риск	87
23	Высокий риск	53
24	Высокий риск	63
26	Высокий риск	57
29	Высокий риск	73
30	Высокий риск	60
35	Высокий риск	63
42	Высокий риск	71
43	Критический риск	83
44	Критический риск	100
45	Критический риск	86
48	Высокий риск	50
49	Высокий риск	56

Рисунок 5 – Список компаний с высоким и критическим риском

1.7. Разработать основной модуль программы, реализующий вызов следующих функций:

1. Генерация данных о компаниях;
2. Расчет и анализ показателей риска и формирование итогового датасета;
3. Расчет и вывод общей статистики по рискам;
4. Вывод списка компаний с высоким и критическим риском;
5. Сохранение итогового датасета в файл 'Компании_риски.xlsx'.

Задача 2. Генерация профиля пользователя интернет-магазина.

2.1 Сгенерировать датасет, содержащий список профилей пользователей компаний. Число пользователей – 100. Каждый пользователь описывается следующими полями:

1. "id": идентификатор;
2. "name": имя (ФИО);
3. "email": адрес электронной почты;
4. "phone": телефон;
5. "address": почтовый адрес;
6. "payment_method": метод оплаты (тип кредитной карты);

7. "order_history": история заказов – список из случайного количества заказов, содержащий следующие поля:

order_id – идентификатор заказа вида "1b5fcc47-096f-43d4-80ab-d9b07fba7e56"
date – дата заказа в формате "ГГГГ-ММ-ДД", например "2025-07-22"
total – сумма заказа, например 5511

Для генерации использовать следующие функции библиотеки **Faker**: `fake.uuid4()`, `fake.name()`, `fake.email()`, `fake.phone_number()`, `fake.address()`, `fake.credit_card_provider()`, `fake.date_between()`, `fake.random_int()`.

Перед генерацией настроить библиотеку на работу с русским языком командой: `fake = Faker('ru_RU')`.

Датасет необходимо сгенерировать и сохранить в формате Json, а также преобразовать в формат pandas DataFrame (Рисунок 6):

```
# Генерируем 100 профилей пользователей
user_profiles = [generate_user_profile() for _ in range(100)]

# Преобразуем данные в DataFrame
df = pd.json_normalize(user_profiles, sep='_')

# Сохраняем в JSON
with open('user_profiles.json', 'w', encoding='utf-8') as f:
    json.dump(user_profiles, f, indent=4, ensure_ascii=False)
```

Рисунок 6 – Команды преобразования и сохранения датасета

Итоговый датасет должен выглядеть следующим образом (Рисунки 7, 8):

	id	name	email	phone	address	payment_method	order_history
0	75afb66-50a5-4847-9bc4-f8940fa451e4	Аристарх Федотович Тихонов	iosiffomin@example.net	+7 (910) 432-00-23	п. Северобайкальск, ш. Ручейное, д. 67, 218919	МИР	[{"order_id": "2942eff5-36d5-4867-958d-a8f078e...", "date": "2025-07-22", "total": 5511}]
1	bc037881-0ebb-41d7-9d10-f8c9d7706eb2	Азарий Власович Цветков	pahomovradovan@example.com	+72268284525	г. Салехард, бул. Попова, д. 641 к. 1, 315413	American Express	[]
2	a376e3a1-57b9-4087-9788-7a982234f642	Большакова Валентина Егоровна	provdrozdov@example.org	+7 665 804 46 91	п. Александровск-Сахалинский, ш. Тупиковое, д.	American Express	[{"order_id": "1b5fcc47-096f-43d4-80ab-d9b07fb...", "date": "2025-07-22", "total": 5511}]
3	9e011db5-8ec9-4a4e-9f70-a49f3bd503c3	Силина Елизавета Константиновна	stanislavmuravev@example.net	8 146 805 1070	с. Куртамыш, наб. Бульварная, д. 8 к. 826, 677438	Maestro	[{"order_id": "2c3ad8c9-aa8e-4c34-a3ab-e962807...", "date": "2025-07-22", "total": 5511}]
4	b1b59c6f-27f0-48d6-90bf-9c982a53ac09	Зуева Фаина Дмитриевна	kira61@example.com	85626126490	ст. Шереш, пер. Промышленный, д. 3/1 стр. 6/...	Union Pay	[{"order_id": "5e177f87-fd0d-46a7-85f2-a63819a...", "date": "2025-07-22", "total": 5511}]

Рисунок 7 – Список профилей пользователей интернет – магазина.



Рисунок 8 – Список профилей в формате json

Содержание отчета

1. Цель работы. 2. Краткие теоретические сведения. 3. Ход работы со скриншотами. 4. Выводы.

Контрольные вопросы

1. Определение синтетических данных.
2. В каких задачах используются синтетические данные?
3. Достоинства и недостатки синтетических данных.
4. Библиотека Faker. Области применения. Основные функции.
5. Библиотека Sklearn. Генерация данных для анализа алгоритмов машинного обучения.
6. Библиотека SDV. Генерация сложных синтетических данных.

Список источников

1. Олег Булыгин. Игра в имитацию: используем Python для генерации синтетических данных для ML и не только. <https://habr.com/ru/articles/888830/>
2. Антон Жеронкин. Генератор синтетических данных на Python с использованием байесовских сетей. <https://newtechaudit.ru/generator-s-bajesovskimi-setyami/>
3. Насурллаев Илья. Выявление неявных связей при анализе графов или как увидеть незримое. Определение телефонного мошенничества с использованием синтетических данных с визуализацией на графах. <https://newtechaudit.ru/vyyavlenie-neyavnyh-svyazej-pri-analize-grafov-ili-kak-uvidet-nezrimoe/>

2. ЛАБОРАТОРНАЯ РАБОТА 2. ПРЕДВАРИТЕЛЬНЫЙ АНАЛИЗ И ВИЗУАЛИЗАЦИЯ ДАННЫХ.

Цель работы: Приобрести практические навыки проведения предварительного анализа и визуализации исходных наборов данных.

Краткие теоретические сведения.

Одним из важнейших этапов любого проекта по анализу данных является предварительная обработка данных (*Data Preprocessing*). Как известно, качество анализа напрямую зависит от качества данных. Даже самые современные модели машинного обучения не смогут показать хорошие результаты, если исходные данные содержат ошибки, пропуски или нерелевантные признаки. По оценкам специалистов, до 70–80% времени работы аналитика уходит на подготовку и очистку данных, и лишь 20–30% — на построение моделей и интерпретацию результатов. Именно поэтому предварительная обработка рассматривается как ключевой элемент процесса интеллектуального анализа данных (*Data Mining*) и применения алгоритмов машинного обучения.

Цель и значение предварительной обработки. Основная цель предварительной обработки — подготовить данные к анализу и моделированию, обеспечив их достоверность, согласованность и пригодность для алгоритмов. Хорошо подготовленные данные повышают точность моделей, сокращают время обучения и делают результаты интерпретируемыми.

Основные задачи предварительной обработки:

1. Удаление ошибок, дубликатов и шумов;
2. Обработка пропущенных значений;
3. Приведение данных к единой шкале (нормализация);
4. Кодирование категориальных признаков;
5. Удаление нерелевантных и избыточных признаков;
6. Снижение размерности данных для ускорения анализа.

Этапы предварительной обработки данных.

Процесс включает несколько последовательных шагов:

1. Очистка данных (*Data Cleaning*)
2. Преобразование данных (*Data Transformation*)
3. Интеграция данных (*Data Integration*)
4. Сокращение данных (*Data Reduction*)

Очистка данных (*Data Cleaning*)

Очистка данных — это процесс выявления и устранения ошибок, пропусков, дубликатов и несоответствий в данных. Главная цель очистки — сделать данные достоверными и согласованными.

Основные типы проблем в данных:

- Пропущенные значения (*missing values*);
- Неверные или противоречивые данные;
- Дублирование записей;
- Шум (ошибочные или случайные значения);
- Разнородные форматы (например, дата в разных форматах).

Методы очистки:

- удаление дубликатов;
- корректировка ошибочных значений;
- фильтрация выбросов (outliers);
- проверка диапазонов и логических условий;
- консолидация данных из разных источников.

Пример:

Если в наборе данных о клиентах встречаются записи с возрастом 300 лет, такие значения необходимо исправить или удалить как очевидную ошибку.

2. Обработка пропусков в данных

Пропуски (missing values) — частое явление в реальных данных. Они могут возникать из-за ошибок сбора данных, технических сбоев и других причин. Неправильная работа с пропусками может привести к искажению результатов анализа.

Способы обработки пропусков:

Удаление записей с пропусками — подходит, если доля пропусков мала (менее 5%).

Заполнение средними значениями (Mean/Median/Mode Imputation) — числовые признаки можно заменить средним или медианой, категориальные — модой.

Интерполяция или прогнозирование пропусков — заполнение с помощью статистических моделей или моделей машинного обучения.

Использование специальных категорий ("unknown") — применяется для категориальных признаков.

Пример:

Если в данных о доходе клиента есть пропуск, можно заменить его на средний доход группы клиентов с аналогичными характеристиками.

3. Нормализация данных.

Нормализация (или стандартизация) — это процесс приведения числовых признаков к единому масштабу, чтобы все признаки вносили одинаковый вклад в обучение модели. Без нормализации признаки с большими числовыми диапазонами могут «доминировать» над другими и искажать результаты анализа.

Основные методы нормализации:

1. Min-Max нормализация: Преобразует данные в диапазон $[0, 1]$.
2. Z-нормализация (стандартизация): Приведение данных к нулевому среднему и единичному стандартному отклонению.
3. Нормализация по вектору (L2-норма): Используется в текстовом и пространственном анализе.

Пример:

Если один признак измеряется в тысячах, а другой — в единицах, модель может «предпочесть» первый. Нормализация решает эту проблему.

4. Дискретизация данных. Дискретизация — процесс преобразования непрерывных данных в категориальные (дискретные) интервалы. Это полезно для упрощения анализа и повышения интерпретируемости моделей.

Методы дискретизации:

Равные интервалы (Equal-width): диапазон значений делится на равные отрезки.

Равная частота (Equal-frequency): в каждый интервал попадает одинаковое количество элементов.

Методы на основе кластеризации: интервалы формируются по естественным кластерам данных.

Эвристические методы: определение границ на основе доменной логики (правил предметной области).

Пример:

Возраст (непрерывный признак) можно дискретизировать как:

- 18–25 лет → «молодые»
- 26–40 лет → «взрослые»
- 41–65 лет → «зрелые»
- 65+ → «пожилые»

5. Отбор признаков (Feature Selection)

Отбор признаков — это процесс выбора наиболее информативных переменных, которые действительно влияют на результат.

Он помогает:

- снизить размерность данных;
- повысить точность модели;
- ускорить обучение;
- улучшить интерпретацию результатов.

Основные методы отбора признаков:

1. Фильтрационные методы (Filter methods): анализ статистических характеристик признаков (корреляция, χ^2 -тест, ANOVA).
2. Методы обёртки (Wrapper methods): пошаговый перебор признаков с использованием модели (например, RFE — Recursive Feature Elimination).
3. Встроенные методы (Embedded methods): встроены в алгоритмы (например, Lasso, Random Forest Feature Importance).

Пример:

Если модель прогнозирует успех маркетинговой кампании, признаки «возраст» и «доход» могут быть важны, а «номер клиента» — нет и должен быть исключён.

Инструменты и библиотеки для предварительной обработки

Современные инструменты и библиотеки позволяют автоматизировать многие этапы предварительной обработки данных:

Pandas: библиотека для работы с наборами данных (**DataFrame**), очистки данных, заполнения пропусков, удаления дубликатов и фильтрации данных.

Scikit-Learn: библиотека для машинного обучения. Включает инструменты для предобработки данных, которые используются для заполнения пропусков, масштабирования признаков и работы с выбросами.

SimpleImputer для заполнения пропусков,

StandardScaler для масштабирования,

LabelEncoder для кодирования категориальных данных.

Matplotlib и **Seaborn:** библиотеки для визуализации данных, используемые для анализа, в том числе обнаружения выбросов и шумов.

Numpy: библиотека для быстрой и эффективной работы с числовыми массивами, включая сложные математические преобразования.

Feature-engine: создание новых признаков, кодирование категорий и работа с выбросами.

Polars: альтернатива Pandas для работы с очень большими объемами данных.

Пример (Python):

```
from sklearn.preprocessing import StandardScaler
scaler = StandardScaler()
X_scaled = scaler.fit_transform(X)
```

Больше информации об использовании библиотек и примеры кода:

Что такое предварительная обработка данных в машинном обучении и как ее провести

<https://blog.skillfactory.ru/predvaritelnaya-obrabotka-dannyh-v-mashinnom-obuchenii/>

Задание на лабораторную работу:

Необходимо выполнить следующие действия:

1. Выбрать набор данных согласно варианту задания.
2. Провести предварительную обработку данных, включающую следующие операции:
 - Загрузка набора данных
 - Просмотр набора данных
 - Получение информации о типах признаков и наличии пропусков
 - Статистическое описание числовых признаков
 - Обработка пропусков
 - Обработка дубликатов
 - Обнаружение выбросов
 - Кодирование категориальных признаков
3. Составить отчет по работе, сделать выводы.

Содержание отчета:

1. Цель работы.
2. Краткие теоретические сведения.
3. Ход работы со скриншотами.
4. Выводы.

Пример решения задачи предварительной обработки данных для простого набора данных о недвижимости приведен ниже:

```
import pandas as pd

# Создание DataFrame с данными о недвижимости

data = {
    'ID': [1, 2, 3, 4, 5, 6, 7, 8, 9, 10],
    'Площадь (кв. м)': [80, 100, 2000, None, 150, 500, 120, 80, -150, 100],
    'Число комнат': [3, None, 2, 4, 3, 5, 3, 3, 3, 3],
    'Возраст дома (лет)': [20, 150, None, 30, 5, 300, 25, -5, 15, 25],
    'Цена (млн руб.)': [8, 10, 50, 6, None, 70, 14, 8, 12, 14],
    'Тип недвижимости': ['квартира', 'дом', 'квартира', 'апартаменты', 'дом', 'квартира',
    'Район': ['А', 'Б', 'А', 'В', 'Б', 'А', 'Б', 'В', 'Б', 'А']]
}

df = pd.DataFrame(data)
```

```
# Просмотр первых строк таблицы
```

```
df.head(10)
```

	ID	Площадь (кв. м)	Число комнат	Возраст дома (лет)	Цена (млн руб.)	Тип недвижимости	Район
0	1	80.0	3.0	20.0	8.0	квартира	А
1	2	100.0	NaN	150.0	10.0	дом	Б
2	3	2000.0	2.0	NaN	50.0	квартира	А
3	4	NaN	4.0	30.0	6.0	апартаменты	В
4	5	150.0	3.0	5.0	NaN	дом	Б
5	6	500.0	5.0	300.0	70.0	квартира	А
6	7	120.0	3.0	25.0	14.0	дом	Б
7	8	80.0	3.0	-5.0	8.0	апартаменты	В
8	9	-150.0	3.0	15.0	12.0	дом	Б
9	10	100.0	3.0	25.0	14.0	квартира	А

```
# Получение информации о типах данных и наличии пропусков
```

```
df.info()
```

```
<class 'pandas.core.frame.DataFrame'>
```

```
RangeIndex: 10 entries, 0 to 9
```

```
Data columns (total 7 columns):
```

#	Column	Non-Null Count	Dtype
---	-----	-----	-----
0	ID	10 non-null	int64
1	Площадь (кв. м)	9 non-null	float64
2	Число комнат	9 non-null	float64
3	Возраст дома (лет)	9 non-null	float64
4	Цена (млн руб.)	9 non-null	float64
5	Тип недвижимости	10 non-null	object
6	Район	10 non-null	object

```
dtypes: float64(4), int64(1), object(2)
```

```
memory usage: 688.0+ bytes
```

```
# Проверка на наличие дубликатов
```

```
duplicates_count = df.duplicated().sum()
```

```
print(f"\nКоличество дубликатов: {duplicates_count}")
```

```
Количество дубликатов: 0
```

```
# Статистическое описание числовых признаков
df.describe()
```

	ID	Площадь (кв. м)	Число комнат	Возраст дома (лет)	Цена (млн руб.)
count	10.00000	9.000000	9.000000	9.000000	9.000000
mean	5.50000	331.111111	3.222222	62.777778	21.333333
std	3.02765	647.638874	0.833333	99.909681	22.649503
min	1.00000	-150.000000	2.000000	-5.000000	6.000000
25%	3.25000	80.000000	3.000000	15.000000	8.000000
50%	5.50000	100.000000	3.000000	25.000000	12.000000
75%	7.75000	150.000000	3.000000	30.000000	14.000000
max	10.00000	2000.000000	5.000000	300.000000	70.000000

```
import numpy as np

# Удаление дубликатов
df = df.drop_duplicates()

# Удаление строк с некорректным значением возраста дома
df = df[df['Возраст дома (лет)'] >= 0]

# Замена ошибочных значений на NaN для последующей обработки
df.loc[df['Площадь (кв. м)'] < 0, 'Площадь (кв. м)'] = np.nan
```

df

	ID	Площадь (кв. м)	Число комнат	Возраст дома (лет)	Цена (млн руб.)	Тип недвижимости	Район
0	1	80.0	3.0	20.0	8.0	квартира	А
1	2	100.0	NaN	150.0	10.0	дом	Б
3	4	NaN	4.0	30.0	6.0	апартаменты	В
4	5	150.0	3.0	5.0	NaN	дом	Б
5	6	500.0	5.0	300.0	70.0	квартира	А
6	7	120.0	3.0	25.0	14.0	дом	Б
8	9	NaN	3.0	15.0	12.0	дом	Б
9	10	100.0	3.0	25.0	14.0	квартира	А

```
: from sklearn.impute import SimpleImputer

# Использование SimpleImputer для заполнения пропусков
imputer = SimpleImputer(strategy='mean')
df[['Площадь (кв. м)', 'Число комнат', 'Возраст дома (лет)']] = imputer.fit_transform(df[['Площадь (кв. м)', 'Число комнат',
```



```
# Заполнение пропусков средним значением

df['Площадь (кв. м)'] = df['Площадь (кв. м)'].fillna(df['Площадь (кв. м)'].mean())

from sklearn.preprocessing import LabelEncoder

# Кодирование категориального признака

encoder = LabelEncoder()

df['Тип недвижимости'] = encoder.fit_transform(df['Тип недвижимости'])

df
```

	ID	Площадь (кв. м)	Число комнат	Возраст дома (лет)	Цена (млн руб.)	Тип недвижимости	Район
0	1	80.0	3.0	20.0	8.0	2	А
1	2	100.0	3.0	150.0	10.0	1	Б
3	4	110.0	4.0	30.0	6.0	0	В
4	5	150.0	3.0	5.0	9.0	1	Б
5	6	500.0	5.0	300.0	70.0	2	А
6	7	120.0	3.0	25.0	14.0	1	Б

```
import matplotlib.pyplot as plt

import seaborn as sns


# Визуализация выбросов с помощью boxplot

plt.figure(figsize=(8, 5))

sns.boxplot(x=df['Цена (млн руб.)'])

plt.title('Выбросы в цене квартир')

plt.show()
```



```

# Определение границ для выбросов

Q1 = df['Цена (млн руб.)'].quantile(0.25)

Q3 = df['Цена (млн руб.)'].quantile(0.75)

IQR = Q3 - Q1

lower_bound = Q1 - 1.5 * IQR

upper_bound = Q3 + 1.5 * IQR

# Обнаружение выбросов

outliers = df[(df['Цена (млн руб.)'] < lower_bound) | (df['Цена (млн руб.)'] > upper_bound)]

print(f"Количество выбросов: {len(outliers)}")

print("Найдены выбросы:\n")
outliers

```

Количество выбросов: 2
Найдены выбросы:

	ID	Площадь (кв. м)	Число комнат	Возраст дома (лет)	Цена (млн руб.)	Тип недвижимости	Район
2	3	2000.0	2.0	NaN	50.0	квартира	А
5	6	500.0	5.0	300.0	70.0	квартира	А

Контрольные вопросы

1. Какая библиотека python предназначена для управления наборами данных: numpy, pandas, sklearn, opencv, matplotlib?
2. Какая стратегия является нежелательной при обработке пропусков в данных?
 - а) замена пропущенных значений в столбце медианным значением по данному столбцу;
 - б) удаление строк, содержащих пропуски в данных;
 - в) замена пропущенных значений в столбце средним арифметическим значением по данному столбцу;
3. г) замена пропущенных значений в столбце наиболее часто встречающимся значением по данному столбцу;
4. Обоснуйте ответ на следующую проблему предварительной обработки данных: имеется независимая категориальная переменная у, которая представляет собой категориальный признак, опеределенный на домене {C#, Java, Python, R}. Нужно ли применять к данному целевому признаку OneHotEncoder?
5. С помощью какой диаграммы можно визуализировать выбросы?
6. Перечислите методы кодирования категориальных признаков.

3. ЛАБОРАТОРНАЯ РАБОТА 3. МЕТОДЫ РЕГРЕССИИ.

Цель работы: научиться строить модели регрессии с использованием библиотек машинного обучения языка Python.

Краткие теоретические сведения.

Регрессия – это метод анализа данных, который позволяет исследовать связь между зависимой переменной и одной или несколькими независимыми переменными. Он используется для прогнозирования и предсказания значений зависимой переменной на основе известных значений независимых переменных.

Регрессионный анализ позволяет определить, какие независимые переменные оказывают значимое влияние на зависимую переменную и как сильно это влияние. Он также позволяет оценить силу и направление этого влияния. Регрессионный анализ может быть применен в различных областях, таких как экономика, финансы, маркетинг, социология и многие другие. Он может быть использован для прогнозирования будущих значений, выявления взаимосвязей между переменными, определения важности факторов и др.

Основные понятия регрессионного анализа:

Зависимая переменная, также известная как целевая переменная или переменная отклика, является переменной, которую мы пытаемся предсказать или объяснить. Она обозначается как Y .

Независимые переменные, также известные как *предикторы* или *факторы*, являются переменными, которые мы используем для предсказания или объяснения зависимой переменной. Они обозначаются как X_1 , X_2 , X_3 и так далее.

Регрессионная модель – это математическое представление, которое описывает отношение между зависимой переменной и независимыми переменными. Она может быть представлена в виде уравнения, которое позволяет нам предсказывать значения зависимой переменной на основе значений независимых переменных.

Коэффициенты регрессии – это числа, которые умножаются на значения независимых переменных в регрессионной модели. Они показывают, как сильно и в каком направлении влияют независимые переменные на зависимую переменную. Коэффициенты регрессии обозначаются как β_0 , β_1 , β_2 и так далее.

Множественная регрессия – это тип регрессионного анализа, в котором есть несколько независимых переменных, влияющих на зависимую переменную. В этом случае регрессионная модель будет содержать несколько коэффициентов регрессии.

Коэффициент детерминации, обозначаемый как R^2 , является мерой объясненной вариации зависимой переменной моделью. Он показывает, насколько хорошо модель соответствует данным и объясняет изменчивость зависимой переменной. Значение R^2 может быть от 0 до 1, где 0 означает, что модель не объясняет вариацию, а 1 означает, что модель полностью объясняет вариацию.

Стандартная ошибка – это мера неопределенности или разброса коэффициентов регрессии. Она показывает, насколько точно коэффициенты регрессии оценивают влияние

независимых переменных на зависимую переменную. Чем меньше стандартная ошибка, тем более точные оценки коэффициентов регрессии.

Методы регрессионного анализа

Регрессионный анализ – это статистический метод, который используется для изучения взаимосвязи между зависимой переменной (такой как цена на недвижимость) и одной или несколькими независимыми переменными (такими как размер жилья, количество комнат и т.д.). В регрессионном анализе строится математическая модель, которая описывает эту взаимосвязь и позволяет делать прогнозы.

Простая линейная регрессия – это метод, который используется, когда есть только одна независимая переменная. Модель простой линейной регрессии имеет вид:

$$y = \beta_0 + \beta_1 x + \varepsilon$$

где y – зависимая переменная, x – независимая переменная, β_0 и β_1 – коэффициенты регрессии, ε – ошибка.

Цель простой линейной регрессии – найти наилучшие значения коэффициентов β_0 и β_1 , чтобы минимизировать сумму квадратов ошибок ε .

Множественная линейная регрессия – это метод, который используется, когда есть несколько независимых переменных. Модель множественной линейной регрессии имеет вид:

$$y = \beta_0 + \beta_1 x_1 + \beta_2 x_2 + \dots + \beta_p x_p + \varepsilon$$

где y – зависимая переменная, $x_1, x_2, \dots, x_p$ – независимые переменные, $\beta_0, \beta_1, \beta_2, \dots, \beta_p$ – коэффициенты регрессии, ε – ошибка.

Цель множественной линейной регрессии – найти наилучшие значения коэффициентов $\beta_0, \beta_1, \beta_2, \dots, \beta_p$, чтобы минимизировать сумму квадратов ошибок ε .

Полиномиальная регрессия – это метод, который используется, когда зависимость между переменными не является линейной, а имеет криволинейную форму. В полиномиальной регрессии используются степенные функции независимых переменных.

Модель полиномиальной регрессии имеет вид:

$$y = \beta_0 + \beta_1 x + \beta_2 x^2 + \dots + \beta_p x^p + \varepsilon$$

где y – зависимая переменная, x – независимая переменная, $\beta_0, \beta_1, \beta_2, \dots, \beta_p$ – коэффициенты регрессии, ε – ошибка.

Цель полиномиальной регрессии – найти наилучшие значения коэффициентов $\beta_0, \beta_1, \beta_2, \dots, \beta_p$, чтобы минимизировать сумму квадратов ошибок ε .

Логистическая регрессия – это метод, который используется, когда зависимая переменная является категориальной (бинарной или многокатегориальной). Логистическая регрессия использует логистическую функцию для предсказания вероятности принадлежности к определенной категории.

Модель логистической регрессии имеет вид:

$$p = 1 / (1 + \exp(-(\beta_0 + \beta_1 x_1 + \beta_2 x_2 + \dots + \beta_p x_p)))$$

где p – вероятность принадлежности к определенной категории, $x_1, x_2, \dots, x_p$ – независимые переменные, $\beta_0, \beta_1, \beta_2, \dots, \beta_p$ – коэффициенты регрессии.

Цель логистической регрессии – найти наилучшие значения коэффициентов $\beta_0, \beta_1, \beta_2, \dots, \beta_p$, чтобы максимизировать вероятность принадлежности к правильной категории.

Это лишь некоторые методы регрессионного анализа. В зависимости от задачи и данных, можно использовать и другие методы, такие как регрессия с использованием деревьев решений, регрессия с использованием искусственных нейронных сетей и т.д.

Построение регрессионной модели

Построение регрессионной модели – это процесс нахождения математической функции, которая наилучшим образом описывает связь между зависимой переменной и одной или несколькими независимыми переменными.

Выбор независимых переменных. Первым шагом в построении регрессионной модели является выбор независимых переменных, которые могут влиять на зависимую переменную. Это может быть основано на предварительном анализе данных, экспертном мнении или теоретических предположениях.

Сбор данных. Для построения регрессионной модели необходимо собрать данные, которые содержат значения зависимой переменной и независимых переменных для каждого наблюдения. Данные могут быть получены из различных источников, таких как опросы, эксперименты или базы данных.

Предварительный анализ данных. Перед построением модели необходимо провести предварительный анализ данных, чтобы оценить их качество и проверить наличие выбросов, пропущенных значений или других аномалий. Также можно провести корреляционный анализ, чтобы определить связь между зависимой переменной и независимыми переменными.

Выбор функциональной формы модели

Следующим шагом является выбор функциональной формы модели, которая определяет, как зависимая переменная связана с независимыми переменными. Наиболее распространенной функциональной формой является линейная модель, где зависимая переменная представляется линейной комбинацией независимых переменных. Однако, в зависимости от данных и предметной области, можно использовать и другие функциональные формы, такие как полиномиальные, логарифмические или экспоненциальные модели.

Оценка параметров модели

После выбора функциональной формы модели, необходимо оценить значения коэффициентов, которые определяют вклад каждой независимой переменной в зависимую переменную. Для этого используется метод наименьших квадратов или другие методы оценки параметров.

Проверка значимости модели. После оценки параметров модели, необходимо проверить ее значимость и адекватность. Для этого используются различные статистические тесты, такие как t-тесты, F-тесты или коэффициент детерминации.

Интерпретация результатов. Последний шаг в построении регрессионной модели – это интерпретация результатов. Это включает в себя анализ значимости и влияния каждой

независимой переменной на зависимую переменную, а также оценку точности и предсказательной способности модели.

Оценка качества модели. Оценка качества модели является важным шагом в регрессионном анализе. Она позволяет определить, насколько хорошо модель соответствует данным и насколько точно она может предсказывать значения зависимой переменной.

Сумма квадратов остатков (SSE). Одним из показателей качества модели является сумма квадратов остатков (SSE). Остатки – это разница между фактическими значениями зависимой переменной и предсказанными значениями, полученными с помощью модели. SSE представляет собой сумму квадратов всех остатков и показывает, насколько хорошо модель соответствует данным. Чем меньше значение SSE, тем лучше модель.

Среднеквадратическая ошибка (MSE) – это среднее значение квадратов остатков. Она вычисляется путем деления SSE на количество наблюдений. MSE также показывает, насколько хорошо модель соответствует данным, но в отличие от SSE, она учитывает размер выборки. Чем меньше значение MSE, тем лучше модель.

Коэффициент детерминации (R-квадрат) – это показатель, который показывает, насколько хорошо модель объясняет изменчивость зависимой переменной. Он принимает значения от 0 до 1, где 0 означает, что модель не объясняет никакой изменчивости, а 1 означает, что модель объясняет всю изменчивость. R-квадрат можно интерпретировать как процент изменчивости зависимой переменной, который объясняется моделью. Чем ближе значение R-квадрат к 1, тем лучше модель.


Другие показатели качества модели. Кроме вышеперечисленных показателей, существуют и другие показатели качества модели, такие как корень из среднеквадратической ошибки (RMSE), коэффициент детерминации скорректированный на количество независимых переменных (R-квадрат скорректированный) и другие. Все эти показатели помогают оценить качество модели и выбрать наиболее подходящую для конкретной задачи.

Интерпретация результатов регрессии

После построения регрессионной модели и получения результатов, необходимо проанализировать и интерпретировать эти результаты. Интерпретация результатов регрессии позволяет понять, какие факторы оказывают значимое влияние на зависимую переменную и какая форма зависимости между ними.

Коэффициенты корреляции

Коэффициент корреляции (чаще всего под ним подразумевают коэффициент Пирсона) — это число в диапазоне от -1 до 1 . Чем ближе коэффициент к 1 , тем сильнее положительная связь между двумя переменными. Коэффициент корреляции $= 1$ означает, что изменению одной переменной соответствует такое же изменение другой. Если коэффициент получается отрицательным, это означает обратную взаимосвязь: то есть при увеличении одной переменной, другая уменьшается. Близкая к нулю корреляция показывает, что статистически значимая взаимосвязь между двумя переменными отсутствует. Корреляция бывает:



Коэффициенты регрессии. Один из основных инструментов для интерпретации результатов регрессии – это коэффициенты регрессии. Каждый коэффициент соответствует одной независимой переменной и показывает, насколько изменится зависимая переменная при изменении соответствующей независимой переменной на одну единицу, при условии, что все остальные переменные остаются постоянными.

Например, если у нас есть регрессионная модель, которая предсказывает зарплату (зависимая переменная) на основе образования (независимая переменная), и коэффициент регрессии для образования равен 0.05, то это означает, что при увеличении образования на одну единицу (например, на один год обучения), зарплата увеличится в среднем на 0.05 единицы, при условии, что все остальные факторы остаются неизменными.

Статистическая значимость коэффициентов. Помимо значения коэффициентов регрессии, также важно оценить их статистическую значимость. Для этого используется t-статистика и соответствующие p-значения. Если p-значение меньше заданного уровня значимости (обычно 0.05), то можно считать, что коэффициент статистически значимо отличается от нуля, и его влияние на зависимую переменную является значимым.

Направление и сила влияния. Интерпретация результатов регрессии также позволяет определить направление и силу влияния независимых переменных на зависимую переменную. Если коэффициент регрессии положительный, то увеличение значения независимой переменной будет сопровождаться увеличением значения зависимой переменной. Если коэффициент регрессии отрицательный, то увеличение значения независимой переменной будет сопровождаться уменьшением значения зависимой переменной. Силу влияния можно оценить по значению коэффициента регрессии. Чем больше абсолютное значение коэффициента, тем сильнее влияние независимой переменной на зависимую переменную.

Задание на лабораторную работу:

Задача 1. Необходимо решить задачу регрессии - предсказания непрерывного значения признака - цены на недвижимость на основе набора данных об объектах недвижимости города Бостона (Boston Housing).

ОПИСАНИЕ НАБОРА ДАННЫХ

1. **CRIM** - Уровень преступности на душу населения в разбивке по районам
2. **ZN** - Доля земель под жилую застройку, разделенных на участки площадью более 25 000 кв. футов.
3. **INDUS** - Доля акров, не связанных с розничной торговлей, в промышленности на город

4. **CHAS** - Фиктивная переменная CHAS Charles River (= 1, если тракт граничит с рекой; 0 в противном случае)
5. **NOX** - Концентрация оксидов азота NOX (частей на 10 миллионов)
6. **RM** - Среднее количество комнат в жилом помещении
7. **AGE** - Доля занимаемых владельцами квартир, построенных до 1940 года
8. **DIS** - Взвешенные расстояния до пяти бостонских центров занятости
9. **RAD** - Индекс доступности радиальных магистралей RAD
10. **TAX** - Налог на недвижимость с полной стоимостью - ставка налога на 10 000 долларов США
11. **PTRATIO** - Соотношение учащихся и учителей по городам
12. **BLASK** - $1000(Bk - 0,63)^2$, где Bk - доля афроамериканцев в разбивке по городам
13. **LSTAT** - % более низкого статуса населения
14. **MEDV** - Медианная стоимость домов, занимаемых владельцами, в 1000 долларов
- **Целевая переменная**

Написать код для решения задачи регрессии:

1. Подключить необходимые библиотеки и провести загрузку набора данных (файл boston.csv)
2. Провести предварительный анализ и подготовку данных:
 - 2.1. Получение описательной статистики: количество наблюдений (count), среднее арифметическое (mean), среднее квадратическое отклонение (std), минимальное (min) и максимальное (max) значения, а также первый (25%), второй (50%) и третий (75%) квартиль каждой количественной переменной.
 - 2.2. Подсчет количества пропусков в данных.
 - 2.3. Определение взаимосвязи между признаками с помощью коэффициента корреляции.
 - 2.4. Визуализация пар признаков.
3. Отбор и выделение признаков.
4. Построение модели регрессии.
 - 4.1 Разбиение на тестовое и обучающее множество.
 - 4.2 Создание модели регрессии.
 - 4.3. Обучение модели регрессии.
 - 4.4. Предсказание целевой переменной – цены на жилье.
 - 4.5. Оценка качества модели с использованием метрик среднеквадратической ошибки и коэффициента детерминации.
5. Проанализировать полученные результаты и сделать выводы.

Пример кода приведен в блокноте BostonDS_Lin_Reg.jpynb.

Задача 2. Необходимо решить задачу регрессии, используя кейс, предоставленный индустриальным партнером.

Контрольные вопросы.

1. Что такое регрессионный анализ и в каких задачах он применяется?
2. Какова базовая модель простой линейной регрессии? Опишите основные компоненты уравнения.
3. Объясните разницу между простой и множественной линейной регрессией. Какие особенности возникают при использовании нескольких предикторов?

4. Что такое корреляция? Какие виды корреляции бывают?
5. Что такое критерий R^2 (коэффициент детерминации)? Как он используется для оценки качества модели?
6. В чем заключается суть полиномиальной регрессии и при каких условиях ее использование обосновано?
7. Какая библиотека Python используется для реализации методов регрессии?

.

4. ЛАБОРАТОРНАЯ РАБОТА 4. МЕТОДЫ КЛАССИФИКАЦИИ.

Цель работы: Научиться решать задачи классификации с использованием различных классификаторов, проводить оценку качества классификации.

Краткие теоретические сведения

Задача классификации представляет собой задачу отнесения образца к одному из нескольких попарно не пересекающихся множеств. Примером таких задач может быть, например, задача определения кредитоспособности клиента банка, медицинские задачи, в которых необходимо определить, например, исход заболевания, решение задач управления портфелем ценных бумаг (продать купить или "придержать" акции в зависимости от ситуации на рынке), задача определения жизнеспособных и склонных к банкротству фирм.

Цель классификации. При решении задач классификации необходимо отнести имеющиеся статические образцы (характеристики ситуации на рынке, данные медосмотра, информация о клиенте) к определенным классам. Возможно несколько способов представления данных. Наиболее распространенным является способ, при котором образец представляется вектором. Компоненты этого вектора представляют собой различные характеристики образца, которые влияют на принятие решения о том, к какому классу можно отнести данный образец. Например, для медицинских задач в качестве компонентов этого вектора могут быть данные из медицинской карты больного.

Таким образом, на основании некоторой информации о примере, необходимо определить, к какому классу его можно отнести. Классификатор относит объект к одному из классов в соответствии с определенным разбиением N -мерного пространства, которое называется пространством входов, и размерность этого пространства является количеством компонент вектора.

Прежде всего, нужно определить уровень сложности системы. В реальных задачах часто возникает ситуация, когда количество образцов ограничено, что осложняет определение сложности задачи. Возможно выделить три основных уровня сложности. Первый (самый простой) – когда классы можно разделить прямыми линиями (или гиперплоскостями, если пространство входов имеет размерность больше двух) – так называемая линейная делимость. Во втором случае классы невозможно разделить линиями (плоскостями), но их возможно отделить с помощью более сложного деления – нелинейная делимость. В третьем случае классы пересекаются и можно говорить только о вероятностной делимости.

Подготовка исходных данных. Для построения классификатора необходимо определить, какие параметры влияют на принятие решения о том, к какому классу принадлежит образец. При этом могут возникнуть две проблемы. Во-первых, если количество параметров мало, то может возникнуть ситуация, при которой один и тот же набор исходных данных соответствует примерам, находящимся в разных классах. Тогда невозможно обучить классификатор, и он будет некорректно работать. Исходные данные обязательно должны быть непротиворечивы. Для решения этой проблемы необходимо увеличить размерность пространства признаков (количество компонент входного вектора, соответствующего образцу).

Задание на лабораторную работу:

Задача 1. Провести исследование набора данных о пассажирах Титаника. Необходимо сравнить два классификатора по метрике точности на тестовом множестве. Вид классификаторов и метрика точности определяется согласно варианту.

Реализацию проекта анализа данных провести на языке Питон с использованием инструментов Jupiter Notebook (локально) или Google Colab (облачный сервис, для работы требуется аккаунт Google).

Для исследований предлагается использовать шаблон электронного блокнота ЛР_№_5_Методы_классификации.ipynb, необходимо выполнить все задания из этого блокнота согласно варианту.

Исходные данные:

Набор данных train_Титаник.csv с сайта проекта <https://www.kaggle.com/c/titanic/data> со следующей структурой:

Столбцы (атрибуты) данных:

PassengerId - идентификатор пассажира

Survival - поле в котором указано спасся человек(1) или нет (0)

Pclass - содержит социально-экономический статус, "класс пассажира" (высокий, средний, низкий)

Name - имя пассажира

Sex - пол
пассажира

Age - возраст

SibSp - содержит информацию о количестве родственников 2-го порядка (муж, жена, братья, сестры)

Parch - содержит информацию о количестве родственников на борту 1-го порядка (мать, отец, дети)

Ticket - номер билета

Fare - цена билета

Cabin - каюта

Embarked - порт посадки (C - Cherbourg, Q - Queenstown, S - Southampton)

Варианты классификаторов:

1. Логистическая регрессия
2. Дерево решений
3. Случайный лес
4. Градиентный бустинг
5. Многослойный перцептрон.

Краткие сведения о метриках классификации необходимо изучить по ссылке:

<https://habr.com/ru/company/ods/blog/328372/>

Необходимо выбрать классификатор, наилучший по метрике (максимальная точность на тестовом множестве), сделать выводы.

Варианты заданий к задаче 1.

	Параметр для генератора случайных чисел	Метрика для оценки точности на тестовом множестве	Классификатор 1	Классификатор 2
<u>1.</u>	42	Accuracy	Логистическая регрессия	Дерево решений
<u>2.</u>	20	Precision	Логистическая регрессия	Случайный лес
<u>3.</u>	25	Recall	Логистическая регрессия	Градиентный бустинг
<u>4.</u>	30	F1-мера	Логистическая регрессия	Многослойный перцептрон
<u>5.</u>	35	Accuracy	Дерево решений	Случайный лес
<u>6.</u>	15	Precision	Дерево решений	Градиентный бустинг
<u>7.</u>	40	Recall	Дерево решений	Многослойный перцептрон
<u>8.</u>	24	F1-мера	Случайный лес	Градиентный бустинг
<u>9.</u>	26	Accuracy	Случайный лес	Многослойный перцептрон
<u>10.</u>	85	Precision	Градиентный бустинг	Многослойный перцептрон
<u>11.</u>	90	Recall	Логистическая регрессия	Дерево решений
<u>2.</u>	<u>50</u>	<u>F1-мера</u>	<u>Логистическая регрессия</u>	<u>Случайный лес</u>
<u>13.</u>	<u>45</u>	<u>Accuracy</u>	<u>Логистическая регрессия</u>	<u>Градиентный бустинг</u>
<u>14.</u>	<u>60</u>	<u>Precision</u>	<u>Логистическая регрессия</u>	<u>Многослойный перцептрон</u>
<u>15.</u>	<u>65</u>	<u>Recall</u>	<u>Дерево решений</u>	<u>Случайный лес</u>
<u>16.</u>	<u>70</u>	<u>F1-мера</u>	<u>Дерево решений</u>	<u>Градиентный бустинг</u>
<u>17.</u>	<u>75</u>	<u>Accuracy</u>	<u>Дерево решений</u>	<u>Многослойный перцептрон</u>

<u>18.</u>	<u>28</u>	<u>Precision</u>	<u>Случайный лес</u>	<u>Градиентный бустинг</u>
<u>19.</u>	<u>44</u>	<u>Recall</u>	<u>Случайный лес</u>	<u>Многослойный перцептрон</u>
<u>20.</u>	<u>22</u>	<u>F1-мера</u>	<u>Градиентный бустинг</u>	<u>Многослойный перцептрон</u>
<u>21.</u>	<u>52</u>	<u>Accuracy</u>	<u>Логистическая регрессия</u>	<u>Дерево решений</u>
<u>22.</u>	<u>54</u>	<u>Precision</u>	<u>Логистическая регрессия</u>	<u>Случайный лес</u>
<u>23.</u>	<u>62</u>	<u>Recall</u>	<u>Логистическая регрессия</u>	<u>Градиентный бустинг</u>
<u>24.</u>	<u>64</u>	<u>F1-мера</u>	<u>Логистическая регрессия</u>	<u>Многослойный перцептрон</u>
<u>25.</u>	<u>36</u>	<u>Accuracy</u>	<u>Дерево решений</u>	<u>Случайный лес</u>
<u>26.</u>	<u>38</u>	<u>Precision</u>	<u>Дерево решений</u>	<u>Градиентный бустинг</u>
<u>27.</u>	<u>40</u>	<u>Recall</u>	<u>Дерево решений</u>	<u>Многослойный перцептрон</u>
<u>28.</u>	<u>46</u>	<u>F1-мера</u>	<u>Случайный лес</u>	<u>Градиентный бустинг</u>
<u>29.</u>	<u>56</u>	<u>Accuracy</u>	<u>Случайный лес</u>	<u>Многослойный перцептрон</u>
<u>30.</u>	<u>92</u>	<u>Precision</u>	<u>Градиентный бустинг</u>	<u>Многослойный перцептрон</u>

Задача 2. Необходимо решить задачу регрессии, используя кейс, предоставленный индустриальным партнером.

Контрольные вопросы.

1. Что понимается под задачей классификации, и чем она принципиально отличается от задачи регрессии?
2. Перечислите основные методы классификации и кратко охарактеризуйте каждый из них.
3. Приведите примеры задач классификации (бинарной и многоклассовой).
4. Какие типы обучения используются в задачах классификации?
5. Нарисуйте матрицу ошибок для бинарной классификации. Обозначьте: TP, TN, FP, FN.
6. Что такое точность (Accuracy)? В каких задачах она может быть обманчива (проблема несбалансированных данных)?
7. Определите Precision, Recall, F1-score. Как они связаны с понятиями «ложноположительное» и «ложноотрицательное» срабатывания?
8. В чем принцип построения и работы дерева решений? Какие критерии используются для разделения узлов?

5. ЛАБОРАТОРНАЯ РАБОТА 5. КЛАСТЕРНЫЙ АНАЛИЗ.

Цель работы: Научиться применять методы кластерного анализа с использованием библиотек Python.

Краткие теоретические сведения.

Кластеризация или кластерный анализ подразумевает выделение из исходного множества данных групп объектов со схожими свойствами. В многомерном пространстве такие группы отображаются в виде сгущений точек (Рисунок 1). Эти группы называются кластерами. Кластеризация часто является первым шагом при анализе данных. Разбиение на группы позволяет упростить работу с данными, после кластеризации применяются другие методы анализа данных, для каждой группы при необходимости строится отдельная модель данных.




Рисунок 1 – Идея кластерного анализа

Рассмотрим понятия центра кластера, радиуса кластера, размера кластера в многомерном пространстве признаков.

Центр кластера – среднее геометрическое место точек в пространстве переменных.

Радиус кластера – максимальное расстояние точек от центра кластера.

Размер кластера – может быть определен либо по радиусу кластера, либо по среднеквадратичному отклонению объектов для этого кластера. Объект относится к кластеру, если расстояние от объекта до центра кластера меньше радиуса кластера.

Существует более 100 алгоритмов кластеризации, при выполнении работы нужно будет реализовать два вида алгоритмов: алгоритм k-means (k –средних) и иерархическую кластеризацию. В основе работы алгоритма k-means лежит принцип оптимального в определенном смысле разбиения множества данных на k кластеров. Выбор числа k может базироваться на теоретических соображениях или интуиции. Алгоритм пытается сгруппировать данные в кластеры таким образом, чтобы целевая функция алгоритма разбиения достигала экстремума. Например, в качестве целевой функции может быть взята внутригрупповая сумма квадратов отклонения:

$$W = \sum_{j=1}^n (x_j - \bar{x})^2 = \sum_{j=1}^n x_j^2 - \frac{1}{n} \left(\sum_{j=1}^n x_j \right)^2$$

где x_j представляет собой параметры (атрибуты) j -го объекта, $\bar{x}$ – среднее значение атрибута.

Алгоритм k-means состоит из двух этапов: 1) Первоначальное распределение объектов по кластерам. Задается число k , и на первом шаге эти точки считаются «центрами» кластеров. Каждому кластеру соответствует один центр. Выбор начальных центров осуществляется случайным образом. В результате каждый объект назначен определенному кластеру. 2) Итерационный процесс. Вычисляются новые центры кластеров и объекты перераспределяются. Процесс вычисления центров и перераспределения объектов продолжается до тех пор, пока не стабилизируются центры кластеров, т.е. все объекты будут принадлежать кластеру, которому они принадлежали до текущей итерации. Пример реализации алгоритма k-means для различного числа кластеров k приведен на рисунке 2.




Рисунок 2 – Метод К-средних (k-means).

Иерархическая кластеризация (также графовые алгоритмы кластеризации и иерархический кластерный анализ) — совокупность алгоритмов упорядочивания данных, направленных на создание иерархии (дерева) вложенных кластеров.

Выделяют два класса методов иерархической кластеризации:

1) *Агломеративные методы* (англ. agglomerative): новые кластеры создаются путем объединения более мелких кластеров.

2) *Дивизимные методы* (англ. divisive): новые кластеры создаются путем деления более крупных кластеров на более мелкие.

Чаще используются агломеративные методы.

Дендрограмма (dendrogram) - древовидная диаграмма, содержащая n уровней, каждый из которых соответствует одному из шагов процесса последовательного укрупнения кластеров. Дендрограмму также называют древовидной схемой, деревом объединения кластеров, деревом иерархической структуры. Дендрограмма представляет

собой вложенную группировку объектов, которая изменяется на различных уровнях иерархии.

Для создания дендрограммы требуется матрица сходства (или различия), которая определяет уровень сходства между парами кластеров. Пример дендрограммы для 20 объектов приведен на рисунке 3.




Рисунок 3 - Дендрограмма

Для построения матрицы сходства (различия) необходимо задать меру расстояния между двумя кластерами.

Наиболее часто используются следующие методы определения расстояния (англ. sorting strategies):

1) *Метод одиночной связи* (англ. single linkage), также известен, как «метод ближайшего соседа». Расстояние между двумя кластерами полагается равным минимальному расстоянию между двумя элементами из разных кластеров.

2) *Метод полной связи* (англ. complete linkage), также известен, как «метод дальнего соседа». Расстояние между двумя кластерами полагается равным максимальному расстоянию между двумя элементами из разных кластеров.

3) *Метод средней связи* (англ. pair-group method using arithmetic mean): Расстояние между двумя кластерами полагается равным среднему расстоянию между элементами этих кластеров.

Решение задачи кластеризации принципиально неоднозначно. Проверить адекватность решения, не прибегая к помощи другого вида кластерного анализа, нельзя – в теоретическом плане эта проблема не решена. Существует эмпирическое правило — устойчивая типология сохраняется при изменении методов кластеризации. Результаты можно проверять повторным кластерным анализом с использованием другого метода. Если сравниваемые классификации групп имеют долю совпадений более 70 % (более 2/3 совпадений), то кластерное решение принимается.

Задание на лабораторную работу

Задача 1. Необходимо провести кластерный анализ следующих наборов данных:

1. Набор данных `iris_df`, загруженный из встроенных наборов данных библиотеки `sklearn` и содержащий следующие поля:
'sepal length (cm)' - длина чашелистика в см
'sepal width (cm)' - ширина чашелистика в см

'petal length (cm)' - длина чашелистика в см
'petal width (cm)' - ширина чашелистика в см
Метки класса (сорта ирисов): Iris-Setosa Iris-Versicolour Iris-Virginica.
Использовать метод k-means.

2. Набор данных train_Титаник.csv. Использовать иерархическую кластеризацию и метод k-means.

Ход работы

1. Загрузить в рабочую папку Jupiter Notebook:
 - 1) файл блокнота ЛР №5 Кластеризация.ipynb (Рисунок 4);
 - 2) набор данных train_Титаник.csv.

```
▼ Кластеризация (Набор данных - Ирисы)

[ ] #импортируем библиотеки
import os
import sys
import random
import pandas as pd
import numpy as np

from matplotlib import pyplot as plt

from sklearn import datasets
from sklearn.cluster import KMeans
from scipy.spatial.distance import pdist
from scipy.cluster.hierarchy import *
#данная строка нужна для корректного отображения графиков
%matplotlib inline

[ ] # Загружаем набор данных
iris_df = datasets.load_iris()

[ ] print(iris_df)

[[5.7, 2.8, 4.1, 1.3],
 [6.3, 3.3, 6. , 2.5],
 [5.8, 2.7, 5.1, 1.9],
 [7.1, 3. , 5.9, 2.1],
 [6.3, 2.9, 5.6, 1.8],
 [6.5, 3. , 5.8, 2.2],
 [7.6, 3. , 6.6, 2.1],
 [4.9, 2.5, 4.5, 1.7],
 [7.3, 2.9, 6.3, 1.8],
 [6.7, 3. , 5. , 1.5]]
```

Рисунок 4 - файл блокнота ЛР №5_Кластеризация.ipynb

2. Изучить код и провести импорт необходимых библиотек.
3. Провести загрузку набора данных iris_df, изучить методы работы со встроенными наборами данных 'DESCR', 'feature_names', 'filename', 'target', 'target_names', вывести перечень столбцов, метки класса.
4. Провести разделение набора данных для визуализации (выделение столбцов).
5. Построить диаграмму рассеивания.
6. Провести кластеризацию методом k-means. Число кластеров принять равным 3.
7. Загрузить набор данных train_Титаник.csv.
8. Выделить первые 20 строк набора для проведения кластеризации.
9. Провести замену категориальных значений на численные
10. Заполнить пропуски в наборе данных.

11. Провести нормализацию данных (приведение к единому диапазону значений)
12. Провести иерархическую кластеризацию.
13. Построить диаграмму рассеивания для анализа результатов кластеризации.
14. Построить дендрограмму для разного числа кластеров.
15. Провести проверку кластерного решения методом К-средних.

Задача 2. Необходимо решить задачу кластеризации, используя кейс, предоставленный промышленным партнером.

Оформить отчет о работе. Допускается электронный вариант отчета.

Содержание отчета: цель работы, краткие теоретические сведения, ход работы со снимками экрана, выводы по работе.

Контрольные вопросы.

1. Что такое кластерный анализ? Какова его цель?
2. В чем разница между кластеризацией и классификацией?
3. Почему нормализация (стандартизация) данных важна для большинства алгоритмов кластеризации?
4. Какие методы преобразования категориальных переменных используются перед кластеризацией?
5. Какие меры расстояния используются в кластерном анализе, и как выбор метрики влияет на результаты?
6. Что такое матрица различия? Матрица сходства?
7. Как определить оптимальное число кластеров K для алгоритма K-means?
8. Опишите принцип агломеративной иерархической кластеризации (снизу вверх).
9. Как построить дендрограмму (древовидную диаграмму)? Как определить число кластеров на дендрограмме?
10. Приведите примеры практических задач, где кластерный анализ играет ключевую роль.

ЛАБОРАТОРНАЯ РАБОТА 6. ПРЕДСТАВЛЕНИЕ РЕЗУЛЬТАТОВ АНАЛИТИЧЕСКОГО ПРОЕКТА

Цель работы: подготовить презентацию аналитического проекта, состоящего из решений задач, входящих в кейсы промышленных партнеров, сделать доклад по результатам проекта.

Примерное содержание презентации:

1. Тема проекта, исполнители
2. Постановка задачи
3. Описание набора данных
4. Извлечение набора данных из источников
5. Загрузка данных в аналитическую систему
6. Предварительный анализ данных
7. Решение задач регрессии
8. Решение задач классификации
9. Решение задач кластеризации
10. Анализ результатов и выводы.

Сведения об авторах

Машенко Елена Николаевна, кандидат технических наук, доцент, доцент кафедры «Информационные технологии и системы» Института информационных технологий Высшей Технологической Школы «Севастопольский приборостроительный институт», ФГАОУ ВО Севастопольский государственный университет.