

Кейсы промышленных партнёров

для задач регрессии, классификации и кластеризации

Партнёры: ООО «РТК ИТ» (Ростелеком ИТ); ПАО «Сбербанк» (Сбер); ООО «Интернет Решения» (Ozon).

Реальные данные партнёров закрыты. Для выполнения работы по каждому кейсу указан публичный датасет-аналог (Kaggle / UCI / GitHub) с сохранением предметной постановки.

Сводная таблица

ID	Партнёр	Задача	Кейс	Датасет
Р-1	Сбер	Регрессия	Прогноз LTV	FinTech LTV
Р-2	Ozon	Регрессия	Прогноз спроса на SKU	Store Item Demand
Р-3	РТК ИТ	Регрессия	Длительность IT-инцидента	UCI Incident Log
Кл-1	Сбер	Классификация	Детекция фрода	Credit Card Fraud
Кл-2	Ozon	Классификация	Прогноз возврата	Return Likelihood
Кл-3	РТК ИТ	Классификация	Прогноз оттока	Telco Churn
Кз-1	Сбер	Кластеризация	Сегментация клиентов банка	Bank Segmentation
Кз-2	Ozon	Кластеризация	Сегментация покупателей	Online Retail II
Кз-3	РТК ИТ	Кластеризация	Кластеризация инцидентов	UCI Incident Log

Регрессия

Р-1. Прогноз LTV клиента розничного банка (Сбер)

Исходная ситуация

В розничном банке стоимость привлечения клиента высока: реклама, партнёрские каналы, онбординг в приложении. При этом бюджет на удержание и кросс-продажи ограничен. Исторически маркетинг часто работал «средним чеком»: одинаковые кампании на широкую базу. В итоге ресурсы уходили на клиентов с низкой отдачей, а высокомаржинальные клиенты не получали персонального развития (накопительные продукты, премиум, страхование, инвестиции).

Команда CRM и продуктовой аналитики Сбера формулирует задачу иначе: **оценить будущую ценность клиента (LTV)** и ранжировать базу — кого удерживать в первую очередь, кому предлагать следующий продукт, на ком экономить коммуникации.

Бизнес-контекст

- LTV используют для приоритизации retention-кампаний и расчёта допустимой стоимости привлечения (CAC).
- Ошибка завышения LTV → лишние расходы на «пустых» клиентов.
- Ошибка занижения → упущенная маржа по перспективным клиентам.

Заинтересованные роли

- **Заказчик результата:** CRM / маркетинг, владельцы розничных продуктов.
- **Пользователи модели:** менеджеры кампаний, аналитики сегментов.
- **Смежные роли:** риск (ограничения по предложениям), compliance (персональные данные).

Внедрение

Скоринг LTV в CRM: ранжирование базы → приоритет retention/кросс-sell → лимиты бюджета кампаний. Результат — дашборд топ-клиентов и правила «кому звонить / кому не звонить».

Постановка ML

- **Тип задачи:** регрессия.
- **Объект:** клиент на отчётную дату.
- **Y:** LTV (ожидаемый доход банка от клиента на горизонте 6–12 месяцев), руб.
- **X (примеры):** tenure; число продуктов; средний остаток; частота транзакций; канал привлечения; регион; активность в мобильном банке; история просрочек; демография.
- **Метрики:** MAE, RMSE, MAPE; интерпретация важности признаков.
- **Задание:** EDA; ≥ 2 модели (например, линейная / Ridge и Random Forest или бустинг); train/test; сравнение; рекомендации для CRM.
- **Ожидаемый результат:** модель прогноза LTV + краткий отчёт «какие факторы сильнее всего связаны с ценностью клиента».

Baseline

Прогноз «средним LTV по всей выборке» или средним LTV внутри простого сегмента (например, по числу продуктов). ML должен устойчиво бить этот baseline по MAE/RMSE.

Данные для работы

[FinTech Customer LTV Dataset \(Kaggle\)](#) — ~7 000 клиентов, целевая **LTV**.

Альтернатива: [Retail Banking Dataset](#).

Р-2. Прогноз спроса на SKU (Ozon)

Исходная ситуация

Ozon управляет огромным ассортиментом и сетью складов и сортировочных центров. Закупки и размещение запасов долго опирались на экспертные оценки категорийных менеджеров и простые скользящие средние. На практике это даёт две боли:

1. **Out-of-stock** — товар закончился в нужном регионе, продажа ушла конкуренту, падает конверсия и рейтинг продавца.

2. **Затоваривание** — лишний запас замораживает оборотный капитал, занимает ячейки фулфилмента, повышает риск уценки.

Особенно остро проблема проявляется в сезон (праздники, распродажи, «Чёрная пятница»), когда спрос скачет, а ручное планирование не успевает.

Бизнес-контекст

- Прогноз нужен supply chain и category management на горизонте дня/недели.
- Хороший прогноз снижает lost sales и издержки хранения.
- Важно отдельно контролировать ошибку в промо-периоды.

Заинтересованные роли

- **Заказчик:** supply chain / category management.
- **Пользователи:** планировщики закупок, менеджеры складов.
- **Смежные роли:** коммерция (цены/промо), логистика.

Внедрение

Ежедневный/еженедельный batch-прогноз → система пополнения (safety stock + прогноз) → аллокация по складам. Алерт при резком отклонении факта от прогноза.

Постановка ML

- **Тип задачи:** регрессия / прогнозирование спроса (tabular + временные признаки).
- **Объект:** SKU × день (или SKU × неделя × склад/магазин).
- **Y:** объём спроса, шт. (или GMV).
- **X (примеры):** лаги продаж; день недели/месяц; цена; скидка/промо; рейтинг; остаток; категория; регион.
- **Метрики:** MAE, RMSE, MAPE; отдельно ошибка на промо.
- **Задание:** baseline (скользящее среднее) vs ML; feature engineering по времени; правило пополнения склада на основе прогноза.
- **Ожидаемый результат:** модель спроса + сравнение с baseline + рекомендация для пополнения.

Baseline

Скользящее среднее продаж за последние 7/14 дней (или наивный прогноз «вчера = сегодня»). ML сравнивать с этим baseline на одном и том же горизонте.

Данные для работы

[Store Item Demand Forecasting Challenge \(Kaggle\)](#).

Альтернатива: [Store Sales — Favorita](#).

Р-3. Прогноз длительности устранения IT-инцидента (РТК ИТ)

Исходная ситуация

РТК ИТ обслуживает ИТ-ландшафт телеком-оператора и корпоративных заказчиков: сети, платформы, прикладные системы. Обращения и аварии регистрируются в ITSM (аналог ServiceNow). По договорам действуют **SLA**: критичный инцидент должен быть устранён за ограниченное время, иначе штрафы и репутационные риски.

На практике диспетчеры и L1 часто оценивают срок «на глазок». В пиковые часы очередь растёт, эскалации запаздывают, а менеджеры смен не понимают, успеет ли команда закрыть инцидент в SLA. Долгие «хвосты» (инциденты, длящиеся днями) съедают ресурс L2/L3 и ломают план работ.

Бизнес-контекст

- Нужен прогноз длительности уже при регистрации тикета.
- Прогноз помогает: выбрать очередь, эскалировать заранее, предупредить заказчика, перераспределить смену.
- Для планирования важны не только среднее, но и «пессимистичный» квантиль (P90).

Заинтересованные роли

- **Заказчик:** руководитель Service Desk / NOC, менеджер SLA.
- **Пользователи:** диспетчеры, L1/L2, менеджеры смен.
- **Смежные роли:** владельцы сервисов (CI), заказчик по договору.

Внедрение

При создании инцидента — прогноз ETA в карточке ITSM; правило автоэскалации, если прогноз > SLA; дашборд загрузки смены по ожидаемым часам закрытия.

Постановка ML

- **Тип задачи:** регрессия.
- **Объект:** IT-инцидент.
- **Y:** длительность устранения = `resolved_at / closed_at - opened_at` (часы/минуты).
- **X (примеры):** приоритет; категория/подкатегория; тип; команда; канал; час/день создания; число эскалаций; похожие инциденты; затронутый сервис (CI).
- **Метрики:** MAE, RMSE; ошибка на P90; анализ хвоста распределения.
- **Задание:** предобработка event log → одна строка на инцидент; модель; разбор факторов долгих инцидентов; предложение по эскалациям.
- **Ожидаемый результат:** модель срока закрытия + рекомендации для Service Desk / NOC.

Baseline

Средняя (или медианная) длительность по приоритету/категории из train. Сравнивать MAE/RMSE модели с этим правилом; отдельно смотреть хвост (P90).

Данные для работы

[Incident Management Process Enriched Event Log \(UCI\)](#).

Kaggle: [IT Incident Log Dataset](#).

Классификация

Кл-1. Детекция мошеннических транзакций (Сбер)

Исходная ситуация

С ростом безналичных платежей и онлайн-переводов растёт и объём мошенничества: украденные карты, социальная инженерия, автоматические скрипты. Банк обязан защищать клиентов, но каждая **ложная блокировка** легитимной операции — это звонок в поддержку, недовольство и риск оттока в другой банк.

Исторически антифрод строился на жёстких правилах (лимиты, страны, MCC). Правила быстро устаревают: мошенники адаптируются, а легитимное поведение клиентов тоже меняется (путешествия, крупные покупки). Поэтому нужен ML-классификатор, который оценивает риск каждой транзакции в реальном времени.

Бизнес-контекст

- Цена **пропуска фрода (FN)** — прямые убытки банка/клиента.
- Цена **ложного срабатывания (FP)** — клиентский опыт и нагрузка на контакт-центр.
- Классы сильно несбалансированы: фрод — доли процента от потока.

Заинтересованные роли

- **Заказчик:** антифрод / служба безопасности банка.
- **Пользователи:** мониторинг транзакций, операторы подтверждения.
- **Смежные роли:** контакт-центр, продуктовые владельцы карт, compliance.

Внедрение

Скоринг в потоке авторизации: score → порог → pass / step-up (OTP) / decline. Журнал решений и периодический пересмотр порога по стоимости FP/FN.

Постановка ML

- **Тип задачи:** бинарная классификация.
- **Объект:** транзакция.
- **Y:** `Class` = 1 (fraud) / 0 (legit).
- **X:** `Amount`, `Time`, признаки V1–V28 (PCA-анонимизация в учебном датасете).
- **Метрики:** Precision, Recall, F1, ROC-AUC, **PR-AUC** (важнее accuracy).
- **Задание:** учесть дисбаланс (веса классов / resampling); сравнить модели (логрег, SVM/k-NN/RF); подобрать порог; оценить стоимость FP vs FN.
- **Ожидаемый результат:** классификатор фрода + политика порога для мониторинга.

Baseline

Классификатор «всегда legit» (majority) и/или простое правило по сумме/времени. Сравнить по Recall/Precision/PR-AUC, не по accuracy.

Данные для работы

Кл-2. Прогноз возврата заказа (Ozon)

Исходная ситуация

На маркетплейсе свободный возврат — конкурентное преимущество и одновременно статья расходов: обратная логистика, переупаковка, уценка, споры с продавцами. Особенно высок процент возвратов в fashion (размер/посадка), электронике (ожидания vs описание) и при агрессивных промо.

Если риск возврата виден **до отгрузки**, платформа может мягко вмешаться: уточнить размер, предложить другой слот доставки, запросить предоплату, показать более релевантные варианты. Без модели решения либо запаздывают (уже после возврата), либо применяются грубые эвристики («вся одежда рискованна»), которые портят UX добросовестным покупателям.

Бизнес-контекст

- Снижение return rate улучшает unit-экономику SKU и продавца.
- Важно не «запретить покупку», а выбрать точечное действие по уровню риска.
- Модель должна быть объяснимой для category/ops команд.

Заинтересованные роли

- **Заказчик:** category / operations / CX.
- **Пользователи:** правила чекаута, поддержка продавцов.
- **Смежные роли:** логистика возвратов, финансы unit-экономики.

Внедрение

Score риска в чекауте/до отгрузки → действия по порогам (подсказка размера, предоплата, иной слот).
Отчёт по категориям с высоким риском для контента карточек.

Постановка ML

- **Тип задачи:** бинарная классификация.
- **Объект:** заказ / позиция заказа.
- **Y:** returned = 1 / 0.
- **X:** категория; цена; вариация размера; рейтинг продавца; история возвратов покупателя; регион; способ доставки; число позиций; скидка; tenure.
- **Метрики:** Precision, Recall, F1, ROC-AUC.
- **Задание:** классификатор; сравнение с простым правилом; матрица ошибок; политика действий по порогам риска.
- **Ожидаемый результат:** модель риска возврата + схема применения в чекауте/доставке.

Baseline

Эвристика: «возврат, если категория = Clothing» или «если previous_returns_count > порога». ML должен улучшить F1/ROC-AUC относительно эвристики.

Данные для работы

[E-Commerce Product Return Likelihood \(Kaggle\)](#).

Альтернатива: [E-commerce Orders Dataset 2026](#).

Кл-3. Прогноз оттока абонента / клиента ИТ-сервиса (РТК ИТ)

Исходная ситуация

В телекоме и ИТ-услугах привлечение нового абонента/корпоративного клиента дороже удержания существующего. Отток часто выглядит «внезапным» для бизнеса: расторжение договора, переход к конкуренту, отказ от доп. услуги. На самом деле перед уходом обычно есть сигналы — рост обращений в поддержку, даунтаймы, смена тарифа на более дешёвый, просрочки оплаты, падение использования сервиса.

РТК ИТ и операторский контур заинтересованы в **проактивном retention**: заранее находить клиентов группы риска и предлагать удержание (скидка, смена тарифа, приоритетная поддержка), а не реагировать после факта ухода.

Бизнес-контекст

- Кампания удержания дорогая → нужен баланс Precision/Recall.
- Высокий Recall класса «отток» важнее, но лавина ложных тревог обесценивает работу операторов.
- Модель должна выдавать интерпретируемые триггеры для скриптов коммуникаций.

Заинтересованные роли

- **Заказчик:** retention / customer success / коммерция B2C–B2B.
- **Пользователи:** операторы удержания, владельцы тарифов.
- **Смежные роли:** Service Desk (качество сервиса как фактор оттока).

Внедрение

Ежемесячный/еженедельный список клиентов группы риска → кампания (скидка, апселл, звонок) → контроль конверсии удержания. Триггеры модели — в скрипт оператора.

Постановка ML

- **Тип задачи:** бинарная классификация.
- **Объект:** абонент / клиент сервиса.
- **Y:** churn = 1 (уйдёт на горизонте H) / 0.
- **X:** tenure; ARPU / MonthlyCharges; контракт; набор услуг; способ оплаты; обращения/техподдержка (если есть); демография.
- **Метрики:** Precision, Recall, F1, ROC-AUC; приоритет Recall класса оттока при контроле Precision.
- **Задание:** сравнить модели; подобрать порог для кампании; список top-признаков как триггеров.
- **Ожидаемый результат:** churn-модель + рекомендации для retention.

Baseline

Правило: «churn, если Contract = Month-to-month и tenure мал» (или majority class). Сравнивать Recall/Precision на классе оттока.

Данные для работы

[Telco Customer Churn \(Kaggle / IBM\)](#).

GitHub: [Telco-Customer-Churn.csv](#).

Кластеризация

Кз-1. Сегментация клиентов банка (Сбер)

Исходная ситуация

База розничного банка неоднородна: студент с одной картой, семья с ипотекой и зарплатным проектом, премиум-клиент с инвестициями, «спящий» вкладчик. Долгое время продуктовые предложения строились по грубым срезам (возраст, регион, наличие кредита). Это даёт низкий отклик: клиенту показывают нерелевантный продукт, растёт «баннерная слепота» в приложении и раздражение от звонков.

Сегментация на основе поведения (остатки, обороты, digital-активность, частота визитов) позволяет выделить устойчивые группы и назначить каждой свой playbook: офферы, каналы, частоту коммуникаций, уровень сервиса.

Бизнес-контекст

- Сегменты нужны маркетингу, CRM и продуктовым владельцам.
- Кластеры должны быть **интерпретируемыми** (не только «хороший silhouette»).
- Результат — карта сегментов с бизнес-именами и рекомендуемыми действиями.

Заинтересованные роли

- **Заказчик:** CRM / маркетинг / продукт.
- **Пользователи:** кампании, персональные менеджеры.
- **Смежные роли:** риск, data governance.

Внедрение

Сегмент как атрибут клиента в CRM → разные офферы и частота коммуникаций → A/B проверка отклика по сегментам.

Постановка ML

- **Тип задачи:** кластеризация (без учителя).
- **Объект:** клиент (профиль, агрегированный из транзакций).
- **X:** возраст; пол; локация; баланс; сумма и частота транзакций; digital-активность и др.
- **Метрики:** Silhouette, elbow/inertia; экспертная интерпретация.
- **Задание:** предобработка и агрегация до клиента; k-means / hierarchical / DBSCAN; визуализация (t-SNE/UMAP); назвать сегменты и офферы.

- **Ожидаемый результат:** сегментная модель + рекомендации по персонализации.

Baseline

Простая нарезка по 1–2 признакам (например, tertiles баланса или возраст × наличие кредита). Кластеры ML должны давать более осмысленные и однородные группы (Silhouette + бизнес-имена).

Данные для работы

[Bank Customer Segmentation — 1M+ Transactions \(Kaggle\)](#).

Альтернатива: [Retail Banking Dataset](#).

Кз-2. Сегментация покупателей маркетплейса (Ozon)

Исходная ситуация

На витрине Ozon миллионы SKU и потоки рекомендаций. Если всем показывать «средний» ассортимент и одинаковые промо, часть аудитории не конвертируется: охотники за скидками игнорируют full-price, premium-покупатели устают от агрессивных акций, семейный сегмент не видит релевантные категории. Классический подход e-commerce — **RFM** (Recency, Frequency, Monetary) плюс категорийный профиль. Кластеризация по этим признакам даёт сегменты вроде «охотники за скидками», «premium fashion», «family FMCG», «редкие крупные заказы», для которых можно настроить ленту, промо и логистические приоритеты (например, экспресс).

Бизнес-контекст

- Сегменты питают рекомендации, CRM-рассылки и управление промо.
- Важно проверить устойчивость кластеров во времени.
- Бизнес ждёт понятные названия и действия, а не номера кластеров.

Заинтересованные роли

- **Заказчик:** CRM / персонализация / performance marketing.
- **Пользователи:** команды рекомендаций и промо.
- **Смежные роли:** логистика (приоритеты доставки), category.

Внедрение

Сегмент в профиле покупателя → персонализация ленты и промо → оценка uplift конверсии/GMV по сегментам.

Постановка ML

- **Тип задачи:** кластеризация.
- **Объект:** покупатель.
- **X:** R, F, M; средний чек; доля категорий; чувствительность к скидкам; доля экспресс-доставки; возвратность (если есть).
- **Метрики:** Silhouette; устойчивость; интерпретируемость.
- **Задание:** построить RFM; кластеризация; бизнес-имена; рекомендации по промо/логистике.

- **Ожидаемый результат:** карта сегментов покупателей + playbook для CRM.

Baseline

Классические RFM-квинтили / rule-based сегменты (Champions, At Risk, ...) без k-means. ML-кластеры сравнивать по интерпретируемости и Silhouette с rule-based нарезкой.

Данные для работы

[Online Retail II \(UCI\)](#).

Kaggle: [Online Retail II UCI](#).

Кз-3. Кластеризация инцидентов службы поддержки (РТК ИТ)

Исходная ситуация

Журнал ITSM содержит тысячи инцидентов с разными кодами, приоритетами и путями эскалации. Эксперты L2/L3 «в голове» знают повторяющиеся сценарии (сеть, доступы, почта, биллинг...), но знания плохо формализованы: новички учатся долго, gunbook'и устаревают, корневые причины одних и тех же сбоев чинят заново.

Кластеризация исторических инцидентов помогает **автоматически выделить типовые профили**: похожие по признакам группы с общей диагностикой. На их основе можно обновить чек-листы, приоритизировать доработки продуктов и ускорить первую линию поддержки.

Бизнес-контекст

- Цель — не предсказать метку, а открыть структуру потока инцидентов.
- Кластеры валидируются с экспертами L2/L3.
- Результат — каталог профилей: описание, частота, первые шаги, типовой ЗИП/команда.

Заинтересованные роли

- **Заказчик:** руководитель Service Desk, knowledge management.
- **Пользователи:** L1 (чек-листы), L2/L3 (валидация профилей).
- **Смежные роли:** владельцы продуктов/сервисов.

Внедрение

Каталог профилей → gunbook в базе знаний → подсказка «похожий профиль» при регистрации инцидента → приоритизация доработок по частоте кластеров.

Постановка ML

- **Тип задачи:** кластеризация.
- **Объект:** инцидент (агрегат event log).
- **X:** категория/подкатегория; приоритет; длительность; число эскалаций; сервис/CI; канал; повторность; смена/час.
- **Метрики:** Silhouette; однородность внутри кластера; экспертная приёмка.

- **Задание:** агрегация лога; кодирование категорий; k-means / hierarchical / DBSCAN; профилирование кластеров.
- **Ожидаемый результат:** каталог профилей инцидентов для Service Desk.

Baseline

Группировка только по полю category/priority (как есть в ITSM). Кластеризация должна дать более тонкие профили внутри/поперёк этих меток и быть полезнее экспертам.

Данные для работы

[UCI Incident Management Log](#).

Kaggle: [IT Incident Log Dataset](#).

Общие материалы для сдачи кейса

Общий пайплайн работы

1. Выбрать кейс и скачать датасет-аналог.
2. EDA: пропуски, типы, распределения, дисбаланс / выбросы.
3. Подготовка признаков и корректный split (для временных задач — по времени).
4. Построить **baseline** из описания кейса.
5. Обучить ≥ 2 подхода (или 2 настройки / алгоритма) и сравнить с baseline.
6. Посчитать метрики кейса; для классификации — матрица ошибок и порог.
7. Интерпретация для бизнеса + предложение по **внедрению**.
8. Оформить отчёт по шаблону ниже.

Рекомендуемый стек: Python, pandas, scikit-learn, matplotlib/seaborn; при дисбалансе (Кл-1) — веса классов или imbalanced-learn.

Шаблон отчёта студента

1. Партнёр, ID кейса, формулировка бизнес-проблемы.
2. Заинтересованные роли и ожидаемое внедрение.
3. Данные: источник-аналог, объём, предобработка.
4. Baseline и выбранные модели / алгоритм кластеризации.
5. Метрики и сравнение с baseline (таблицы/графики).
6. Бизнес-интерпретация и предложение по внедрению.
7. Выводы.

Пример заполненного отчёта (Кл-1, Сбер)

Ниже — образец оформления. Цифры иллюстративные; в своей работе подставьте реальные результаты прогона.

Отчёт по кейсу Кл-1. Детекция мошеннических транзакций (Сбер)

Студент: Иванов И.И.

Дата: 23.07.2026

Партнёр / ID: Сбер · Кл-1

Тип задачи: бинарная классификация

1. Бизнес-проблема

Банку нужно отличать мошеннические транзакции от легитимных в потоке авторизаций. Пропуск фрода (FN) даёт прямые убытки; ложная блокировка (FP) портит клиентский опыт и загружает контакт-центр. Правила антифрода устаревают — нужен ML-скоринг риска.

2. Заинтересованные роли и внедрение

- **Заказчик:** антифрод / служба безопасности.
- **Пользователи:** мониторинг транзакций, операторы step-up проверки.
- **Внедрение:** модель выдаёт $score \in [0,1]$ в момент авторизации → порог T :
 - $score < T_1 \rightarrow pass$;
 - $T_1 \leq score < T_2 \rightarrow OTP / подтверждение$;
 - $score \geq T_2 \rightarrow decline + алерт$. Порог пересматривается раз в квартал по стоимости FP/FN.

3. Данные

- **Источник-аналог:** [Credit Card Fraud Detection \(MLG-ULB\)](#).
- **Объём:** 284 807 транзакций; fraud = 492 (0,172%).
- **Признаки:** Time, Amount, V1–V28 (PCA); целевая Class.
- **Предобработка:** проверка пропусков (нет); масштабирование Amount и Time (StandardScaler); train/test 80/20 со stratify по Class; на train — class_weight='balanced' (без SMOTE в финальной модели, чтобы не исказить калибровку порога).

4. Baseline и модели

Подход	Описание
Baseline A	Всегда предсказывать «legit» (majority)
Baseline B	Правило: fraud, если Amount > P99 train
Модель 1	Логистическая регрессия + class_weight
Модель 2	Random Forest (n_estimators=200, max_depth=12, class_weight)

Подбор порога для моделей — по максимуму F1 на validation (стратифицированные 20% от train) с контролем Recall $\geq 0,80$.

5. Метрики (test, иллюстративно)

Метод	Precision	Recall	F1	ROC-AUC	PR-AUC
Baseline A (majority)	—	0,00	0,00	0,50	~0,002
Baseline B (Amount>P99)	0,04	0,12	0,06	0,55	0,02
LogReg	0,72	0,84	0,78	0,97	0,74
Random Forest	0,81	0,86	0,83	0,98	0,82

Матрица ошибок Random Forest (test, порог 0,35): TP=85, FN=14, FP=20, TN≈56 842.

Вывод по метрикам: RF бьёт оба baseline; accuracy (~99,9%) не используем как главный критерий из-за дисбаланса.

6. Бизнес-интерпретация и внедрение

- Важные признаки (RF importance): V14, V10, V12, Amount — для мониторинга, не для «человекочитаемого» объяснения клиенту (PCA).
- Рекомендуемый режим: порог $T_2 \approx 0,35$ (высокий Recall); для step-up — более мягкий $T_1 \approx 0,15$.
- Оценка стоимости (условно): если убыток от FN = 50× стоимость разбора FP, выбранный порог предпочтительнее «максимума Precision».
- План внедрения: пилот на 5% трафика → сравнение с правилами → полный rollout + журнал решений.

7. Выводы

- Итог:** Random Forest с порогом 0,35 рекомендован как кандидат в антифрод-контур при пилотном сравнении с действующими правилами.

Критерии оценивания (рубрикатор)

Критерий	Что проверяется	Ориентир «сдано»
Постановка	Понятна связь кейса с задачей ML	Есть Y/объект/метрики или принцип кластеризации
Данные и EDA	Корректная работа с датасетом-аналогом	Описаны объём, пропуски, ключевые распределения
Baseline	Есть точка сравнения	Baseline посчитан и использован в выводах
Модели / метод	Адекватный выбор методов	≥2 подхода или обоснованный один + тюнинг
Метрики	Соответствуют типу задачи	Считаются заявленные метрики; для фрода — не только accuracy
Внедрение	Не только «обучил модель»	Есть роли, сценарий использования, пороги/действия
Оформление	Читаемый отчёт	Структура по шаблону, воспроизводимые шаги

Итоговая логика: кейс считается выполненным, если есть корректный эксперимент и осмысленный бизнес-вывод с планом внедрения, а не только таблица метрик.