

ЛАБОРАТОРНАЯ РАБОТА 3. РЕШЕНИЕ ЗАДАЧ РЕГРЕССИИ.

Цель работы: научиться строить модели регрессии с использованием библиотек машинного обучения языка Python.

Краткие теоретические сведения.

Регрессия – это метод анализа данных, который позволяет исследовать связь между зависимой переменной и одной или несколькими независимыми переменными. Он используется для прогнозирования и предсказания значений зависимой переменной на основе известных значений независимых переменных.

Регрессионный анализ позволяет определить, какие независимые переменные оказывают значимое влияние на зависимую переменную и как сильно это влияние. Он также позволяет оценить силу и направление этого влияния. Регрессионный анализ может быть применен в различных областях, таких как экономика, финансы, маркетинг, социология и многие другие. Он может быть использован для прогнозирования будущих значений, выявления взаимосвязей между переменными, определения важности факторов и др.

Основные понятия регрессионного анализа:

Зависимая переменная, также известная как целевая переменная или переменная отклика, является переменной, которую мы пытаемся предсказать или объяснить. Она обозначается как Y .

Независимые переменные, также известные как *предикторы* или *факторы*, являются переменными, которые мы используем для предсказания или объяснения зависимой переменной. Они обозначаются как X_1 , X_2 , X_3 и так далее.

Регрессионная модель – это математическое представление, которое описывает отношение между зависимой переменной и независимыми переменными. Она может быть представлена в виде уравнения, которое позволяет нам предсказывать значения зависимой переменной на основе значений независимых переменных.

Коэффициенты регрессии – это числа, которые умножаются на значения независимых переменных в регрессионной модели. Они показывают, как сильно и в каком направлении влияют независимые переменные на зависимую переменную. Коэффициенты регрессии обозначаются как β_0 , β_1 , β_2 и так далее.

Множественная регрессия – это тип регрессионного анализа, в котором есть несколько независимых переменных, влияющих на зависимую переменную. В этом случае регрессионная модель будет содержать несколько коэффициентов регрессии.

Коэффициент детерминации, обозначаемый как R^2 , является мерой объясненной вариации зависимой переменной моделью. Он показывает, насколько хорошо модель соответствует данным и объясняет изменчивость зависимой переменной. Значение R^2 может быть от 0 до 1, где 0 означает, что модель не объясняет вариацию, а 1 означает, что модель полностью объясняет вариацию.

Стандартная ошибка – это мера неопределенности или разброса коэффициентов регрессии. Она показывает, насколько точно коэффициенты регрессии оценивают влияние

независимых переменных на зависимую переменную. Чем меньше стандартная ошибка, тем более точные оценки коэффициентов регрессии.

Методы регрессионного анализа

Регрессионный анализ – это статистический метод, который используется для изучения взаимосвязи между зависимой переменной (такой как цена на недвижимость) и одной или несколькими независимыми переменными (такими как размер жилья, количество комнат и т.д.). В регрессионном анализе строится математическая модель, которая описывает эту взаимосвязь и позволяет делать прогнозы.

Простая линейная регрессия – это метод, который используется, когда есть только одна независимая переменная. Модель простой линейной регрессии имеет вид:

$$y = \beta_0 + \beta_1 x + \varepsilon$$

где y – зависимая переменная, x – независимая переменная, β_0 и β_1 – коэффициенты регрессии, ε – ошибка.

Цель простой линейной регрессии – найти наилучшие значения коэффициентов β_0 и β_1 , чтобы минимизировать сумму квадратов ошибок ε .

Множественная линейная регрессия – это метод, который используется, когда есть несколько независимых переменных. Модель множественной линейной регрессии имеет вид:

$$y = \beta_0 + \beta_1 x_1 + \beta_2 x_2 + \dots + \beta_p x_p + \varepsilon$$

где y – зависимая переменная, $x_1, x_2, \dots, x_p$ – независимые переменные, $\beta_0, \beta_1, \beta_2, \dots, \beta_p$ – коэффициенты регрессии, ε – ошибка.

Цель множественной линейной регрессии – найти наилучшие значения коэффициентов $\beta_0, \beta_1, \beta_2, \dots, \beta_p$, чтобы минимизировать сумму квадратов ошибок ε .

Полиномиальная регрессия – это метод, который используется, когда зависимость между переменными не является линейной, а имеет криволинейную форму. В полиномиальной регрессии используются степенные функции независимых переменных.

Модель полиномиальной регрессии имеет вид:

$$y = \beta_0 + \beta_1 x + \beta_2 x^2 + \dots + \beta_p x^p + \varepsilon$$

где y – зависимая переменная, x – независимая переменная, $\beta_0, \beta_1, \beta_2, \dots, \beta_p$ – коэффициенты регрессии, ε – ошибка.

Цель полиномиальной регрессии – найти наилучшие значения коэффициентов $\beta_0, \beta_1, \beta_2, \dots, \beta_p$, чтобы минимизировать сумму квадратов ошибок ε .

Логистическая регрессия – это метод, который используется, когда зависимая переменная является категориальной (бинарной или многокатегориальной). Логистическая регрессия использует логистическую функцию для предсказания вероятности принадлежности к определенной категории.

Модель логистической регрессии имеет вид:

$$p = 1 / (1 + \exp(-(\beta_0 + \beta_1 x_1 + \beta_2 x_2 + \dots + \beta_p x_p)))$$

где p – вероятность принадлежности к определенной категории, $x_1, x_2, \dots, x_p$ – независимые переменные, $\beta_0, \beta_1, \beta_2, \dots, \beta_p$ – коэффициенты регрессии.

Цель логистической регрессии – найти наилучшие значения коэффициентов $\beta_0, \beta_1, \beta_2, \dots, \beta_p$, чтобы максимизировать вероятность принадлежности к правильной категории.

Это лишь некоторые методы регрессионного анализа. В зависимости от задачи и данных, можно использовать и другие методы, такие как регрессия с использованием деревьев решений, регрессия с использованием искусственных нейронных сетей и т.д.

Построение регрессионной модели

Построение регрессионной модели – это процесс нахождения математической функции, которая наилучшим образом описывает связь между зависимой переменной и одной или несколькими независимыми переменными.

Выбор независимых переменных. Первым шагом в построении регрессионной модели является выбор независимых переменных, которые могут влиять на зависимую переменную. Это может быть основано на предварительном анализе данных, экспертном мнении или теоретических предположениях.

Сбор данных. Для построения регрессионной модели необходимо собрать данные, которые содержат значения зависимой переменной и независимых переменных для каждого наблюдения. Данные могут быть получены из различных источников, таких как опросы, эксперименты или базы данных.

Предварительный анализ данных. Перед построением модели необходимо провести предварительный анализ данных, чтобы оценить их качество и проверить наличие выбросов, пропущенных значений или других аномалий. Также можно провести корреляционный анализ, чтобы определить связь между зависимой переменной и независимыми переменными.

Выбор функциональной формы модели

Следующим шагом является выбор функциональной формы модели, которая определяет, как зависимая переменная связана с независимыми переменными. Наиболее распространенной функциональной формой является линейная модель, где зависимая переменная представляется линейной комбинацией независимых переменных. Однако, в зависимости от данных и предметной области, можно использовать и другие функциональные формы, такие как полиномиальные, логарифмические или экспоненциальные модели.

Оценка параметров модели

После выбора функциональной формы модели, необходимо оценить значения коэффициентов, которые определяют вклад каждой независимой переменной в зависимую переменную. Для этого используется метод наименьших квадратов или другие методы оценки параметров.

Проверка значимости модели. После оценки параметров модели, необходимо проверить ее значимость и адекватность. Для этого используются различные статистические тесты, такие как t-тесты, F-тесты или коэффициент детерминации.

Интерпретация результатов. Последний шаг в построении регрессионной модели – это интерпретация результатов. Это включает в себя анализ значимости и влияния каждой

независимой переменной на зависимую переменную, а также оценку точности и предсказательной способности модели.

Оценка качества модели. Оценка качества модели является важным шагом в регрессионном анализе. Она позволяет определить, насколько хорошо модель соответствует данным и насколько точно она может предсказывать значения зависимой переменной.

Сумма квадратов остатков (SSE). Одним из показателей качества модели является сумма квадратов остатков (SSE). Остатки – это разница между фактическими значениями зависимой переменной и предсказанными значениями, полученными с помощью модели. SSE представляет собой сумму квадратов всех остатков и показывает, насколько хорошо модель соответствует данным. Чем меньше значение SSE, тем лучше модель.

Среднеквадратическая ошибка (MSE) – это среднее значение квадратов остатков. Она вычисляется путем деления SSE на количество наблюдений. MSE также показывает, насколько хорошо модель соответствует данным, но в отличие от SSE, она учитывает размер выборки. Чем меньше значение MSE, тем лучше модель.

Коэффициент детерминации (R-квадрат) – это показатель, который показывает, насколько хорошо модель объясняет изменчивость зависимой переменной. Он принимает значения от 0 до 1, где 0 означает, что модель не объясняет никакой изменчивости, а 1 означает, что модель объясняет всю изменчивость. R-квадрат можно интерпретировать как процент изменчивости зависимой переменной, который объясняется моделью. Чем ближе значение R-квадрат к 1, тем лучше модель.


Другие показатели качества модели. Кроме вышеперечисленных показателей, существуют и другие показатели качества модели, такие как корень из среднеквадратической ошибки (RMSE), коэффициент детерминации скорректированный на количество независимых переменных (R-квадрат скорректированный) и другие. Все эти показатели помогают оценить качество модели и выбрать наиболее подходящую для конкретной задачи.

Интерпретация результатов регрессии

После построения регрессионной модели и получения результатов, необходимо проанализировать и интерпретировать эти результаты. Интерпретация результатов регрессии позволяет понять, какие факторы оказывают значимое влияние на зависимую переменную и какая форма зависимости между ними.

Коэффициенты корреляции

Коэффициент корреляции (чаще всего под ним подразумевают коэффициент Пирсона) — это число в диапазоне от -1 до 1 . Чем ближе коэффициент к 1 , тем сильнее положительная связь между двумя переменными. Коэффициент корреляции $= 1$ означает, что изменению одной переменной соответствует такое же изменение другой. Если коэффициент получается отрицательным, это означает обратную взаимосвязь: то есть при увеличении одной переменной, другая уменьшается. Близкая к нулю корреляция показывает, что статистически значимая взаимосвязь между двумя переменными отсутствует. Корреляция бывает:



Коэффициенты регрессии. Один из основных инструментов для интерпретации результатов регрессии – это коэффициенты регрессии. Каждый коэффициент соответствует одной независимой переменной и показывает, насколько изменится зависимая переменная при изменении соответствующей независимой переменной на одну единицу, при условии, что все остальные переменные остаются постоянными.

Например, если у нас есть регрессионная модель, которая предсказывает зарплату (зависимая переменная) на основе образования (независимая переменная), и коэффициент регрессии для образования равен 0.05, то это означает, что при увеличении образования на одну единицу (например, на один год обучения), зарплата увеличится в среднем на 0.05 единицы, при условии, что все остальные факторы остаются неизменными.

Статистическая значимость коэффициентов. Помимо значения коэффициентов регрессии, также важно оценить их статистическую значимость. Для этого используется t-статистика и соответствующие p-значения. Если p-значение меньше заданного уровня значимости (обычно 0.05), то можно считать, что коэффициент статистически значимо отличается от нуля, и его влияние на зависимую переменную является значимым.

Направление и сила влияния. Интерпретация результатов регрессии также позволяет определить направление и силу влияния независимых переменных на зависимую переменную. Если коэффициент регрессии положительный, то увеличение значения независимой переменной будет сопровождаться увеличением значения зависимой переменной. Если коэффициент регрессии отрицательный, то увеличение значения независимой переменной будет сопровождаться уменьшением значения зависимой переменной. Силу влияния можно оценить по значению коэффициента регрессии. Чем больше абсолютное значение коэффициента, тем сильнее влияние независимой переменной на зависимую переменную.

Задание на лабораторную работу:

Необходимо решить задачу регрессии - предсказания непрерывного значения целевой переменной на основе набора данных согласно варианту.

Написать код для решения задачи регрессии:

1. Подключить необходимые библиотеки и провести загрузку набора данных.

2. Провести предварительный анализ и подготовку данных:

2.1. Получение описательной статистики: количество наблюдений (count), среднее арифметическое (mean), среднее квадратическое отклонение (std), минимальное (min)

- и максимальное (max) значения, а также первый (25%), второй (50%) и третий (75%) квартиль каждой количественной переменной.
- 2.2. Подсчет количества пропусков в данных.
 - 2.3. Определение взаимосвязи между признаками с помощью коэффициента корреляции.
 - 2.4. Визуализация пар признаков.
- 3. Отбор и выделение признаков.
 - 4. Построение модели регрессии.
 - 4.1 Разбиение на тестовое и обучающее множество.
 - 4.2 Создание модели регрессии.
 - 4.3. Обучение модели регрессии.
 - 4.4. Предсказание целевой переменной.
 - 4.5. Оценка качества модели с использованием метрик среднеквадратической ошибки и коэффициента детерминации.
 - 5. Проанализировать полученные результаты и сделать выводы.

Пример решения задачи:

Необходимо решить задачу регрессии - предсказания непрерывного значения признака - цены на недвижимость на основе набора данных об объектах недвижимости города Бостона (Boston Housing). Набор данных - файл boston.csv

ОПИСАНИЕ НАБОРА ДАННЫХ

1. **CRIM** - Уровень преступности на душу населения в разбивке по районам
2. **ZN** - Доля земель под жилую застройку, разделенных на участки площадью более 25 000 кв. футов.
3. **INDUS** - Доля акров, не связанных с розничной торговлей, в промышленности на город
4. **CHAS** - Фиктивная переменная CHAS Charles River (= 1, если тракт граничит с рекой; 0 в противном случае)
5. **NOX** - Концентрация оксидов азота NOX (частей на 10 миллионов)
6. **RM** - Среднее количество комнат в жилом помещении
7. **AGE** - Доля занимаемых владельцами квартир, построенных до 1940 года
8. **DIS** - Взвешенные расстояния до пяти бостонских центров занятости
9. **RAD** - Индекс доступности радиальных магистралей RAD
10. **TAX** - Налог на недвижимость с полной стоимостью - ставка налога на 10 000 долларов США
11. **PTRATIO** - Соотношение учащихся и учителей по городам
12. **BLSK** - $1000(B_k - 0,63)^2$, где B_k - доля афроамериканцев в разбивке по городам
13. **LSTAT** - % более низкого статуса населения
14. **MEDV** - Медианная стоимость домов, занимаемых владельцами, в 1000 долларов
- **Целевая переменная**

Пример кода приведен в блокноте BostonDS_Lin_Reg.jpynb.