

Модуль 1. Основы Машинного обучения.

Контрольные вопросы к лабораторным работам.

ЛАБОРАТОРНАЯ РАБОТА 1. СБОР ДАННЫХ ДЛЯ МАШИННОГО ОБУЧЕНИЯ.

1. Дайте определение понятию «Открытые данные».
2. Поясните различия между агрегированными и сырыми данными.
3. Что такое набор данных?
4. Какая информация содержится в паспорте набора данных?
5. Приведите пример машиночитаемых форматов данных.
6. Какой источник открытых данных вы использовали для анализа?
7. Какие диаграммы вы использовали для визуализации данных?
8. Какие выводы по проведенному анализу открытых данных можно сделать?
9. Что такое дашборд?
10. Как загрузить данные в Yandex DataLens?
11. Как создать чарт (график)?
12. Как провести сортировку данных на графике?
13. Как создать и редактировать дашборд?
14. Как добавить график на дашборд?
15. Что такое селектор? Для чего его применяют?
16. Как предоставить публичный или приватный доступ к дашборду?
17. Определение синтетических данных.
18. В каких задачах используются синтетические данные?
19. Достоинства и недостатки синтетических данных.
20. Библиотека Faker. Области применения. Основные функции.
21. Библиотека Sklearn. Генерация данных для анализа алгоритмов машинного обучения.
22. Библиотека SDV. Генерация сложных синтетических данных.

ЛАБОРАТОРНАЯ РАБОТА 2. ПРЕДВАРИТЕЛЬНЫЙ АНАЛИЗ И ВИЗУАЛИЗАЦИЯ ДАННЫХ.

1. Какая библиотека python предназначена для управления наборами данных: numpy, pandas, sklearn, opencv, matplotlib?
2. Какая стратегия является нежелательной при обработке пропусков в данных?
 - а) замена пропущенных значений в столбце медианным значением по данному столбцу;
 - б) удаление строк, содержащих пропуски в данных;
 - в) замена пропущенных значений в столбце средним арифметическим значением по данному столбцу;
 - г) замена пропущенных значений в столбце наиболее часто встречающимся значением по данному столбцу;
3. Обоснуйте ответ на следующую проблему предварительной обработки данных: имеется независимая категориальная переменная y , которая представляет собой категориальный признак, опеределенный на домене {C#, Java, Python, R}. Нужно ли применять к данному целевому признаку кодирование OneHotEncoder?
4. С помощью какой диаграммы можно визуализировать выбросы?
5. Перечислите методы кодирования категориальных признаков.
6. В чём суть алгоритма t-sne?
7. В чём суть алгоритма UMAP?

8. Какой алгоритм нелинейного снижения размерности лучше сохраняет локальные и глобальные свойства объектов?
9. Какой алгоритм нелинейного снижения размерности лучше сохраняет глобальные свойства объектов?
10. В чём суть PCA?
11. Назовите сходства и различия между PCA и t-SNE с точки зрения: целей использования, интерпретируемости, вычислительной сложности?
12. В чём суть метода `pivot_table`?
13. Что такое таблица сопряженности?
14. Для чего применяется метод `crosstab`?
15. В чём сходство и отличие коробчатых диаграмм и скрипичных графиков?
16. Как работает функция `reset_index`?
17. Что показывает тепловая карта?
18. О чём говорят отрицательные и положительные числа в тепловой карте?
19. Что показывают асимметрия и эксцесс?
20. Назовите метрики центральной тенденции и вариабельности.