

Модуль 2. Классическое машинное обучение.

Контрольные вопросы к лабораторным работам.

ЛАБОРАТОРНАЯ РАБОТА 3. МЕТОДЫ РЕГРЕССИИ.

1. Что такое регрессионный анализ и в каких задачах он применяется?
2. Какие этапы предобработки данных необходимы перед обучением регрессионной модели?
3. Какие диаграммы используются для визуализации зависимостей признаков?
4. Какова базовая модель простой линейной регрессии? Опишите основные компоненты уравнения.
5. Объясните разницу между простой и множественной линейной регрессией. Какие особенности возникают при использовании нескольких предикторов?
6. Что такое корреляция? Какие виды корреляции бывают?
7. Какие метрики оценки качества регрессионных моделей вы использовали?
8. Что такое критерий R^2 (коэффициент детерминации)? Как он используется для оценки качества модели?
9. В чем заключается суть полиномиальной регрессии и при каких условиях ее использование обосновано?
10. Какая библиотека Python используется для реализации методов регрессии?
11. Что такое переобучение и недообучение в контексте регрессии? Как их диагностировать по кривым обучения?
12. Опишите методы регуляризации: Ridge (L2), Lasso (L1), Elastic Net. В чём принципиальное различие между L1 и L2 регуляризацией?
13. Что такое кросс-валидация и как её использовать для подбора гиперпараметров?
14. Блок 4: Расширения линейной регрессии
15. Что такое полиномиальная регрессия? Является ли она линейной моделью? Обоснуйте ответ.
16. Опишите идею логистической регрессии. Почему она относится к регрессионным моделям, хотя решает задачу классификации?
17. Опишите принцип работы регрессии на основе деревьев решений. Как принимается решение о разбиении узла в задаче регрессии?
18. В чём заключается идея ансамблевых методов (Random Forest, Gradient Boosting) для задачи регрессии? Приведите примеры библиотек.
19. Что такое SVR (Support Vector Regression)?
20. Приведите пример реальной задачи, где применение регрессионного анализа будет наиболее уместно, и обоснуйте свой выбор.

ЛАБОРАТОРНАЯ РАБОТА 4. МЕТОДЫ КЛАССИФИКАЦИИ.

1. Что понимается под задачей классификации, и чем она принципиально отличается от задачи регрессии?
2. Перечислите основные методы классификации и кратко охарактеризуйте каждый из них.
3. Приведите примеры задач классификации (бинарной и многоклассовой).
4. Какие типы обучения используются в задачах классификации?
5. Нарисуйте матрицу ошибок для бинарной классификации. Обозначьте: TP, TN, FP, FN.

6. Что такое точность (Accuracy)? В каких задачах она может быть обманчива (проблема несбалансированных данных)?
7. Определите Precision, Recall, F1-score. Как они связаны с понятиями «ложноположительное» и «ложноотрицательное» срабатывания?
8. В чем принцип построения и работы дерева решений? Какие критерии используются для разделения узлов?
9. В чём суть андерсэмплинга? Приведите примеры алгоритмов андерсэмплинга.
10. В чём суть оверсэмплинга? Приведите примеры алгоритмов андерсэмплинга.
11. Как работает алгоритм SMOTE.
12. В чём различие между собой граничных версий алгоритма SMOTE?
13. В чём отличие граничных версий алгоритма SMOTE от базового алгоритма?
14. Какой алгоритм оверсэмплинга не добавляет новую информацию в набор данных и почему?
15. Как работают гибридные алгоритмы оверсэмплинга?
16. Восстановление баланса классов должно применяться ко всему набору данных, к тестовой выборке или к обучающей выборке?
17. Как влияет выбор функции ядра в SVM на способность модели аппроксимировать сложные зависимости?
18. В каком алгоритме классификации используются информационная энтропия и индекс Джини?
19. Какой алгоритм классификации не требует масштабирования признаков?
20. Какой классификатор называется метрическим?
21. Какую метрику качества классификации следует использовать в случае несбалансированного набора данных?
22. При каком соотношении классов применение алгоритмов балансировки классов является обязательным?
23. Что такое опорный вектор? В каком алгоритме он присутствует?
24. Хорошо ли, если число опорных векторов примерно равно числу примеров в обучающей выборке?

ЛАБОРАТОРНАЯ РАБОТА 5. Кластерный анализ.

1. Что такое кластерный анализ? Какова его цель?
2. В чем разница между кластеризацией и классификацией?
3. Опишите процесс подготовки данных для кластерного анализа. Какие шаги необходимо выполнить?
4. Почему нормализация (стандартизация) данных важна для большинства алгоритмов кластеризации?
5. Какие методы преобразования категориальных переменных используются перед кластеризацией?
6. Какие меры расстояния используются в кластерном анализе, и как выбор метрики влияет на результаты?
7. Что такое матрица различия? Матрица сходства?
8. Как определить оптимальное число кластеров K для алгоритма K-means?
9. Опишите принцип агломеративной иерархической кластеризации.
10. Как построить дендрограмму? Как определить число кластеров на дендрограмме?
11. Как интерпретировать дендрограмму в иерархическом кластерном анализе?
12. Что такое метод DBSCAN? В чём его преимущества перед методом k-средних?

13. Как метод DBSCAN определяет выбросы и кластеры?
14. Что такое Silhouette Score? Как он используется в кластерном анализе?
15. Опишите процесс подготовки данных для кластерного анализа. Какие шаги необходимо выполнить?
16. Как влияет выбор метрики расстояния на результаты кластерного анализа?
17. В каких случаях применение кластерного анализа может быть нецелесообразно? Приведите примеры.
18. Как оценить качество кластеризации? Перечислите основные метрики и методы оценки.
19. Как можно визуализировать результаты кластерного анализа? Перечислите и кратко опишите методы визуализации.
20. Как осуществить выбор между различными алгоритмами кластеризации на основе специфики данных и задачи?
21. Приведите примеры практических задач, где кластерный анализ играет ключевую роль.