

ПЕРЕЧЕНЬ ТЕСТОВ к МОДУЛЮ 1 «ОСНОВЫ МАШИННОГО ОБУЧЕНИЯ»**Индикатор ML-2.1*****Тестовые вопросы закрытого типа***

1. К какому типу задач машинного обучения относится прогнозирование стоимости акций?

а) Регрессия

б) Классификация

в) Кластеризация

г) Обучение с подкреплением

2. Какой алгоритм не используется для задач классификации?

а) Линейная регрессия

б) Метод опорных векторов (SVM)

в) Дерево решений

г) Логистическая регрессия

3. Что такое переобучение (overfitting) модели?

а) Когда модель слишком хорошо подстраивается под обучающие данные и плохо работает на новых данных

б) Когда модель недостаточно обучается на данных

в) Когда модель работает одинаково хорошо на всех данных

г) Когда модель случайным образом угадывает ответы

4. Какой метод используется для борьбы с переобучением?

а) Регуляризация

б) Увеличение сложности модели

в) Уменьшение размера обучающей выборки

г) Удаление признаков из модели

5. Какая метрика не используется для оценки регрессионных моделей?

а) Accuracy

б) MAE (Mean Absolute Error)

в) MSE (Mean Squared Error)

г) R-квадрат (R^2)

6. Что такое кросс-валидация?

а) Метод оценки качества модели на разных подвыборках данных

б) Метод увеличения объема данных

в) Метод уменьшения размерности данных

г) Метод визуализации данных

7. Какой алгоритм относится к обучению без учителя?

а) K-means

б) Линейная регрессия

- в) Метод k-ближайших соседей
- г) Дерево решений

8. Что такое One-Hot Encoding?

- а) Преобразование категориальных признаков в бинарные векторы**
- б) Нормализация числовых признаков
- в) Удаление пропущенных значений
- г) Создание новых признаков

9. Какая задача решается в обучении с подкреплением?

- а) Агент учится принимать решения через взаимодействие со средой**
- б) Классификация объектов по размеченным данным
- в) Прогнозирование числовых значений
- г) Разделение данных на кластеры

10. Что такое нормализация данных?

- а) Приведение признаков к одинаковому масштабу**
- б) Удаление выбросов из данных
- в) Заполнение пропущенных значений
- г) Создание новых признаков

11. Какая метрика наиболее полезна при несбалансированных классах?

- а) F1-мера**
- б) Ассигасу
- в) R^2
- г) MSE

12. Что такое ансамблирование в машинном обучении?

- а) Объединение нескольких моделей для улучшения прогноза**
- б) Увеличение объема обучающих данных
- в) Уменьшение сложности модели
- г) Визуализация результатов модели

13. Какой алгоритм основан на идее «разделяй и властвуй»?

- а) Дерево решений**
- б) Линейная регрессия
- в) K-means
- г) Метод опорных векторов

14. Что такое Grid Search?

- а) Метод подбора оптимальных гиперпараметров модели**
- б) Метод визуализации данных
- в) Метод уменьшения размерности

г) Метод обработки пропущенных значений

15. Какая задача относится к многоклассовой классификации?

а) Распознавание цифр на изображениях (0-9)

б) Прогнозирование температуры воздуха

в) Определение спам/не спам

г) Сегментация клиентов по 2 группам

16. Что такое feature importance?

а) Оценка важности признаков для модели

б) Количество признаков в данных

в) Качество признаков

г) Скорость вычисления признаков

17. Какой метод не используется для понижения размерности?

а) Линейная регрессия

б) PCA (Principal Component Analysis)

в) t-SNE

г) UMAP

18. Что такое Confusion Matrix?

а) Матрица для оценки качества классификации

б) Метод обработки изображений

в) Алгоритм кластеризации

г) Метод регуляризации

19. Какая проблема решается с помощью SMOTE?

а) Несбалансированность классов

б) Пропущенные значения

в) Выбросы в данных

г) Высокая размерность данных

20. Что такое transfer learning?

а) Использование предобученной модели для решения новой задачи

б) Передача данных между серверами

в) Обмен моделями между исследователями

г) Конвертация форматов данных

Тестовые вопросы открытого типа

1. Тип машинного обучения, где каждому объекту в обучающей выборке соответствует правильный ответ, называется обучение [Ответ: с учителем (supervised)].

2. Задача прогнозирования непрерывной числовой величины называется [Ответ: регрессия].

3. Алгоритм, разделяющий данные на группы по схожести без использования размеченных примеров, решает задачу [**Ответ: кластеризации**].
4. Метрика, используемая для оценки моделей классификации при несбалансированных классах, называется [**Ответ: F1**]-мера.
5. Процесс преобразования категориальных признаков в числовые называется [**Ответ: one-hot**] кодирование.
6. Тип обучения, при котором агент учится на основе взаимодействия со средой, называется обучение [**Ответ: с подкреплением (reinforcement)**].
7. Задача, в которой требуется определить принадлежность объекта к одному из двух классов, называется [**Ответ: бинарная**] классификация.
8. Метод борьбы с переобучением, добавляющий штраф за сложность модели, называется [**Ответ: регуляризация**].
9. Алгоритм, основанный на построении древовидной структуры решений, называется дерево [**Ответ: решений**].
10. Процесс приведения числовых признаков к одинаковому масштабу называется [**Ответ: нормализация (стандартизация)**].
11. Тип задачи, где требуется найти аномальные объекты в данных, называется [**Ответ: обнаружение аномалий (outlier detection)**].
12. Метрика, показывающая долю верно предсказанных положительных классов среди всех объектов, предсказанных как положительные, называется [**Ответ: precision (точность)**].
13. Алгоритм, основанный на вычислении расстояний между объектами, называется метод [**Ответ: k ближайших (k-nearest)**] соседей.
14. Задача уменьшения размерности пространства признаков при сохранении максимальной информации называется [**Ответ: метод главных компонент.**]
15. Процесс создания новых признаков на основе существующих называется [**Ответ: признаковый инжиниринг (feature engineering)**].

16. Метод объединения нескольких моделей для улучшения предсказаний называется [**Ответ: ансамблирование (ensemble)**].

17. Тип классификации, где объект может принадлежать одновременно к нескольким классам, называется [**Ответ: многоклассовая**] классификация.

18. График, показывающий зависимость ошибки модели от объема обучающей выборки, называется [**Ответ: learning curve (кривая обучения)**].

19. Алгоритм, основанный на построении разделяющей гиперплоскости, называется метод [**Ответ: опорных векторов (SVM)**].

20. Процесс разделения данных на обучающую и тестовую выборки называется [**Ответ: hold-out (отложенная)**] выборка.

Индикатор ML-2.2

Тестовые вопросы закрытого типа

1. Какой метод используется для обработки пропущенных значений в числовых данных?

- а) Заполнение средним или медианным значением**
- б) Удаление всех строк с пропусками
- в) Замена пропусков случайными числами
- г) Игнорирование проблемы пропусков

2. Что такое One-Hot Encoding?

- а) Преобразование категориальных переменных в бинарные векторы**
- б) Нормализация числовых данных
- в) Удаление выбросов
- г) Создание полиномиальных признаков

3. Какой метод не является методом нормализации данных?

- а) Удаление стоп-слов из текста**
- б) Min-Max Scaling
- в) Standard Scaling
- г) Robust Scaling

4. Для чего используется метод PCA (Principal Component Analysis)?

- а) Уменьшение размерности данных**
- б) Увеличение объема данных
- в) Создание новых категориальных признаков
- г) Удаление всех числовых признаков

5. Что такое Feature Scaling?

а) Приведение признаков к одинаковому масштабу

б) Увеличение количества признаков

в) Удаление некорректных признаков

г) Изменение формата данных

6. Какой метод используется для обработки выбросов в данных?

а) Winsorization или использование IQR

б) Удаление всех данных

в) Замена выбросов нулевыми значениями

г) Игнорирование выбросов

7. Что такое TF-IDF?

а) Метод векторизации текстовых данных

б) Алгоритм кластеризации

в) Метод визуализации данных

г) Алгоритм классификации

8. Какой метод не используется для создания новых признаков?

а) Удаление всех существующих признаков

б) Полиномиальные преобразования

в) Создание взаимодействий между признаками

г) Извлечение признаков из даты/времени

9. Что такое Label Encoding?

а) Преобразование категориальных значений в числовые коды

б) Нормализация числовых данных

в) Удаление пропущенных значений

г) Создание бинарных признаков

10. Для чего используется метод SMOTE?

а) Балансировка несбалансированных классов

б) Увеличение скорости работы алгоритмов

в) Уменьшение размера данных

г) Удаление шума из данных

11. Что такое Cross-Validation?

а) Метод оценки устойчивости модели на разных подвыборках

б) Метод увеличения объема данных

в) Метод удаления признаков

г) Метод визуализации данных

12. Какой метод используется для отбора наиболее важных признаков?

а) Recursive Feature Elimination

- б) Удаление случайных признаков
- в) Сохранение всех признаков без изменений
- г) Удаление только числовых признаков

13. Что такое Data Augmentation?

- а) Увеличение объема данных через преобразования**
- б) Уменьшение объема данных
- в) Удаление части данных
- г) Изменение формата хранения данных

14. Какой метод используется для обработки текстовых данных?

- а) Токенизация и лемматизация**
- б) Удаление всех текстовых данных
- в) Преобразование текста в изображение
- г) Случайное перемешивание слов

15. Что такое Feature Engineering?

- а) Создание новых признаков на основе существующих**
- б) Удаление всех признаков
- в) Копирование существующих признаков
- г) Изменение имен признаков

16. Какой метод используется для обработки временных рядов?

- а) Создание лаговых признаков**
- б) Удаление временных меток
- в) Случайное перемешивание данных
- г) Преобразование в категориальные данные

17. Что такое Binning?

- а) Дискретизация непрерывных переменных**
- б) Удаление переменных
- в) Создание новых переменных
- г) Изменение типа данных

18. Какой метод не является методом обработки категориальных данных?

- а) Min-Max Scaling**
- б) One-Hot Encoding
- в) Target Encoding
- г) Label Encoding

19. Что такое Pipeline в контексте предобработки данных?

- а) Последовательность шагов обработки данных**
- б) Способ хранения данных
- в) Метод визуализации данных

г) Алгоритм машинного обучения

20. Для чего используется метод Z-score нормализации?

- а) Приведение данных к распределению с $\text{mean}=0$ и $\text{std}=1$
- б) Увеличение объема данных
- в) Удаление выбросов
- г) Создание новых признаков

Тестовые вопросы открытого типа

1. Процесс преобразования категориальных переменных в бинарные векторы называется [Ответ: **one-hot**] кодирование.

2. Метод приведения числовых признаков к диапазону $[0, 1]$ называется [Ответ: **min-max**] масштабирование.

3. Техника уменьшения размерности данных при сохранении максимальной дисперсии называется [Ответ: **метод главных**] компонент.

4. Процесс обработки текстовых данных путем приведения слов к их начальной форме называется [Ответ: **лемматизация**].

5. Метод заполнения пропущенных значений с использованием соседних наблюдений называется [Ответ: **K-ближайших соседей (KNN)**] импутация.

6. Техника создания новых признаков на основе существующих называется [Ответ: **признаковый инжиниринг (feature engineering)**].

7. Метод обработки выбросов, ограничивающий крайние значения, называется [Ответ: **винзоризация (winsorization)**].

8. Процесс преобразования категориальных значений в числовые коды называется [Ответ: **label**] кодирование.

9. Метод векторизации текстовых данных, учитывающий важность слов в документах, называется [Ответ: **TF-IDF**].

10. Техника балансировки классов через генерацию синтетических примеров называется [Ответ: **SMOTE**].
11. Процесс разделения непрерывной переменной на интервалы называется [Ответ: **биннинг (дискретизация)**].
12. Метод отбора признаков на основе их важности для модели называется [Ответ: **рекурсивный отбор (recursive feature elimination)**].
13. Техника обработки временных рядов через создание сдвинутых значений называется [Ответ: **лаговые**] признаки.
14. Метод нормализации, приводящий данные к распределению со средним 0 и стандартным отклонением 1, называется [Ответ: **Z-score (стандартная)**] нормализация.
15. Процесс автоматического применения последовательности шагов предобработки называется [Ответ: **pipeline (конвейер)**].
16. Метод кодирования категориальных переменных на основе целевой переменной называется [Ответ: **target**] кодирование.
17. Техника увеличения объема данных через преобразования называется [Ответ: **аугментация**] данных.
18. Процесс извлечения числовых признаков из даты и времени называется [Ответ: **временной**] инжиниринг.
19. Метод обработки текста путем разбиения на отдельные слова называется [Ответ: **токенизация**].
20. Техника отбора признаков на основе статистических тестов называется [Ответ: **фильтровый (univariate)**] отбор.

Индикатор BD-1.3

Тестовые вопросы закрытого типа

1. Какое требование к данным является наиболее критичным для обучения модели с учителем?
- а) **Наличие целевой переменной (разметки)**
 - б) Большой объем данных
 - в) Высокая размерность признаков
 - г) Красивая визуализация данных

2. При оценке качества данных в первую очередь следует проверять:

- а) Соответствие данных заявленным требованиям и наличие необходимых признаков**
- б) Скорость загрузки данных в систему
- в) Цветовую схему визуализаций
- г) Совместимость с предыдущими версиями формата

3. Что означает требование репрезентативности данных?

- а) Данные должны равномерно представлять все категории и сценарии, которые встретятся при работе модели**
- б) Данные должны быть представлены в удобном для просмотра формате
- в) Данные должны занимать минимальный объем памяти
- г) Данные должны обрабатываться максимально быстро

4. Какой метод не подходит для оценки качества разметки данных?

- а) Расчет коэффициента согласия между несколькими экспертами
- б) Проверка на соответствие данных бизнес-правилам
- в) Случайное удаление части разметки для ускорения процесса**
- г) Анализ распределения целевой переменной на предмет сбалансированности

5. Что такое «data leakage» в контексте машинного обучения?

- а) Использование при обучении информации, которая не будет доступна в момент прогнозирования**
- б) Потеря данных из-за сбоя в системе хранения
- в) Неправомерный доступ третьих лиц к данным
- г) Случайное удаление части данных в процессе обработки

6. Какой объем данных обычно требуется для обучения сложной модели?

- а) Чем сложнее модель, тем больше данных требуется для предотвращения переобучения**
- б) Объем данных не зависит от сложности модели
- в) Сложные модели требуют меньше данных благодаря своей гибкости
- г) Достаточно 100 примеров для любой модели

7. Что означает требование целостности (consistency) данных?

- а) Отсутствие противоречий в данных и соответствие бизнес-правилам**
- б) Все данные хранятся в одном файле
- в) Данные имеют одинаковый размер записей
- г) Все данные получены из одного источника

8. Какой подход наиболее эффективен для работы с несбалансированными данными?

- а) Стратифицированное разбиение на выборки и использование специальных методов (взвешивание классов, аугментация)**
- б) Удаление примеров из мажоритарного класса до достижения баланса
- в) Игнорирование проблемы несбалансированности

г) Использование только самых частых классов

9. Что такое «аугментация данных»?

- а) **Искусственное увеличение объема данных путем их преобразования**
- б) Удаление шумных данных из набора
- в) Сжатие данных для экономии места
- г) Автоматическая разметка неразмеченных данных

10. Какой критерий не является важным при определении требований к качеству данных?

- а) **Цветовая гамма визуализации распределений признаков**
- б) Процент пропущенных значений
- в) Наличие выбросов и аномалий
- г) Сбалансированность классов

11. Что означает требование своевременности данных?

- а) **Данные должны быть актуальными на момент их использования**
- б) Данные должны обрабатываться в реальном времени
- в) Данные должны быть доставлены к определенному сроку
- г) Данные должны обновляться каждую секунду

12. Какой метод не используется для обработки пропущенных значений?

- а) Удаление всех строк с пропусками
- б) Замена пропусков средним/медианным значением
- в) Использование алгоритмов, устойчивых к пропускам
- г) **Замена всех пропусков нулевыми значениями без анализа**

13. Что такое «стратифицированное разбиение» данных?

- а) **Разбиение, сохраняющее распределение целевой переменной в разных выборках**
- б) Разбиение данных по временным меткам
- в) Случайное перемешивание и разбиение данных
- г) Разбиение данных по алфавитному порядку

14. Какой показатель не используется для оценки качества данных?

- а) **Точность предсказаний будущей модели**
- б) Процент пропущенных значений
- в) Количество противоречий в данных
- г) Степень сбалансированности классов

15. Что означает требование полноты данных?

- а) **Наличие всех необходимых признаков и записей для решения задачи**
- б) Все данные должны быть в числовом формате
- в) Данные должны занимать весь отведенный объем памяти
- г) Все данные должны быть получены из одного источника

16. При проведении разведочного анализа данных (EDA) была выдвинута гипотеза, что между доходом клиента и вероятностью одобрения кредита существует нелинейная зависимость. Какой метод визуализации позволит наиболее эффективно проверить эту гипотезу по сравнению с построением гистограммы каждого признака по отдельности?

- а) Построение корреляционной матрицы (heatmap)
- б) Построение диаграммы рассеяния (scatter plot) между доходом и вероятностью одобрения**
- в) Построение ящика с усами (box plot) для дохода
- г) Построение круговой диаграммы (pie chart) распределения одобрений

17. При работе с данными о клиентах банка была выдвинута гипотеза, что у некоторых клиентов возраст и стаж работы противоречат друг другу (например, стаж больше возраста). Какой тип контроля данных необходимо применить для проверки этой гипотезы?

- а) Логический контроль данных**
- б) Форматный контроль данных
- в) Контроль целостности ссылок
- г) Статистический контроль данных

18. Какой метод не подходит для работы с категориальными признаками?

- а) One-hot encoding
- б) Label encoding
- в) Target encoding
- г) Удаление всех категориальных признаков**

19. Что означает требование согласованности данных?

- а) Отсутствие противоречий между связанными данными**
- б) Все данные имеют одинаковый формат
- в) Данные поступают с постоянной скоростью
- г) Все данные обрабатываются одним алгоритмом

20. Какой критерий является наиболее важным при определении требований к данным для временных рядов?

- а) Наличие временных меток и отсутствие разрывов в последовательностях**
- б) Красивые графики временных рядов
- в) Равномерное распределение значений
- г) Минимальный объем данных

Тестовые вопросы открытого типа

1. Минимальное количество данных, необходимое для построения качественной модели, зависит от [**Ответ: сложности (размерности)**] задачи и сложности модели.

2. Процесс проверки данных на пропуски, аномалии и противоречия называется [**Ответ: валидация (верификация)**] данных.
3. Показатель, измеряющий процент пропущенных значений в наборе данных, называется [**Ответ: доля (процент)**] пропусков.
4. Разметка данных для обучения модели с учителем называется [**Ответ: ручная (экспертная)**] разметка.
5. Требование к данным, означающее, что они должны равномерно представлять все категории целевой переменной, называется [**Ответ: сбалансированность (репрезентативность)**].
6. Метод оценки качества разметки данных несколькими экспертами называется [**Ответ: коэффициент (метрика)**] согласия.
7. Процесс преобразования данных в формат, пригодный для машинного обучения, называется [**Ответ: предобработка (препроцессинг)**] данных.
8. Требование к данным, означающее их соответствие реальным объектам предметной области, называется [**Ответ: адекватность (релевантность)**].
9. Набор данных, используемый для финальной оценки качества модели, называется [**Ответ: тестовой (контрольной)**] выборкой.
10. Проблема, возникающая когда данные содержат информацию, которая не будет доступна в момент прогноза, называется [**Ответ: утечка данных (data leakage)**].
11. Процесс сбора дополнительных данных для улучшения сбалансированности набора называется [**Ответ: аугментация**] данных.
12. Требование к данным, означающее их непротиворечивость и отсутствие ошибок, называется [**Ответ: целостность (консистентность)**].
13. Метод оценки качества данных, основанный на статистическом анализе распределений, называется [**Ответ: разведочный (EDA)**] анализ.
14. Процесс проверки соответствия данных заданным бизнес-правилам называется [**Ответ: логический контроль**].

15. Требование к данным, означающее возможность их использования для решения конкретной задачи, называется [**Ответ: пригодность (fitness for use)**].

16. Метрика, оценивающая разнообразие данных в наборе, называется [**Ответ: семантическое (смысловое)**] разнообразие.

17. Процесс устранения дублирующих записей в наборе данных называется [**Ответ: дедупликация (deduplication)**] данных.

18. Требование к данным, означающее их актуальность на текущий момент времени, называется [**Ответ: современность (актуальность)**].

19. Процесс поиска и визуализации аномалий в данных с помощью анализа распределений и межквартильного размаха называется [**Ответ: обнаружение выбросов**].

20. Процесс первичного анализа данных, включающий расчет статистических характеристик, визуализацию распределений и проверку гипотез о структуре данных, называется [**Ответ: разведочный анализ**].

Индикатор BD-1.4

Тестовые вопросы закрытого типа

1. Какова основная цель применения методов понижения размерности при первичной интерпретации многомерных данных?

а) Увеличение точности моделей машинного обучения

б) Визуализация структуры данных в 2D или 3D пространстве при сохранении важных закономерностей

в) Ускорение работы алгоритмов кластеризации

г) Уменьшение объема хранимых данных

2. Какая проблема возникает при визуализации многомерных данных без предварительного понижения размерности?

а) Невозможность отобразить данные на плоскости без потери информации

б) Увеличение времени обработки

в) Потеря точности вычислений

г) Увеличение объема данных

3. Что такое «проклятие размерности» в контексте визуализации данных?

а) Увеличение вычислительной сложности при росте числа признаков

б) Потеря различимости между объектами в многомерном пространстве и невозможность их интерпретации

в) Увеличение числа выбросов

г) Уменьшение объема данных

4. Какой метод понижения размерности является линейным и сохраняет максимальную дисперсию данных?

а) t-SNE

б) PCA (Principal Component Analysis)

в) UMAP

г) Autoencoder

5. Что такое главные компоненты в методе PCA?

а) Исходные признаки, выбранные по важности

б) Новые признаки, являющиеся линейными комбинациями исходных и упорядоченные по объясненной дисперсии

в) Случайно выбранные признаки

г) Признаки с минимальной дисперсией

6. Как интерпретируется первая главная компонента в PCA?

а) Направление в пространстве признаков, вдоль которого дисперсия данных максимальна

б) Направление, вдоль которого дисперсия минимальна

в) Среднее значение всех признаков

г) Медианное значение всех признаков

7. Какой метод используется для выбора оптимального числа главных компонент в PCA?

а) Метод локтя на графике объясненной дисперсии

б) Метод силуэта

в) Кросс-валидация

г) Grid Search

8. В чем преимущество метода PCA перед нелинейными методами понижения размерности (t-SNE, UMAP) при первичной интерпретации данных?

а) PCA всегда дает лучшее качество визуализации

б) PCA является линейным и интерпретируемым, позволяет понять вклад каждого исходного признака, а полученные компоненты могут использоваться как новые признаки для обучения моделей

в) PCA работает быстрее на любых данных

г) PCA не требует нормализации данных

9. Какой метод понижения размерности использует распределение Стьюдента в низкоразмерном пространстве и оптимизирует расхождение Кульбака-Лейблера?

а) PCA

б) t-SNE

- в) UMAP
- г) LDA

10. В чем ключевое преимущество UMAP перед t-SNE при визуализации больших наборов данных?

- а) UMAP сохраняет только локальную структуру
- б) UMAP быстрее работает на больших данных и лучше сохраняет глобальную структуру, что позволяет использовать полученные низкоразмерные представления как признаки для других моделей**
- в) UMAP не требует настройки гиперпараметров
- г) UMAP работает только с категориальными данными

11. Какой параметр в t-SNE отвечает за баланс между сохранением локальной и глобальной структуры данных?

- а) n_components
- б) perplexity**
- в) learning_rate
- г) random_state

12. Почему методы t-SNE и UMAP не рекомендуется использовать для получения новых признаков для моделей машинного обучения?

- а) Они слишком медленные
- б) Они не имеют детерминированного и обратного преобразования, что делает невозможным применение полученного представления к новым данным**
- в) Они не работают с категориальными данными
- г) Они не сохраняют дисперсию данных

13. Что такое «эффект скученности» в t-SNE и как его решает UMAP?

- а) Проблема, при которой точки скапливаются в центре — UMAP решает её за счет использования теории нечетких множеств и лучшего сохранения глобальной структуры**
- б) Проблема медленной работы — UMAP использует случайную инициализацию
- в) Проблема переобучения — UMAP использует регуляризацию
- г) Проблема интерпретации — UMAP использует линейные комбинации

14. Какой метод понижения размерности следует выбрать для визуализации данных с сильно нелинейной структурой и небольшим количеством объектов (< 5000)?

- а) PCA
- б) t-SNE или UMAP**
- в) LDA
- г) Факторный анализ

15. Какой метод понижения размерности является дискриминантным и учитывает метки классов?

- а) PCA
- б) t-SNE**

в) LDA (Linear Discriminant Analysis)

г) UMAP

Ответ: в)

16. При работе с данными, содержащими большое количество шума и выбросов, какой метод понижения размерности будет более устойчивым и позволит получить надежные признаки для дальнейшего использования по сравнению с t-SNE и UMAP?

а) t-SNE

б) UMAP

в) RASMAP

г) TRIMAP

17. В чем отличие факторного анализа (Factor Analysis) от PCA?

а) Факторный анализ предполагает наличие латентных переменных и учитывает ошибки измерения, а PCA — простое проецирование на направления максимальной дисперсии

б) Факторный анализ является нелинейным методом

в) PCA всегда дает лучшее качество

г) Факторный анализ не требует нормализации

18. Как использование методов понижения размерности влияет на время разработки моделей машинного обучения?

а) Увеличивает время обучения из-за дополнительных вычислений

б) Сокращает время обучения и экспериментов за счет уменьшения числа признаков, упрощения моделей и ускорения кросс-валидации

в) Не влияет на время разработки

г) Только увеличивает время на подготовку данных

19. Какие преимущества дает использование PCA для создания новых признаков по сравнению с нелинейными методами при построении моделей машинного обучения?

а) PCA дает нелинейные признаки, которые лучше разделяют классы

б) PCA позволяет получать линейные интерпретируемые признаки и имеет обратное преобразование, что упрощает применение к новым данным и сокращает время на переобучение модели

в) PCA не требует нормализации данных

г) PCA всегда работает быстрее t-SNE на любых данных

20. В каком случае использование сниженной размерности как новых признаков может сократить время разработки модели, но при этом незначительно потерять в качестве?

а) Когда исходные признаки сильно коррелированы и содержат избыточную информацию — PCA или UMAP позволяют выделить основные компоненты без значительной потери качества

б) Когда данные полностью линейно разделимы

в) Когда число объектов очень мало

г) Когда все признаки независимы и одинаково важны

Тестовые вопросы открытого типа

1. Метод понижения размерности, при котором новые признаки являются линейными комбинациями исходных и упорядочены по объясненной дисперсии, называется [**Ответ: PCA / метод главных компонент**].
2. График, показывающий долю объясненной дисперсии каждой главной компонентой в PCA, называется [**Ответ: scree plot / график каменной осыпи**].
3. Процесс центрирования и масштабирования данных перед применением PCA называется [**Ответ: стандартизация / нормализация**].
4. В методе PCA первая главная компонента направлена вдоль [**Ответ: максимальной дисперсии**].
5. Коэффициенты, показывающие вклад исходных признаков в формирование главных компонент в PCA, называются [**Ответ: нагрузки / loadings**].
6. В алгоритме t-SNE параметр perplexity определяет эффективное количество соседей для каждой точки и влияет на баланс между сохранением локальной и глобальной структуры данных. Слишком малое значение perplexity приводит к разбиению [**Ответ: на отдельные кластеры**], а слишком большое — к [**Ответ: потере локальной структуры**].
7. Метод понижения размерности, использующий распределение Стьюдента в низкоразмерном пространстве, называется [**Ответ: t-SNE**].
8. В t-SNE для измерения сходства между точками в высокоразмерном пространстве используется условное [**Ответ: распределение вероятностей**].
9. Основным преимуществом алгоритма PAMAP перед t-SNE является использование парного контроля, что позволяет лучше сохранять [**Ответ: глобальную структуру**] и обеспечивает устойчивость [**Ответ: к шуму**].
10. Метод понижения размерности, использующий теорию нечетких множеств и построение графа ближайших соседей, называется [**Ответ: UMAP**].

11. Параметр в UMAP, определяющий размер локальной окрестности и баланс между локальной и глобальной структурой, называется [**Ответ: n_neighbors**].
12. В отличие от t-SNE, алгоритм UMAP лучше сохраняет [**Ответ: глобальную структуру**], что позволяет использовать полученное представление для кластеризации и построения моделей.
13. Для визуализации многомерных данных с сохранением как локальной, так и глобальной структуры часто используют алгоритм [**Ответ: UMAP**], который строит граф ближайших соседей на основе теории нечетких множеств и оптимизирует расположение точек в низкоразмерном пространстве, сохраняя топологию исходных данных.
14. Для линейного понижения размерности с возможностью интерпретации и использования полученных признаков в моделях используется метод [**Ответ: PCA**].
15. В алгоритме PAMAP (Pairwise Controlled Manifold Approximation) для балансировки локальной и глобальной структуры данных используется [**Ответ: парный контроль**], который позволяет адаптивно регулировать влияние ближних и дальних соседей на итоговое низкоразмерное представление.
16. Для данных с известными метками классов для понижения размерности может использоваться метод [**Ответ: LDA / линейный дискриминантный анализ**].
17. Использование PCA для снижения размерности позволяет сократить время обучения модели за счет [**Ответ: уменьшения числа признаков**].
18. Перед применением PCA необходимо выполнить [**Ответ: стандартизацию / нормализацию**] признаков, чтобы избежать доминирования признаков с большими значениями.
19. Процесс выбора оптимального числа главных компонент в PCA называется [**Ответ: анализ объясненной дисперсии**].
20. В алгоритме PAMAP (Pairwise Controlled Manifold Approximation) целевая функция представляет собой комбинацию трех компонент: [**Ответ: локальная, глобальная, регуляризационная**], что позволяет балансировать сохранение локальной структуры, глобальной топологии и гладкости отображения.

Тестовые вопросы закрытого типа

1. Какова основная цель отбора признаков (feature selection) при подготовке данных для исследования?

а) Увеличение объема данных

б) Выявление наиболее информативных признаков, снижение размерности и улучшение интерпретируемости модели

в) Ускорение сбора данных

г) Увеличение числа признаков для повышения точности

2. Какая проблема возникает при использовании всех доступных признаков без их предварительного отбора?

а) Ускорение обучения модели

б) «Проклятие размерности», переобучение и ухудшение интерпретируемости результатов

в) Упрощение анализа данных

г) Снижение вычислительной сложности

3. Что такое «шумовые признаки» в контексте отбора признаков?

а) Признаки с высокой предсказательной способностью

б) Признаки, не несущие полезной информации и ухудшающие качество модели

в) Признаки с пропущенными значениями

г) Признаки с высокой корреляцией

4. Какое утверждение о релевантности признаков является верным?

а) Релевантные признаки всегда независимы друг от друга

б) Релевантные признаки вносят значимый вклад в предсказание целевой переменной и могут быть как независимыми, так и зависимыми

в) Релевантные признаки всегда имеют высокую дисперсию

г) Релевантные признаки не требуют предварительной обработки

5. Какой метод отбора признаков оценивает каждый признак независимо от других на основе статистических критериев?

а) Метод фильтрации (Filter Method)

б) Оберточный метод (Wrapper Method)

в) Встроенный метод (Embedded Method)

г) Метод главных компонент

6. Какая метрика используется в фильтровых методах для оценки взаимосвязи между признаком и целевой переменной в задачах классификации?

а) Коэффициент корреляции Пирсона

б) Взаимная информация (Mutual Information)

в) Дисперсия признака

г) Среднее значение

7. Какое преимущество имеют фильтровые методы отбора признаков перед оберточными?

а) Более высокая точность отбора

б) Высокая вычислительная эффективность и независимость от выбранного алгоритма обучения

в) Учет взаимодействий между признаками

г) Возможность работы с категориальными данными

8. Какой статистический тест используется в фильтровых методах для оценки связи между категориальным признаком и бинарной целевой переменной?

а) F-тест

б) Хи-квадрат (χ^2) тест

в) T-тест

г) Тест Шапиро-Уилка

9. В чем заключается основной принцип оберточных методов (Wrapper Methods) отбора признаков?

а) Оценка важности признаков на основе их дисперсии

б) Использование алгоритма машинного обучения для оценки качества различных подмножеств признаков

в) Встроенная регуляризация для отбора признаков

г) Анализ корреляционной матрицы

10. Какой метод является классическим примером оберточного метода отбора признаков?

а) Взаимная информация

б) Рекурсивное исключение признаков (RFE)

в) L1-регуляризация (Lasso)

г) Коэффициент корреляции

11. Каков основной недостаток оберточных методов по сравнению с фильтровыми?

а) Низкая точность отбора

б) Высокая вычислительная сложность из-за многократного обучения модели

в) Невозможность работы с большими данными

г) Отсутствие интерпретируемости

12. Какой метод отбора признаков использует жадный алгоритм для последовательного добавления или удаления признаков?

а) PCA

б) Метод фильтрации

в) Встроенный метод

г) Оберточный метод

13. При анализе важности признаков с помощью случайного леса было обнаружено, что два сильно коррелированных признака имеют низкие значения важности по отдельности, но при удалении одного из них важность другого значительно возрастает. Какое явление иллюстрирует этот эффект и как его интерпретировать при отборе признаков?

- а) Мультиколлинеарность — признаки дублируют информацию, поэтому их совместная важность распределяется между ними**
- б) Эффект усиления — коррелированные признаки усиливают друг друга
- в) Шумовой эффект — признаки не несут полезной информации
- г) Эффект подавления — один признак маскирует другой

14. Какая регуляризация используется в линейных моделях для отбора признаков путем обнуления незначимых коэффициентов?

- а) L2-регуляризация (Ridge)
- б) L1-регуляризация (Lasso)**
- в) Elastic Net
- г) Dropout

15. Какой встроенный метод отбора признаков реализован в алгоритме случайного леса (Random Forest)?

- а) Коэффициент корреляции
- б) Важность признаков на основе уменьшения примесей (Gini Importance) или ООВ-ошибки**
- в) Регуляризация L1
- г) Взаимная информация

16. В чем преимущество встроенных методов перед фильтровыми?

- а) Учет взаимодействий между признаками в процессе отбора**
- б) Более высокая скорость работы
- в) Независимость от алгоритма обучения
- г) Простота интерпретации

17. Какой метод отбора признаков рекомендуется использовать при работе с очень большими наборами данных (более 100 000 признаков)?

- а) Оберточные методы
- б) Фильтровые методы (взаимная информация, корреляция)**
- в) Встроенные методы (Lasso)
- г) Все методы одинаково эффективны

Ответ: б)

18. Как оценить стабильность результатов отбора признаков при использовании случайных алгоритмов (например, случайного леса)?

- а) Провести однократный отбор
- б) Провести многократный отбор на разных подвыборках и оценить согласованность (например, с помощью кластеризации важностей)**
- в) Использовать только фильтровые методы

г) Использовать все признаки без отбора

19. Какая проблема возникает при использовании корреляционного анализа для отбора признаков в задачах с нелинейными зависимостями?

а) Корреляция Пирсона не учитывает нелинейные связи, что может привести к отбрасыванию важных признаков

б) Корреляция всегда показывает нелинейные связи

в) Корреляция не требует нормализации данных

г) Корреляция работает только с категориальными данными

20. Почему отбор признаков является критически важным этапом при построении интерпретируемых моделей?

а) Уменьшает количество параметров модели и позволяет выявить наиболее значимые факторы, влияющие на целевую переменную

б) Увеличивает точность модели

в) Ускоряет сбор данных

г) Повышает сложность модели

Тестовые вопросы открытого типа

1. Метод отбора признаков, оценивающий каждый признак независимо на основе статистических критериев, называется [**Ответ: фильтровый метод**].

2. Метрика, измеряющая количество информации, которое признак содержит о целевой переменной, называется [**Ответ: взаимная информация**].

3. Статистический тест, используемый для оценки связи между категориальными признаками и целевой переменной, называется [**Ответ: хи-квадрат**].

4. Коэффициент, измеряющий силу линейной связи между двумя переменными, называется [**Ответ: корреляция Пирсона**].

5. Метод отбора признаков, использующий алгоритм машинного обучения для оценки качества подмножеств признаков, называется [**Ответ: оберточный метод**].

6. Алгоритм, который последовательно удаляет наименее важные признаки, переобучая модель на каждом шаге, называется [**Ответ: рекурсивное исключение признаков**].

7. Метод, при котором признаки последовательно добавляются к текущему набору, называется **[Ответ: прямой отбор]**.
8. Метод, при котором признаки последовательно удаляются из полного набора, называется **[Ответ: обратный отбор]**.
9. Метод регуляризации, обнуляющий веса незначимых признаков, называется **[Ответ: Lasso / L1-регуляризация]**.
10. Метрика важности признаков в случайном лесе, основанная на усреднении уменьшения примесей, называется **[Ответ: Gini importance]**.
11. Метод регуляризации, комбинирующий L1 и L2 штрафы, называется **[Ответ: Elastic Net]**.
12. Метод регуляризации, уменьшающий веса признаков без их обнуления, называется **[Ответ: гребневая]** регрессия.
13. Для высокоразмерных данных ($> 100\,000$ признаков) рекомендуется использовать **[Ответ: фильтровые]** методы отбора признаков.
14. Метод отбора признаков, который не требует обучения модели и оценивает каждый признак на основе статистических тестов, относится к классу **[Ответ: фильтровых]** методов.
15. Метод отбора признаков, который выполняет отбор с помощью регуляризации в процессе обучения модели, относится к классу **[Ответ: встроенных]** методов.
16. Метод, который требует многократного обучения модели, называется **[Ответ: оберточный]**.
17. Процесс удаления признаков с низкой дисперсией называется отбор **[Ответ: по дисперсии]**.
18. Проблема, при которой добавление новых признаков ухудшает качество модели из-за избыточности информации, называется **[Ответ: мультиколлинеарность]**.
19. Метод отбора признаков, использующий важность из случайного леса, относится к **[Ответ: встроенным]** методам.
20. Для отбора признаков при сильной корреляции между ними эффективно использовать метод регуляризации, который обнуляет веса неинформативных признаков. Этот метод называется **[Ответ: Lasso]**.