

ПЕРЕЧЕНЬ ТЕСТОВ К МОДУЛЮ 2 «КЛАССИЧЕСКОЕ МАШИННОЕ ОБУЧЕНИЕ»**Индикатор ML-2.3*****Тестовые вопросы закрытого типа***

1. Столкнувшись с несбалансированными классами, специалист с системным мышлением рассмотрит несколько решений (например, взвешивание объектов, SMOTE, смену метрики), потому что:

а) Не существует единственного лучшего способа решения этой проблемы.

б) Системный подход требует перепробовать все известные методы.

в) Это увеличит время работы над проектом.

г) Так рекомендует преподаватель.

2. Какая модификация логистической регрессии является наиболее эффективной для работы с сильно несбалансированными классами?

а) Увеличить количество итераций обучения.

б) Использовать регуляризацию L2.

в) Изменить порог классификации или использовать взвешивание классов.

г) Добавить полиномиальные признаки.

3. Какой подход наиболее эффективен для работы с несбалансированными данными?

а) Стратифицированное разбиение на выборки и использование специальных методов (взвешивание классов, аугментация)

б) Удаление примеров из мажоритарного класса до достижения баланса

в) Игнорирование проблемы несбалансированности

г) Использование только самых частых классов

4. Какая метрика наиболее полезна при несбалансированных классах?

а) F1-мера

б) Ассигасу

в) R^2

г) MSE

5. Какая проблема решается с помощью SMOTE?

а) Несбалансированность классов

б) Пропущенные значения

в) Выбросы в данных

г) Высокая размерность данных

6. Для чего используется метод SMOTE?

а) Балансировка несбалансированных классов

б) Увеличение скорости работы алгоритмов

- в) Уменьшение размера данных
- г) Удаление шума из данных

7. Метод автоматического выбора стратегии обработки несбалансированных данных на основе анализа распределения классов и сложности границы решений называется [Ответ: адаптивная] балансировка.

8. Какой метод теории вероятностей применяется для автоматической обработки несбалансированных данных?

- а) Байесовское взвешивание**
- б) Случайное удаление
- в) Полное сохранение данных
- г) Удаление миноритарного класса

8. Если добавление новых данных не улучшает качество модели, системный подход подсказывает, что следует:

- а) Продолжить сбор данных, так как их всегда не хватает.
- б) Проанализировать, не исчерпала ли модель информационность текущих признаков, и поискать новые источники информации.**
- в) Сделать модель еще более сложной.
- г) Сменить метрику качества на менее строгую.

9. Выбор между простой интерпретируемой моделью и сложной "черным ящиком" с чуть лучшим качеством должен определяться:

- а) Всегда нужно выбрать самую сложную модель.
- б) Требованиями задачи: нужна ли интерпретируемость для заказчика и регуляторов.**
- в) Личными предпочтениями специалиста по ML.
- г) Тем, какая модель быстрее обучается.

10. Что такое кросс-валидация?

- а) Метод оценки качества модели на разных подвыборках данных**
- б) Метод увеличения объема данных
- в) Метод уменьшения размерности данных
- г) Метод визуализации данных

11. Что такое Confusion Matrix?

- а) Матрица для оценки качества классификации**
- б) Метод обработки изображений
- в) Алгоритм кластеризации
- г) Метод регуляризации

12. Какой метод используется для оценки качества моделей классификации?

- а) **accuracy_score**
- б) mean_squared_error
- в) r2_score
- г) Все перечисленные

13. В чем основное отличие алгоритма ADASYN от классического SMOTE?

- а) ADASYN генерирует синтетические примеры только для миноритарного класса без учета плотности
- б) **ADASYN адаптивно определяет количество синтетических примеров для каждого образца в зависимости от сложности классификации**
- в) ADASYN удаляет примеры из мажоритарного класса перед генерацией синтетических данных
- г) ADASYN генерирует синтетические примеры только на основе близости к центроиду класса

14. Для чего используются алгоритмы андерсэмплинга при работе с несбалансированными данными?

- а) Для увеличения размера миноритарного класса путем создания синтетических примеров
- б) **Для уменьшения размера мажоритарного класса путем удаления части его примеров для балансировки**
- в) Для преобразования категориальных признаков в числовые
- г) Для нормализации данных перед обучением модели

15. Какая стратегия генерации синтетических примеров используется в алгоритме BORDERLINE-SMOTE?

- а) Генерация примеров только на основе случайно выбранных соседей из всего миноритарного класса
- б) **Генерация примеров только для образцов, находящихся на границе между классами (borderline примеры)**
- в) Генерация примеров равномерно по всему пространству миноритарного класса
- г) Генерация примеров только для центроидов кластеров миноритарного класса

16. В чем заключается проблема "проклятия размерности" при применении SMOTE к высокоразмерным данным?

- а) SMOTE становится слишком быстрым и не успевает обработать все данные
- б) **В высокоразмерном пространстве расстояния между точками становятся менее различимыми, что снижает качество генерации**
- в) SMOTE требует больше оперативной памяти для обработки высокоразмерных данных
- г) SMOTE не может работать с данными размерности более 100 признаков

17. Как интерпретируется значение F1-меры, близкое к 0?

- а) Модель идеально классифицирует все объекты
- б) **Модель имеет высокий дисбаланс между precision и recall (хотя бы одна из метрик близка к нулю)**
- в) Модель имеет высокие значения и precision, и recall

г) Модель показывает случайное угадывание

18. Для какой задачи предпочтительнее использовать метрику ROC-AUC вместо Accuracy?

а) Когда классы сбалансированы и стоимость ошибок равнозначна

б) Когда данные имеют сильный дисбаланс классов и важно оценить способность модели разделять классы при разных порогах

в) Когда модель используется для прогнозирования непрерывных значений

г) Когда все объекты относятся к одному классу

19. Как рассчитывается Precision для задачи бинарной классификации?

а) $TP / (TP + TN)$

б) $TP / (TP + FP)$

в) $TP / (TP + FN)$

г) $(TP + TN) / (TP + TN + FP + FN)$

20. Почему Accuracy может быть неинформативной метрикой при работе с несбалансированными данными?

а) Accuracy всегда равна 1 на несбалансированных данных

б) Accuracy не учитывает дисбаланс классов и может оставаться высокой за счет правильного предсказания мажоритарного класса, игнорируя миноритарный

в) Accuracy не работает для задач классификации

г) Accuracy рассчитывается только для регрессионных задач

Тестовые вопросы открытого типа

1. Для задачи классификации с сильно несбалансированными классами вместо Accuracy лучше использовать метрику, вычисляемую как среднее гармоническое двух других метрик **[Ответ: F1-мера]**.

2. Метрика, используемая для оценки моделей классификации при несбалансированных классах, называется **[Ответ: F1]-мера**.

3. Проблема, когда модель показывает хорошее качество на обучающих данных, но плохое на новых, называется **[Ответ: переобучение (overfitting)]**.

4. Если модель дает одинаковые ошибки на определенном типе объектов, для улучшения качества нужно провести **[Ответ: анализ (разбор)]** ошибок.

5. Метод повышения качества ансамблевых моделей, при котором каждое следующее дерево обучается на ошибках предыдущих, называется **[Ответ: бустинг (boosting)]**.

6. Набор данных, используемый для финальной оценки качества модели, называется [**Ответ: тестовой (контрольной)**] выборкой.
7. Метод теории вероятностей для автоматической обработки несбалансированных данных через взвешивание примеров называется [**Ответ: байесовское**] взвешивание.
8. Подход к работе с несбалансированными данными через искусственное уменьшение большего класса называется [**Ответ: андерсэмплинг**].
9. Подход к работе с несбалансированными данными через искусственное увеличение меньшего класса называется [**Ответ: оверсэмплинг**].
10. Метод генерации синтетических примеров на основе интерполяции между выбранным образцом миноритарного класса и его ближайшими соседями называется [**Ответ: SMOTE**].
11. Алгоритм BORDERLINE-SMOTE генерирует синтетические примеры только для образцов, находящихся на [**Ответ: границе**] между классами.
12. В алгоритме ADASYN количество синтетических примеров для каждого образца миноритарного класса определяется на основе [**Ответ: сложности классификации**] (плотности соседей другого класса).
13. Метод андерсэмплинга, при котором удаляются примеры мажоритарного класса, ближайшие к примерам миноритарного класса, называется [**Ответ: Tomek Links**].
14. Алгоритм SMOTE сначала выбирает случайный образец из [**Ответ: миноритарного**] класса, затем находит его k ближайших соседей из того же класса и генерирует новый пример путем интерполяции.
15. Метрика, вычисляемая как среднее гармоническое между Precision и Recall, называется [**Ответ: F1-мера**].
16. Метрика ROC-AUC показывает способность модели [**Ответ: разделять**] классы при различных порогах классификации.
17. Precision рассчитывается как отношение [**Ответ: True Positive**] к сумме [**Ответ: True Positive и False Positive**].

18. Метрика, показывающая долю верно классифицированных объектов среди всех объектов, называется [**Ответ: Accuracy**].

19. Confusion Matrix содержит значения [**Ответ: True Positive, False Positive, False Negative и True Negative**] для оценки качества классификации.

20. Метрика Recall для задачи бинарной классификации рассчитывается как отношение [**Ответ: True Positive**] к сумме [**Ответ: True Positive и False Negative**].

Компетенция ML-3

Индикатор ML-3.1

Тестовые вопросы закрытого типа

1. Что является первым и фундаментальным этапом системного подхода при решении задачи машинного обучения?

- а) Выбор алгоритма с лучшими результатами на Kaggle.
- б) Формализация проблемы и определение цели.**
- в) Немедленный сбор всех доступных данных.
- г) Обучение нескольких моделей для сравнения.

2. Выбор метрики для оценки модели (например, Accuracy, Precision, F1-score) напрямую зависит от:

- а) Количества данных в обучающей выборке.
- б) Выбранного алгоритма машинного обучения.
- в) Сформулированной цели и стоимости ошибок.**
- г) Производительности компьютера.

3. При работе с данными системный подход предполагает последовательность действий:

- а) Обучение модели → Предобработка данных → Анализ качества данных.
- б) Сбор данных → Разведочный анализ и предобработка → Обучение модели.**
- в) Разведочный анализ → Обучение модели → Сбор недостающих данных.
- г) Предобработка данных → Сбор данных → Обучение модели.

4. Обнаружив, что модель плохо работает на новых данных, специалист, применяющий системный подход, в первую очередь должен:

- а) Увеличить сложность модели (например, глубину дерева).
- б) Собрать еще больше данных.**

- в) Проверить гипотезу о смещении обучающей и тестовой выборок (data drift).
- г) Попробовать другой алгоритм машинного обучения.

5. Какое из утверждений лучше всего описывает применение системного подхода к предобработке данных?

- а) Это рутинный этап, который всегда выполняется одинаково для любых данных.
- б) Это итеративный процесс, основанный на анализе природы данных и выявленных аномалий.**
- в) Это этап, который можно пропустить, если используется мощный алгоритм.
- г) Это этап, который выполняется один раз после сбора всех данных.

6. Процесс разбиения данных на обучающую, валидационную и тестовую выборки является примером:

- а) Оптимизации производительности вычислений.
- б) Системного метода контроля переобучения и оценки способности модели к обобщению.**
- в) Случайной процедуры, не влияющей на результат.
- г) Метода ускорения процесса обучения.

7. Признак в данных следует исключить из рассмотрения, если он:

- а) Сложен для вычисления.
- б) Имеет прямую, но не очевидную связь с целевой переменной.
- в) Является «утечкой данных» (data leakage), т.е. содержит информацию из будущего или о целевом признаке.**
- г) Имеет высокую дисперсию.

8. Что из перечисленного не является частью системного подхода к построению пайплайна машинного обучения?

- а) Автоматизация последовательности этапов (предобработка, обучение, оценка).
- б) Изоляция этапа предобработки данных от этапа применения модели.
- в) Ручное изменение параметров предобработки для каждой новой порции данных.**
- г) Обеспечение воспроизводимости результатов.

9. Какая из этих проблем требует в первую очередь пересмотра постановки задачи, а не применения более сложной модели?

- а) Низкая точность на валидационной выборке.
- б) Модель регрессии предсказывает отрицательные значения там, где они невозможны (например, цена).**
- в) Долгое время обучения модели.
- г) Большой объем потребляемой памяти.

10. Кросс-валидация как метод более надежной оценки модели демонстрирует системный подход, потому что:

- а) Она всегда дает более высокий результат, чем простое разбиение на train/test.
- б) Она позволяет использовать больше данных для обучения.

в) Она системно использует данные, многократно проверяя модель на разных подвыборках, чтобы получить устойчивую оценку.

г) Это самый быстрый способ оценить модель.

11. Столкнувшись с несбалансированными классами, специалист с системным мышлением рассмотрит несколько решений (например, взвешивание объектов, SMOTE, смену метрики), потому что:

а) Не существует единственного лучшего способа решения этой проблемы.

б) Системный подход требует перепробовать все известные методы.

в) Это увеличит время работы над проектом.

г) Так рекомендует преподаватель.

12. Регуляризация в машинном обучении — это пример системного подхода, направленного на:

а) Максимизацию точности на обучающей выборке.

б) Упрощение модели для улучшения ее способности к обобщению.

в) Ускорение времени обучения модели.

г) Увеличение сложности модели.

13. При анализе работы модели классификации важно анализировать не только общую точность (Accuracy), но и матрицу ошибок (Confusion Matrix), так как это:

а) Требуется техническое задание.

б) Позволяет системно оценить, на каких именно классах ошибается модель.

в) Это стандартный этап, не несущий особой смысловой нагрузки.

г) Позволяет сделать модель сложнее.

14. Вы завершили проект, построив модель. Что из перечисленного является заключительным этапом системного подхода?

а) Заархивировать код и данные.

б) Развернуть модель и забыть о ней.

в) Подготовить выводы, описать ограничения модели и передать результаты заказчику.

г) Начать следующий проект.

15. Понимание ограничений и допущений конкретного алгоритма (например, линейности у линейной регрессии) важно с точки зрения системного подхода, потому что:

а) Это сложно и требует глубоких математических знаний.

б) Это позволяет осознанно выбирать инструмент, адекватный задаче и данным.

в) Об этом пишут в научных статьях.

г) Это необходимо для составления отчета.

16. Что является ключевой целью применения системного подхода на этапе feature engineering?

а) Создать как можно больше признаков.

б) Создать признаки, которые системно отражают закономерности в данных, важные для решения задачи.

в) Использовать самые сложные математические преобразования.

г) Сделать данные визуально привлекательными.

17. Итеративность процесса машинного обучения (построение базовой модели → анализ ошибок → улучшение) лучше всего отражает принцип системного подхода, так как:

а) Позволяет бесконечно откладывать финальный результат.

б) Позволяет постепенно и целенаправленно улучшать систему (модель), углубляя понимание задачи и данных.

в) Это модная тенденция в разработке.

г) Требуется по методологии Agile.

18. Если добавление новых данных не улучшает качество модели, системный подход подсказывает, что следует:

а) Продолжить сбор данных, так как их всегда не хватает.

б) Проанализировать, не исчерпала ли модель информационность текущих признаков, и поискать новые источники информации.

в) Сделать модель еще более сложной.

г) Сменить метрику качества на менее строгую.

19. Выбор между простой интерпретируемой моделью и сложной «черным ящиком» с чуть лучшим качеством должен определяться:

а) Всегда нужно выбирать самую сложную модель.

б) Требованиями задачи: нужна ли интерпретируемость для заказчика.

в) Личными предпочтениями специалиста по ML.

г) Тем, какая модель быстрее обучается.

20. Что из перечисленного не является примером системного подхода в машинном обучении?

а) Документирование всех этапов работы, использованных данных и параметров моделей.

б) Обучение одной модели и ее немедленное применение без тщательной валидации.

в) Построение базового уровня (baseline) для сравнения с более сложными моделями.

г) Анализ причин ошибок модели для целенаправленного ее улучшения.

Тестовые вопросы открытого типа

1. Первым этапом системного подхода в ML является формулировка [**Ответ: проблемы (цели)**] задачи.

2. Для системной оценки способности модели к обобщению данные необходимо разделять на обучающую и [**Ответ: тестовую**] выборки.

3. Метрика оценки модели должна выбираться на основе [Ответ: **целей задачи**] и стоимости ошибок.
4. Системный метод борьбы с переобучением, заключающийся в добавлении штрафа за сложность модели, называется [Ответ: **регуляризация**].
5. Многократное разбиение данных для получения устойчивой оценки модели называется [Ответ: **кросс-валидация**].
6. Процесс мониторинга модели после внедрения для выявления снижения её качества называется [Ответ: **постпродакшн (продакшн, промышленный, постоянный, операционный)**] мониторинг.
7. Процесс создания новых признаков на основе существующих данных называется [Ответ: **feature**] engineering.
8. Ситуация, когда модель работает хорошо на обучающих данных, но плохо на новых, называется [Ответ: **переобучение (overfitting)**].
9. Простая модель, служащая точкой отсчета для оценки более сложных алгоритмов, называется [Ответ: **baseline (базовая модель)**].
10. Использование при обучении информации, которая будет недоступна в режиме прогнозирования, называется [Ответ: **утечка данных (data leakage)**].
11. Изменение распределения входных данных с течением времени называется [Ответ: **data drift (дрейф данных)**].
12. Основной инструмент для системного анализа ошибок модели классификации называется [Ответ: **матрица ошибок (confusion matrix)**].
13. Системный подход к работе с пропущенными значениями начинается с анализа [Ответ: **причины (природы)**] их возникновения.
14. Процесс изучения распределений и взаимосвязей в данных перед построением модели называется [Ответ: **разведочный (EDA)**] анализ данных.
15. Системное требование к ML-проекту, означающее, что результаты должны быть повторяемыми, называется [Ответ: **воспроизводимость**].

16. Важным свойством модели для финансовой и медицинской сфер является её **[Ответ: интерпретируемость]**, то есть возможность объяснить прогноз.

17. Процесс последовательного выполнения этапов предобработки, обучения и применения модели называется **[Ответ: пайплайн (pipeline)]**.

Ответ:

18. Системный подход к сравнению моделей требует их оценки на **[Ответ: одинаковых (одних и тех же)]** данных.

19. Для системного понимания того, какие признаки влияют на прогноз модели, используются методы **[Ответ: feature]** importance.

20. Ключевой принцип системного подхода в ML - **[Ответ: итеративность]** процесса (построение → анализ ошибок → улучшение).

Индикатор ML-3.2

Тестовые вопросы закрытого типа

1. При выборе между линейной регрессией и деревом решений для прогнозирования спроса на сезонный товар ключевым аргументом в пользу дерева будет:

- а) Высокая интерпретируемость линейной модели.
- б) Способность дерева улавливать нелинейные зависимости и взаимодействия признаков.**
- в) Большая скорость обучения линейной регрессии.
- г) Меньшая склонность деревьев к переобучению.

2. Почему метод k-ближайших соседей (k-NN) может быть плохим выбором для системы реального времени с высоконагруженным API?

- а) Он требует хранения всего обучающего набора данных для предсказания, что приводит к высоким вычислительным затратам при инференсе.**
- б) Он не умеет работать с категориальными признаками.
- в) Он имеет слишком низкую точность по сравнению с нейросетями.
- г) Он не поддерживает онлайн-обучение.

3. Какая модификация логистической регрессии является наиболее эффективной для работы с сильно несбалансированными классами?

- а) Увеличить количество итераций обучения.
- б) Использовать регуляризацию L2.
- в) Изменить порог классификации или использовать взвешивание классов.**
- г) Добавить полиномиальные признаки.

4. При анализе клиентской базы интернет-магазина необходимо выделить группы покупателей со схожим поведением для персонализации предложений. Данные содержат как числовые признаки (сумма покупок, частота заказов, время на сайте), так и категориальные (город, категория товаров, тип устройства). При этом заранее неизвестно, сколько групп покупателей существует. Какой подход к кластеризации наиболее обоснован в данной ситуации?

- а) Использование алгоритма k-means с предварительным масштабированием данных и методом локтя для определения числа кластеров
- б) Использование алгоритма DBSCAN с предварительным кодированием категориальных признаков с помощью One-Hot Encoding
- в) Использование иерархической кластеризации с Gower-расстоянием для смешанных типов данных**
- г) Использование алгоритма Fuzzy C-Means с предварительной стандартизацией всех признаков

5. Если модель случайного леса (Random Forest) показывает высокую точность на кросс-валидации, но плохую на отложенной тестовой выборке, наиболее вероятная причина и способ адаптации:

- а) Переобучение; уменьшить количество деревьев в лесу.
- б) Недообучение; увеличить глубину каждого дерева.
- в) утечка данных; проверить корректность разбиения данных и предобработка.**
- г) Слишком высокий learning rate; уменьшить его.

6. В задаче детекции аномалий на временных рядах, где аномалии редки и не размечены, обоснованным применением метода будет:

- а) Логистическая регрессия.
- б) K-means кластеризация.
- в) One-Class SVM, обучающийся на «нормальных» данных.**
- г) Метод k-ближайших соседей (k-NN) для кластеризации.

7. В алгоритме случайного леса (Random Forest) для построения каждого дерева используется бутстреп-выборка (bootstrap sampling) из исходного набора данных. Какой из следующих эффектов НЕ является следствием использования бутстреп-выборки в случайном лесу?

- а) Уменьшение переобучения за счет обучения каждого дерева на разных подвыборках данных
- б) Увеличение разнообразия между деревьями в ансамбле
- в) Гарантированное улучшение качества модели на любых данных**
- г) Возможность оценки важности признаков с помощью Out-of-Bag (OOB) ошибки

8. Какая модификация стандартного градиентного бустинга (например, в XGBoost) критически важна для обучения на данных с пропущенными значениями?

- а) Замена всех пропусков на ноль.
- б) Встроенный алгоритм, который учится направлять наблюдения с пропусками в нужную ветку дерева.**
- в) Обязательное удаление всех строк с пропусками.

г) Использование только тех признаков, где нет пропусков.

9. Для задачи прогнозирования временного ряда с выраженной сезонностью обоснованной модификацией линейной модели будет:

- а) Добавление в качестве признаков лаговых значений ряда и синусоидальных функций от времени.**
- б) Увеличение степени регуляризации L1.
- в) Замена линейной модели на K-means.
- г) Применение метода главных компонент (РСА) к исходному ряду.

10. Если важна не только точность, но и интерпретируемость модели (например, для кредитного скоринга), обоснованным выбором не будет:

- а) Дерево решений.
- б) Линейная регрессия с L1-регуляризацией.
- в) Глубокая нейронная сеть из 10 слоев.**
- г) Логистическая регрессия.

11. При работе с несбалансированным датасетом (например, 95% объектов относятся к одному классу) для задачи бинарной классификации с использованием случайного леса (Random Forest) наиболее обоснованным действием будет:

- а) Использование стандартного случайного леса без изменений, так как он устойчив к дисбалансу классов.
- б) Применение метода взвешивания классов (`class_weight='balanced'`) для учета важности миноритарного класса при построении деревьев.**
- в) Удаление всех объектов мажоритарного класса до полной балансировки данных.
- г) Увеличение числа деревьев в лесу до 1000 для автоматического решения проблемы дисбаланса.

12. При работе с небольшим размеченным датасетом (500 объектов, 20 числовых признаков) для задачи бинарной классификации без явно выраженных нелинейных зависимостей наиболее обоснованным выбором между случайным лесом (Random Forest) и методом опорных векторов (SVM) будет:

- а) Случайный лес, так как он автоматически справляется с выбросами и не требует масштабирования признаков, что критично для такого размера данных.
- б) SVM с линейным ядром, так как при небольшом количестве объектов линейные модели дают более стабильные результаты на числовых данных с отсутствием сложных нелинейностей.**
- в) SVM с RBF-ядром, так как оно всегда дает лучшее качество для числовых данных любого размера.
- г) Случайный лес с 1000 деревьями, так как увеличение числа деревьев автоматически решает все проблемы с качеством на малых данных.

13. При решении задачи бинарной классификации на небольшом датасете (300 объектов, 10 числовых признаков) с отсутствием явных нелинейных зависимостей между признаками и

целевой переменной, а также при наличии небольшого количества выбросов, наиболее обоснованным выбором между методом опорных векторов (SVM) и методом k ближайших соседей (kNN) будет:

- а) Метод kNN, так как он устойчив к выбросам и не требует настройки гиперпараметров.
- б) SVM с линейным ядром, так как он обеспечивает устойчивое разделение классов на небольших данных с линейной структурой, особенно при правильной нормализации признаков.**
- в) SVM с RBF-ядром, так как он всегда дает лучшее качество для числовых данных любого размера.
- г) Метод kNN с большим значением k (например, $k=20$), чтобы минимизировать влияние выбросов.

14. При построении модели регрессии для прогнозирования продаж на основе исторических данных обнаружена проблема: модель показывает низкие ошибки на обучающей выборке, но значительно более высокие на тестовой. Какой метод борьбы с переобучением не является обоснованным в данной ситуации?

- а) Уменьшение сложности модели (например, уменьшение степени полинома или глубины дерева)
- б) Добавление регуляризации (L1 или L2) в функцию потерь
- в) Увеличение количества признаков путем добавления полиномиальных членов высоких степеней**
- г) Увеличение размера обучающей выборки за счет сбора дополнительных данных

15. В задаче множественной линейной регрессии для прогнозирования цены недвижимости используется 20 признаков. При построении модели обнаружена высокая мультиколлинеарность между некоторыми признаками (например, площадь дома и количество комнат). Какое действие НЕ является корректным для решения этой проблемы?

- а) Удаление одного из коррелирующих признаков
- б) Применение гребневой регрессии (Ridge Regression)
- в) Применение метода главных компонент (PCA) для уменьшения размерности
- г) Добавление полиномиальных признаков высоких степеней для усиления мультиколлинеарности**

16. Какая модификация метода опорных векторов (SVM) является стандартной для применения в задаче классификации более чем с двумя классами?

- а) Использование сигмоидальной функции активации.
- б) Стратегия «один-против-всех» (one-vs-rest) или «один-против-одного» (one-vs-one).**
- в) Увеличение размера ядра (kernel).
- г) Уменьшение параметра регуляризации C.

17. При построении классификатора на основе метода k ближайших соседей (kNN) для задачи бинарной классификации с 5 числовыми признаками и 1000 объектами было замечено, что

качество модели сильно падает при увеличении размерности пространства признаков. Какое из следующих действий не является обоснованным способом решения этой проблемы?

- а) Применение метода главных компонент (РСА) для уменьшения размерности до 2-3 компонент
- б) Использование взвешенного kNN, где вклад соседей зависит от расстояния до них
- в) Добавление новых признаков, созданных как полиномиальные комбинации существующих, для увеличения размерности**
- г) Масштабирование признаков к одному диапазону (например, StandardScaler)

18. Для задачи прогнозирования, где точность прогноза на 1 шаг вперед важнее, чем на 10 шагов, обоснованной модификацией обучения рекуррентной сети (RNN) будет:

- а) Обучение с учителем только на 1 шаг вперед.**
- б) Обучение с учителем на 10 шагов вперед.
- в) Использование только линейных слоев.
- г) Игнорирование последовательной природы данных.

19. Если модель на основе градиентного бустинга слишком медленная для инференса в реальном времени, обоснованным способом адаптации является:

- а) Увеличение количества деревьев в ансамбле.
- б) Увеличение глубины каждого дерева.
- в) Аппроксимация предсказаний бустинга одной быстрой моделью (например, неглубоким деревом).**
- г) Обучение на большем количестве признаков.

20. Признаком того, что выбранная модель не соответствует специфике задачи, является:

- а) Высокая точность на тестовой выборке.
- б) Низкая точность на обучающей и тестовой выборках (систематическое недообучение).**
- в) Стабильное время предсказания.
- г) Интерпретируемость предсказаний модели.

Тестовые вопросы открытого типа

1. Простая модель, которая служит точкой отсчета для сравнения с более сложными алгоритмами, называется [**Ответ: базовая (baseline)**] модель.

2. Если важны не только прогнозы, но и понимание влияния каждого признака на результат, требуется [**Ответ: интерпретируемая**] модель.

3. Метод, позволяющий линейным классификаторам работать с нелинейно разделимыми данными, называется [**Ответ: трюкс ядром (kernel trick)**].

4. Процесс создания новых признаков на основе существующих для улучшения качества модели называется [**Ответ: признаковый инжиниринг (feature engineering)**].
5. Если в данных присутствуют пропущенные значения, которые не являются случайными, перед заполнением пропусков нужно проанализировать [**Ответ: причину (механизм)**] их возникновения.
6. Проблема, когда модель показывает хорошее качество на обучающих данных, но плохое на новых, называется [**Ответ: переобучение (overfitting)**].
7. Техника борьбы с переобучением, при которой к функции потерь добавляется штраф за большие веса, называется [**Ответ: регуляризация**].
8. В задаче бинарной классификации с небольшим количеством объектов (500) и числовыми признаками (20) при отсутствии явных нелинейностей, но при наличии выбросов, метод опорных векторов (SVM) с линейным ядром часто оказывается предпочтительнее случайного леса, поскольку [**Ответ: устойчив к выбросам**].
9. При работе с набором данных, содержащим категориальные и числовые признаки, случайный лес часто оказывается предпочтительнее метода опорных векторов, поскольку [**Ответ: работает с категориями**].
10. Если после продолжительного использования модели её качество постепенно ухудшается из-за изменения распределения данных, это явление называется [**Ответ: дрейф данных (data drift)**].
11. В алгоритме дерева решений для классификации прирост информации (Information Gain) используется для выбора признака, который обеспечивает [**Ответ: максимальное разделение**].
12. Метод объединения нескольких моделей для повышения общей точности и устойчивости называется [**Ответ: ансамблирование**].
13. В случайном лесу (Random Forest) для повышения разнообразия деревьев и снижения переобучения используется метод, при котором каждое дерево строится на случайной подвыборке объектов и случайном подмножестве признаков, что называется [**Ответ: бэггинг / bagging**].
14. Преобразование категориальных признаков в числовые с сохранением информации о сходстве между категориями называется [**Ответ: порядковое кодирование (ordinal encoding)**].

15. Процесс автоматического преобразования категориальных признаков в бинарные векторы называется [Ответ: **one-hot кодирование (one-hot encoding)**].
16. Если при прогнозировании временного ряда нужно учитывать долгосрочные зависимости, следует использовать архитектуру [Ответ: **рекуррентной нейронной сети (RNN)**].
17. В логистической регрессии для бинарной классификации функция потерь, которая минимизируется в процессе обучения, называется [Ответ: **логистическая / log loss**].
18. При обработке данных с большим количеством признаков перед обучением модели часто применяют [Ответ: **снижение (reduction)**] размерности.
19. Метод повышения качества ансамблевых моделей, при котором каждое следующее дерево обучается на ошибках предыдущих, называется [Ответ: **бустинг (boosting)**].
20. Для проверки устойчивости модели к небольшим изменениям в входных данных используют [Ответ: **стресс-тестирование (адаптационное)**] тестирование.

Индикатор ML-3.3

Тестовые вопросы закрытого типа

1. При решении задачи прогнозирования временных рядов с выраженной сезонностью и трендом, но без явных нелинейных зависимостей, какая модель регрессии покажет лучший результат по сравнению с линейной регрессией?
- а) Линейная регрессия с полиномиальными признаками
 - б) Гребневая регрессия (Ridge)
 - в) Lasso-регрессия
 - г) **Линейная регрессия с добавлением сезонных фиктивных переменных и тренда**
2. В чем преимущество Lasso-регрессии перед гребневой регрессией (Ridge) при работе с данными, содержащими большое количество неинформативных признаков?
- а) Lasso быстрее обучается
 - б) **Lasso обнуляет коэффициенты неинформативных признаков, выполняя отбор признаков**
 - в) Lasso устойчивее к выбросам
 - г) Lasso не требует масштабирования данных
3. При высокой мультиколлинеарности признаков в задаче регрессии какая модель даст более стабильные коэффициенты по сравнению с обычной линейной регрессией?
- а) Lasso-регрессия
 - б) **Гребневая регрессия (Ridge)**
 - в) Метод опорных векторов для регрессии (SVR)

г) Дерево решений для регрессии

4. Для прогнозирования спроса на товар с большим количеством выбросов в данных (например, аномально высокие продажи в праздничные дни) какая регрессионная модель будет более устойчивой по сравнению с обычной линейной регрессией?

- а) Lasso-регрессия
- б) Гребневая регрессия (Ridge)
- в) Робастная регрессия**
- г) Полиномиальная регрессия

5. В задаче прогнозирования цен на недвижимость с большим количеством категориальных признаков (тип дома, район, этаж) какая модель регрессии имеет преимущество перед линейной регрессией?

- а) Гребневая регрессия (Ridge)
- б) Дерево решений для регрессии**
- в) Lasso-регрессия
- г) Метод опорных векторов для регрессии (SVR)

6. При работе с данными, где число признаков значительно превышает число наблюдений ($p \gg n$), какая регрессионная модель покажет лучший результат по сравнению с обычной линейной регрессией?

- а) Lasso-регрессия (с L1-регуляризацией)
- б) Гребневая регрессия (с L2-регуляризацией)
- в) Elastic Net (комбинация L1 и L2)
- г) Все перечисленные модели будут работать лучше линейной регрессии**

7. При решении задачи классификации спам-сообщений с высокоразмерными разреженными данными, какая модель покажет лучшее качество по сравнению с логистической регрессией?

- а) Метод опорных векторов (SVM) с линейным ядром**
- б) Метод опорных векторов (SVM) с RBF-ядром
- в) Дерево решений
- г) Наивный Байес

8. В задаче бинарной классификации с несбалансированными классами (95% объектов — класс 0, 5% — класс 1) какая модель обеспечит лучшее обнаружение миноритарного класса по сравнению со стандартной логистической регрессией?

- а) Стандартная логистическая регрессия
- б) Логистическая регрессия с параметром `class_weight='balanced'`**
- в) Дерево решений без ограничений
- г) Наивный Байес

9. При наличии сложных нелинейных зависимостей между признаками и целевой переменной в задаче классификации, какая модель даст преимущество перед линейными методами

(логистическая регрессия, линейный SVM)?

- а) SVM с полиномиальным ядром
- б) SVM с RBF-ядром
- в) Дерево решений
- г) **Все перечисленные модели могут дать преимущество**

10. В задаче классификации изображений небольшого размера (например, 8×8 пикселей, как в наборе данных с цифрами) с малым количеством объектов (1000) какая модель покажет лучшее качество по сравнению со сложными нелинейными моделями (SVM с RBF)?

- а) **Логистическая регрессия**
- б) SVM с RBF-ядром
- в) Случайный лес с 100 деревьями
- г) Метод k ближайших соседей (kNN)

11. Для задачи классификации с сильным дисбалансом классов (например, обнаружение мошеннических транзакций) какая модель имеет преимущество в интерпретируемости результатов по сравнению со случайным лесом?

- а) **Логистическая регрессия**
- б) Градиентный бустинг (XGBoost)
- в) SVM с RBF-ядром
- г) Метод k ближайших соседей (kNN)

12. При работе с данными, содержащими пропуски в большом количестве признаков, какая классификационная модель будет более устойчива по сравнению с линейными методами?

- а) Логистическая регрессия
- б) **Случайный лес**
- в) Метод опорных векторов (SVM)
- г) Наивный Байес

13. В задаче классификации с большим количеством шумовых признаков (50 признаков, из которых только 10 информативных) какая модель покажет лучшее качество по сравнению с полным случайным лесом?

- а) Случайный лес без изменений
- б) Случайный лес с отбором признаков на основе важности
- в) Градиентный бустинг (XGBoost)
- г) **Логистическая регрессия с L1-регуляризацией (Lasso)**

14. При решении задачи классификации с малым количеством объектов (300) и большим числом признаков (50) какая модель даст преимущество перед глубокими деревьями (неограниченный Random Forest)?

- а) **Логистическая регрессия с регуляризацией**
- б) SVM с RBF-ядром
- в) Случайный лес с глубокими деревьями
- г) Градиентный бустинг (XGBoost)

15. При работе с данными, имеющими кластеры произвольной формы и большое количество шума, какая модель кластеризации покажет лучшее качество по сравнению с k-means?

- а) Иерархическая кластеризация
- б) DBSCAN**
- в) Fuzzy C-Means
- г) k-means с предварительным PCA

16. При решении задачи классификации спам-сообщений с высокоразмерными разреженными данными, какая модель покажет лучшее качество по сравнению с логистической регрессией?

- а) Метод опорных векторов (SVM) с линейным ядром
- б) Метод опорных векторов (SVM) с RBF-ядром
- в) Дерево решений
- г) Наивный Байес**

17. При работе с набором данных, содержащим значительное количество выбросов (например, доходы населения с несколькими миллиардерами), какой метод масштабирования признаков является наиболее обоснованным выбором по сравнению со стандартизацией (StandardScaler)?

- а) MinMaxScaler (нормализация в диапазон [0, 1])
- б) RobustScaler (масштабирование на основе медианы и квартилей)**
- в) StandardScaler (стандартизация с удалением среднего и приведением к единичной дисперсии)
- г) Normalizer (приведение к единичной норме)

18. Для данных с сильно перекрывающимися кластерами, где объекты могут принадлежать нескольким группам с разной степенью уверенности, какая модель кластеризации дает преимущество перед жесткими методами (k-means)?

- а) Иерархическая кластеризация
- б) DBSCAN
- в) Fuzzy C-Means**
- г) Метод максимизации ожидания (EM)

19. При необходимости определения оптимального числа кластеров без использования внешних метрик и визуализации какая модель кластеризации позволяет обоснованно выбрать число кластеров по сравнению с DBSCAN?

- а) k-means с методом локтя
- б) Иерархическая кластеризация с дендрограммой
- в) DBSCAN с анализом eps-графика
- г) Все перечисленные алгоритмы позволяют определить число кластеров**

20. При решении задачи бинарной классификации с небольшим набором данных (500 объектов, 10 признаков) методом опорных векторов (SVM) было обнаружено, что модель с RBF-ядром показывает высокую точность на обучающей выборке (98%), но значительно более низкую на тестовой (72%). Какое действие наиболее обоснованно для борьбы с переобучением по сравнению с использованием RBF-ядра без изменений?

- а) Увеличить значение параметра C
- б) Уменьшить значение параметра γ**
- в) Использовать полиномиальное ядро с высокой степенью
- г) Использовать линейное ядро вместо RBF

Тестовые вопросы открытого типа

1. Модель регрессии, которая минимизирует сумму квадратов остатков с добавлением штрафа пропорционально квадрату коэффициентов, называется [**Ответ: гребневая регрессия / Ridge**].
2. Модель регрессии, выполняющая отбор признаков путем обнуления коэффициентов неинформативных переменных, называется [**Ответ: Lasso-регрессия / Lasso**].
3. В отличие от линейной регрессии, модель регрессии на основе деревьев решений позволяет [**Ответ: учитывать нелинейности / работать с категориями**].
4. Метод регрессии, устойчивый к выбросам за счет использования не квадратичной, а другой функции потерь, называется [**Ответ: робастная регрессия**].
5. В отличие от обычной линейной регрессии, гребневая регрессия лучше справляется с проблемой [**Ответ: мультиколлинеарности**].
6. Метод регрессии, комбинирующий преимущества $L1$ и $L2$ регуляризации, называется [**Ответ: Elastic Net**].
7. В отличие от логистической регрессии, метод опорных векторов с RBF-ядром позволяет разделять [**Ответ: нелинейные данные**].
8. В отличие от метода опорных векторов, логистическая регрессия имеет преимущество в [**Ответ: интерпретируемости результатов**].
9. В отличие от логистической регрессии, случайный лес позволяет автоматически отбирать [**Ответ: признаки**].
10. В отличие от деревьев решений, метод опорных векторов обеспечивает максимизацию [**Ответ: разделяющего зазора**].

11. В отличие от случайного леса, градиентный бустинг (XGBoost) обычно обеспечивает более [Ответ: высокую точность] на структурированных данных.
12. В отличие от логистической регрессии, наивный байесовский классификатор требует независимости [Ответ: признаков].
13. В отличие от методов на основе расстояний (kNN), дерево решений не требует масштабирования [Ответ: признаков].
14. В отличие от градиентного бустинга, случайный лес менее склонен к [Ответ: переобучению] на шумных данных.
15. В отличие от k-means, алгоритм DBSCAN не требует задания [Ответ: числа кластеров].
16. В отличие от DBSCAN, алгоритм k-means предполагает, что кластеры имеют [Ответ: сферическую форму].
17. В отличие от жесткой кластеризации (k-means), алгоритм Fuzzy C-Means позволяет объекту принадлежать [Ответ: нескольким кластерам].
18. В отличие от иерархической кластеризации, алгоритм k-means работает быстрее на [Ответ: больших данных].
19. В отличие от k-means, иерархическая кластеризация позволяет [Ответ: визуализировать] структуру через дендрограмму.
20. В отличие от логистической регрессии, наивный байесовский классификатор предполагает, что признаки являются [Ответ: независимыми].

Компетенция ML-4

Индикатор ML-4.1

Тестовые вопросы закрытого типа

1. Какой метод не используется для снижения размерности данных?
- а) Линейная регрессия
 - б) PCA (Principal Component Analysis)

- в) t-SNE
- г) UMAP

2. Для чего используется метод PCA (Principal Component Analysis)?

- а) Снижение размерности данных**
- б) Увеличение объема данных
- в) Создание новых категориальных признаков
- г) Удаление всех числовых признаков

3. Метод главных компонент (PCA) является...

- а) Алгоритмом кластеризации.
- б) Алгоритмом с учителем для уменьшения размерности.
- в) Алгоритмом без учителя для уменьшения размерности.**
- г) Методом классификации.

4. Почему метод главных компонент (PCA) может быть неудачным выбором для обнаружения выбросов в категориальных данных?

- а) PCA всегда идеально работает с любыми типами данных.
- б) PCA предназначен для линейного снижения размерности непрерывных данных и может терять важные нелинейные зависимости в категориальных признаках.**
- в) PCA слишком медленный для категориальных данных.
- г) PCA требует обязательной нормализации категориальных данных.

5. Понятие ковариации между случайными величинами непосредственно используется в:

- а) Методе главных компонент (PCA)**
- б) Логистической регрессии
- в) Наивном байесовском классификаторе
- г) Методе k-средних

6. При решении задачи кластеризации при работе с данными, содержащими шумы и выбросы, обоснованным приемом является использование:

- а) Увеличения количества кластеров k в алгоритме k-means.
- б) Алгоритма DBSCAN, который не требует задания числа кластеров и устойчив к шумам.**
- в) Уменьшения количества кластеров k в алгоритме k-means.
- г) Предварительного удаления всех выбросов вручную.

7. Какая из перечисленных проблем наиболее вероятна при применении алгоритма k-means к данным с кластерами разного размера и плотности?

- а) алгоритм всегда будет находить оптимальное решение, проблем нет.
- б) Алгоритм может некорректно выделить кластеры из-за чувствительности к центроидам.**
- в) Алгоритм будет слишком медленным.
- г) Алгоритм присвоит всем объектам один кластер.

8. Какая из этих мер расстояния не используется в алгоритме k-means?

- а) Евклидово расстояние.
- б) Манхэттенское расстояние.
- в) Косинусное расстояние.
- г) **Расстояние Хэмминга.**

9. В чем ключевое различие между алгоритмами ЕМ (Expectation-Maximization) и k-means?

- а) **k-means – это частный случай ЕМ для гауссовых смесей с ковариационной матрицей, пропорциональной единичной.**
- б) ЕМ всегда сходится быстрее.
- в) k-means может работать с категориальными данными.
- г) Разницы нет, это один и тот же алгоритм.

10. Какой алгоритм не является методом кластеризации?

- а) DBSCAN
- б) K-means
- в) Gaussian Mixture Models
- г) **Random Forest**

11. Какая задача решается при группировке клиентов по поведению при покупках?

- а) **Кластеризация**
- б) Регрессия
- в) Классификация
- г) Обнаружение аномалий

12. В чем заключается ключевое различие между t-SNE и UMAP в подходе к сохранению структуры данных?

- а) t-SNE сохраняет глобальную структуру, а UMAP — локальную
- б) t-SNE оптимизирует распределение вероятностей в высокоразмерном и низкоразмерном пространствах, а UMAP использует теорию многообразий и сохраняет как локальную, так и глобальную структуру
- в) UMAP работает только с линейными данными, а t-SNE — с нелинейными
- г) t-SNE быстрее UMAP и требует меньше вычислительных ресурсов

13. Какой параметр в алгоритме UMAP отвечает за баланс между сохранением локальной и глобальной структуры данных?

- а) **n_neighbors**
- б) min_dist
- в) n_components
- г) random_state

14. В чем преимущество алгоритма TriMap перед t-SNE и UMAP?

- а) TriMap работает только с категориальными данными

- б) TriMar использует тройные сравнения (triplet constraints) вместо парных, что позволяет лучше сохранять глобальную структуру и обеспечивает более высокую скорость работы**
- в) TriMar не требует настройки гиперпараметров
- г) TriMar сохраняет только локальную структуру, игнорируя глобальную

15. Для решения каких задач алгоритмы t-SNE и UMAP НЕ подходят?

- а) Визуализация многомерных данных в 2D или 3D пространстве
- б) Предварительная обработка данных перед кластеризацией
- в) Обнаружение выбросов в данных
- г) Работа с данными, содержащими более 100 000 наблюдений (из-за высокой вычислительной сложности)**

16. Что такое «проклятие размерности» и как его преодолевают алгоритмы снижения размерности?

- а) Увеличение количества признаков для улучшения качества модели
- б) Снижение размерности данных путем проецирования на многообразие меньшей размерности при сохранении важной структуры**
- в) Удаление всех категориальных признаков из набора данных
- г) Увеличение объема обучающей выборки для компенсации высокой размерности

17. В чем принципиальное отличие нечеткой кластеризации (Fuzzy C-Means) от жесткой кластеризации (например, k-means)?

- а) Fuzzy C-Means присваивает каждому объекту степень принадлежности ко всем кластерам, а не жестко относит к одному**
- б) Fuzzy C-Means работает только с категориальными данными
- в) Fuzzy C-Means всегда находит оптимальное число кластеров автоматически
- г) Fuzzy C-Means не требует инициализации центроидов

18. Какое из перечисленных утверждений справедливо для алгоритма DBSCAN?

- а) DBSCAN требует заранее заданного числа кластеров
- б) DBSCAN устойчив к выбросам и может выделять кластеры произвольной формы**
- в) DBSCAN работает только с нормально распределенными данными
- г) DBSCAN всегда разделяет данные на сферические кластеры

19. Какой показатель не используется для определения оптимального числа кластеров в алгоритме k-means?

- а) Метод локтя (Elbow Method)
- б) Индекс силуэта (Silhouette Score)
- в) Статистика разрыва (Gap Statistic)
- г) Коэффициент Дарбина-Уотсона (Durbin-Watson)**

20. Какое преимущество дает иерархическая кластеризация по сравнению с k-means?

- а) Иерархическая кластеризация быстрее работает на больших данных
- б) Иерархическая кластеризация не требует заранее задавать число кластеров и позволяет**

визуализировать структуру данных в виде дендрограммы

- в) Иерархическая кластеризация всегда дает более качественные кластеры
- г) Иерархическая кластеризация устойчива к выбросам

Тестовые вопросы открытого типа

1. Метод снижения размерности, сохраняющий топологию данных и реализующий построение графа с использованием теории нечетких множеств, называется [**Ответ: UMAP**].
2. Метод снижения размерности, основанный на сингулярном разложении матрицы данных, называется [**Ответ: метод главных компонент (PCA)**].
3. Метод уменьшения размерности, который сохраняет нелинейные зависимости в данных и является предшественником алгоритма UMAP, называется [**Ответ: t-SNE**].
4. Метод уменьшения размерности, реализующий стохастическое вложение соседей с t-распределением и сохраняющий локальную структуру данных, называется [**Ответ: t-SNE**].
5. Алгоритм кластеризации, который представляет собой частный случай EM-алгоритма для сферических кластеров, называется [**Ответ: k-means**].
6. Если в данных присутствует много шума и выбросов, для кластеризации лучше использовать алгоритм [**Ответ: DBSCAN**], а не k-means.
7. Алгоритм, разделяющий данные на группы по схожести без использования размеченных примеров, решает задачу [**Ответ: кластеризации**].
8. Алгоритм кластеризации, основанный на плотности распределения данных, называется [**Ответ: DBSCAN**].
9. Процесс разделения данных на группы по схожести называется [**Ответ: кластеризация**].
10. Алгоритм снижения размерности, который сохраняет как локальную, так и глобальную структуру данных, называется [**Ответ: PASCAR**].

11. Метод визуализации высокоразмерных данных, основанный на минимизации расхождения Кульбака-Лейблера между распределениями вероятностей в исходном и низкоразмерном пространствах, называется [**Ответ: t-SNE**].

12. Алгоритм снижения размерности, использующий тройные сравнения (триплеты) для сохранения структуры данных, называется [**Ответ: TRIMAP**].

13. Параметр в алгоритме t-SNE, определяющий «эффективную» локальную окрестность для каждого объекта, называется [**Ответ: perplexity**].

14. Алгоритм кластеризации, не требующий задания числа кластеров и выделяющий плотные области произвольной формы, называется [**Ответ: DBSCAN**].

15. Древоподобная диаграмма, визуализирующая иерархическую кластеризацию, называется [**Ответ: дендрограмма**].

16. Алгоритм кластеризации, в котором каждый объект может принадлежать нескольким кластерам с разной степенью принадлежности, называется [**Ответ: Fuzzy C-Means / нечеткая кластеризация**].

14. В алгоритме DBSCAN минимальное количество точек, необходимое для формирования кластера, обозначается параметром [minPts / min_samples].

15. Алгоритм, представляющий собой нелинейный метод снижения размерности и сохраняющий как локальную, так и глобальную структуру с помощью триплетов (троек) точек, называется [**Ответ: TriMap**].

16. Метод иерархической кластеризации, при котором на каждом шаге объединяются два ближайших кластера на основе минимального расстояния между их элементами, называется [**Ответ: одиночная связь / single linkage**].

17. Алгоритм кластеризации, который требует задания числа кластеров и использует итеративный процесс пересчета центроидов как средних арифметических точек в кластере, называется [**Ответ: k-means**].

18. Метод иерархической кластеризации, при котором расстояние между кластерами определяется как максимальное расстояние между их элементами, называется [**Ответ: полная связь / complete linkage**].

19. Алгоритм кластеризации, который присваивает каждому объекту степень принадлежности ко всем кластерам в диапазоне от 0 до 1, называется [**Ответ: Fuzzy C-Means / нечеткая кластеризация**].

20. Алгоритм кластеризации, являющийся модификацией k-means, в котором центроиды вычисляются как медианы, что делает его устойчивым к выбросам, называется [**Ответ: k-medians / k-медиан**].

Индикатор ML-4.3

Тестовые вопросы закрытого типа

1. Какой показатель из теории информации используется для автоматической оценки качества кластеризации?

- а) Скорректированная взаимная информация**
- б) Индекс Джини
- в) Коэффициент детерминации
- г) Стандартное отклонение

2. Какой вероятностный показатель используется для автоматической оценки качества кластеризации?

- а) Скорректированный индекс Rand**
- б) Инертность кластеров
- в) Среднее расстояние до центроидов
- г) Количество кластеров

3. Какая метрика не используется для оценки кластеризации?

- а) Silhouette Score
- б) Adjusted Rand Index
- в) Mean Absolute Error**
- г) Calinski-Harabasz Index

4. Какая метрика оценки качества кластеризации принимает значения в диапазоне от -1 до 1, где 1 означает идеальное разделение кластеров?

- а) Индекс Данна (Dunn Index)
- б) Коэффициент силуэта (Silhouette Score)**
- в) Индекс Калински-Харабаса (Calinski-Harabasz Index)
- г) Индекс Дэвиса-Болдина (Davies-Bouldin Index)

5. Как интерпретируется значение индекса Дэвиса-Болдина (Davies-Bouldin Index)?

- а) Чем выше значение, тем лучше качество кластеризации
- б) Чем ниже значение, тем лучше качество кластеризации (меньше схожесть между**

кластерами)

- в) Индекс всегда равен 1 при идеальной кластеризации
- г) Индекс не зависит от числа кластеров

6. Какая метрика оценки качества кластеризации использует отношение суммы квадратов расстояний между кластерами к сумме квадратов расстояний внутри кластеров?

- а) Индекс силуэта (Silhouette Score)
- б) Индекс Калински-Харабаса (Calinski-Harabasz Index)**
- в) Индекс Дэвиса-Болдина (Davies-Bouldin Index)
- г) Индекс Данна (Dunn Index)

7. Что означает низкое значение индекса силуэта (близкое к 0) для конкретного объекта?

- а) Объект находится далеко от своего кластера и близко к соседним
- б) Объект находится на границе между кластерами или в области перекрытия**
- в) Объект идеально классифицирован
- г) Объект является выбросом

8. Какая метрика оценки качества кластеризации не требует знания истинных меток классов?

- а) Adjusted Rand Index (ARI)
- б) Normalized Mutual Information (NMI)
- в) Индекс силуэта (Silhouette Score)**
- г) F1-мера

9. Какой метод используется для оценки стабильности кластеризации при различных начальных условиях?

- а) Кросс-валидация
- б) Повторные запуски алгоритма с разными инициализациями и анализ согласованности результатов**
- в) Бутстрап
- г) Grid Search

10. Какая метрика оценки качества кластеризации использует отношение минимального расстояния между кластерами к максимальному диаметру кластера?

- а) Индекс Калински-Харабаса (Calinski-Harabasz Index)
- б) Индекс Дэвиса-Болдина (Davies-Bouldin Index)
- в) Индекс Данна (Dunn Index)**
- г) Индекс силуэта (Silhouette Score)

11. В чем заключается метод «локтя» (Elbow Method) для оценки качества кластеризации?

- а) В поиске точки перегиба на графике суммы квадратов внутрикластерных расстояний (WCSS) в зависимости от числа кластеров**
- б) В визуализации кластеров в 2D пространстве
- в) В расчете индекса силуэта для каждого кластера

г) В анализе дендрограммы

12. Какая метрика оценки качества кластеризации является внешней (требует знания истинных меток)?

- а) Индекс силуэта (Silhouette Score)
- б) Индекс Калински-Харабаса (Calinski-Harabasz Index)
- в) Adjusted Rand Index (ARI)**
- г) Индекс Данна (Dunn Index)

13. Как интерпретируется значение индекса Калински-Харабаса (Calinski-Harabasz Index)?

- а) Чем выше значение, тем лучше качество кластеризации (кластеры плотнее и лучше разделены)**
- б) Чем ниже значение, тем лучше качество кластеризации
- в) Индекс не зависит от числа объектов в выборке
- г) Индекс всегда равен числу кластеров

14. Какая метрика оценки качества кластеризации не зависит от числа кластеров и размера выборки?

- а) Индекс Калински-Харабаса
- б) Индекс Дэвиса-Болдина
- в) Индекс силуэта**
- г) Индекс Данна

15. На силуэтной диаграмме кластер отображается в виде горизонтальных полос. О чем свидетельствует большая «толщина» силуэта кластера?

- а) Объекты в кластере имеют высокие значения коэффициента силуэта
- б) Кластер содержит большое количество объектов**
- в) Кластер имеет компактную структуру
- г) Кластер хорошо отделен от соседних кластеров

16. При визуальном анализе силуэтной диаграммы у кластера наблюдается большая толщина, но все силуэты короткие и имеют значения, близкие к 0. Как следует интерпретировать этот результат?

- а) Кластер состоит из большого числа объектов, которые находятся на границе между кластерами или в области перекрытия**
- б) Кластер содержит много объектов и имеет высокое качество кластеризации
- в) Кластер содержит мало объектов, но они хорошо отделены от других
- г) Кластер является выбросом и должен быть удален из анализа

17. Отрицательное значение коэффициента силуэта для отдельного объекта означает, что:

- а) Объект находится далеко от центроида своего кластера, но близко к центроиду соседнего**
- б) Объект идеально классифицирован и находится в центре своего кластера
- в) Объект является выбросом и не относится ни к одному из кластеров

г) Алгоритм кластеризации работает корректно и выбрано оптимальное число кластеров

18. Какое из следующих утверждений справедливо для индекса Xie-Beni (Xie-Beni Index) при оценке качества кластеризации?

- а) Индекс Xie-Beni оценивает качество кластеризации как отношение внутрикластерной дисперсии к межкластерному расстоянию; чем меньше значение, тем лучше качество кластеризации**
- б) Индекс Xie-Beni оценивает качество кластеризации как отношение межкластерной дисперсии к внутрикластерной; чем больше значение, тем лучше
- в) Индекс Xie-Beni принимает значения от -1 до 1, где 1 означает идеальное разделение
- г) Индекс Xie-Beni используется только для оценки иерархической кластеризации и неприменим к k-means

19. При анализе силуэтной диаграммы обнаружен кластер с очень короткими силуэтами (значения близки к 0) и большой толщиной. Это свидетельствует о том, что:

- а) Кластер состоит из большого числа объектов с нечеткими границами, которые плохо отделяются от других кластеров**
- б) Кластер содержит мало объектов, но они хорошо отделены
- в) Кластер имеет высокую компактность
- г) Кластер является идеально сформированным

20. В чем заключается основное отличие индекса Xie-Beni от коэффициента силуэта при оценке качества кластеризации?

- а) Индекс Xie-Beni использует отношение внутрикластерной дисперсии к минимальному квадрату расстояния между центроидами, тогда как коэффициент силуэта основан на попарных расстояниях между объектами**
- б) Индекс Xie-Beni требует знания истинных меток классов, а коэффициент силуэта — нет
- в) Индекс Xie-Beni принимает значения от -1 до 1, а коэффициент силуэта — неограничен
- г) Индекс Xie-Beni используется только для иерархической кластеризации

Тестовые вопросы открытого типа

1. Показатель из теории информации для оценки качества кластеризации называется [**Ответ: индекс нормированной (скорректированной) взаимной информации**].

2. Процесс разделения данных на группы по схожести называется [**Ответ: кластеризация**].

3. Вероятностный показатель оценки качества кластеризации с учетом случайного угадывания называется [**Ответ: скорректированный индекс Рэнда (Rand)**].

4. Метод определения оптимального числа кластеров, основанный на анализе суммы квадратов внутрикластерных расстояний, называется [**Ответ: метод локтя / Elbow Method**].

5. Метрика, оценивающая качество кластеризации на основе соотношения внутрикластерного сходства и межкластерного различия, называется [**Ответ: индекс силуэта / Silhouette Score**].
6. Метрика для оценки качества кластеризации, принимающая значения от -1 до 1, где 1 означает хорошее разделение кластеров, называется [**Ответ: индекс силуэта / silhouette score**].
7. Метод определения оптимального числа кластеров, основанный на анализе графика суммы квадратов внутрикластерных расстояний, называется [**Ответ: метод локтя / elbow method**].
8. Процесс повторного запуска алгоритма кластеризации с разными инициализациями для оценки стабильности результата называется [**Ответ: анализ стабильности / stability analysis**].
9. Метрика оценки качества кластеризации, основанная на среднем расстоянии объекта до своего кластера и до соседних кластеров, называется [**Ответ: коэффициент силуэта / silhouette score**].
10. Метод определения оптимального числа кластеров, основанный на поиске точки перегиба графика суммы квадратов внутрикластерных расстояний, называется [**Ответ: метод локтя / elbow method**].
11. Метрика, оценивающая качество кластеризации как отношение суммы квадратов расстояний между кластерами к сумме квадратов расстояний внутри кластеров, называется [**Ответ: индекс Калински-Харабаса / Calinski-Harabasz Index**].
12. Метрика, основанная на отношении минимального расстояния между кластерами к максимальному диаметру кластера, называется [**Ответ: индекс Данна / Dunn Index**].
13. Метрика оценки качества кластеризации, которая учитывает среднюю схожесть между кластерами (чем меньше значение, тем лучше), называется [**Ответ: индекс Дэвиса-Болдина / Davies-Bouldin Index**].
14. Внешняя метрика оценки качества кластеризации, корректирующая индекс Rand на случайное совпадение, называется [**Ответ: Adjusted Rand Index / ARI**].
15. Метрика, измеряющая количество информации, разделяемой между кластерной разметкой и истинными метками, называется [**Ответ: Normalized Mutual Information / NMI**].

16. Метрика, оценивающая качество кластеризации на основе попарного сравнения объектов (правильно/неправильно отнесены к одному кластеру), называется [**Ответ: индекс Rand / Rand Index**].
17. Визуальный метод анализа качества иерархической кластеризации в виде древовидной структуры называется [**Ответ: дендрограмма**].
18. Метод оценки оптимального числа кластеров, сравнивающий внутрикластерную дисперсию с ожидаемой при случайном распределении данных, называется [**Ответ: Gap Statistic / статистика разрыва**].
19. Интерпретация отрицательного значения коэффициента силуэта (Silhouette Score) для отдельного объекта означает, что объект находится [**Ответ: ближе к соседнему кластеру, чем к своему / неправильно классифицирован / вероятно, является выбросом**].
20. На силуэтной диаграмме (silhouette plot) «толщина» силуэта кластера характеризует [**Ответ: количество объектов в кластере**], а «длина» силуэта каждого отдельного объекта отражает [**Ответ: значение коэффициента силуэта для этого объекта / качество отнесения объекта к своему кластеру**].